







中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生数学建模竞赛

学　　校	
参赛队号	
队员姓名	1.
	2.
	3.

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题　目：　基于语音锚点对齐与缺失感知融合的多模态情感预测研究

摘　要：

一段视频里的情绪从措辞、语调、神情三条通道同时流出，可用的线索却常常残缺。三条通道的推进速度相差两个数量级，录制过程又会使其中某一条整段取不到数，模型给出的分数亦无法说明依据。数据取CMU-MOSEI英文多模态语料，针对三问依次建立**语音锚点词元对齐模型**、**缺失感知融合网络**与**四层归因回溯模型**，三问共用一套输入接口。参数仅在附件2的训练划分上学习，结构仅在验证划分上确定。

针对问题一的三种通道对齐，首先定公共刻度：语音每十毫秒取一帧，把eGeMAPS描述子与梅尔倒谱系数拼成45维；视觉每一百毫秒取一帧，由MTCNN定位人脸后送入面部网格模型，输出52个表情系数、3个姿态角与1个人脸检出标志，合计56维；文本取冻结语言模型末层的768维隐状态。然后由语音识别给出每个词的起止时刻，用最长公共子序列对齐转写与识别结果，未配对的词由两侧锚点按词数分摊。最后给每个词元配一段时间窗，窗内的语音帧与视觉帧一并归到该词元上，映射单调不减、并集覆盖整段、每窗至少命中一帧。建立的模型记为**语音锚点词元对齐模型**，结果是100条全部提取完成，**词级对齐率为80.7%**，有效词元2447个，**没有词元窗落空**，人脸检出率为0.898，自算的文本特征与附件2逐元素比对，平均绝对差为0.000，结果详见表4-1与表4-2。

针对问题二的通道失效预测，首先要区分三类零值：补足长度的填充、数据自带的零行、人为制造的缺失，判据不统一会让填充被误判为缺失；文本一路另需单独处理，附件2给的是冻结隐状态，每个位置都带整句语义，只把缺失位置置零等同于没有缺失。然后把缺失词元改写为未登录记号后重新编码，编码器再以**低秩增量**随之调整，各通道学习一个缺失词元替换不可信的位置，模态内与跨模态之间各接一层注意力，汇聚时只对可用位置归一化。最后在连续区段掩蔽之外叠加整模态丢弃，合称**两级掩蔽增广**，并加入重建与一致性两项约束；融合方式设门控与平均融合两个候选，按事先写定的准则在验证集上裁定。建立的模型记为**缺失感知融合网络**，测试集上**平均绝对误差为0.602**，与标注的相关系数0.697，三分类准确率0.697、F1值0.688；**缺失率超过20% 后，本文单模型的误差低于全部只训练一次的开源方法**，缺失70% 时为0.805，最强对照Self-MM为0.835；**文本整体缺失时误差由0.612升至0.876**，语音或视觉整体缺失只升高1.9% 与1.4%。附件3的30条判出正向19条、负向5条、中性6条，结果详见表5-6与表5-12。

针对问题三的依据解释，首先把解释拆成四层：通道的作用程度由融合处的门控权重给出，通道的必要性由整条遮蔽前后的预测偏移给出，片段的重要性由**积分梯度**与注意力权重各自归一化再求和的得分给出，依据的可回溯性由问题一的映射给出，把位置下标换算为原文本词、语音时段与视觉关键帧。然后按综合得分排出前三个依据位置，逐条回看原始视频。最后另设删除对照，检验解释的忠实性。建立的模型记为**四层归因回溯模型**，测试集上平均绝对误差为0.625、与标注的相关系数为0.674、三分类准确率为0.649；**清**

掉被指认的3个文本依据所带来的预测变化，是清掉同样多个随机位置的4.53倍；验证样本中有97.80% 以文本为主要参考模态。附件4的20条中，判为负向的8条、正向7条、中性5条，依据均可回溯到具体时刻，结果详见表6-2与表6-7。

本文的推进有三点。其一，文本缺失放在词元这一级处理，训练时编码器同步调整，评测所依据的口径与附件3给出的缺失编码相同。其二，缺模态情形的对照都在同一套掩码下完成，网络结构与挑选准则事先写定、只在验证集上裁决，通道、占比、位置三者交叉铺成一张覆盖齐全的网格。其三，解释给出的位置可经问题一的映射回溯至原始素材，忠实性另有量化检验。

关键词：多模态情感识别；语音锚点对齐；模态缺失；分层融合；积分梯度；归因回溯

目 录

1 问题重述 **4**
1.1 问题背景 4
1.2 问题提出 4
1.3 数据说明 5
1.4 数据预处理与评价指标 6

2 模型的假设 **8**

3 符号说明 **8**

4 问题一的模型建立与求解 **10**
4.1 问题一分析 10
4.2 问题一数学模型 13
4.3 问题一模型求解 16
4.4 问题一求解结果 17

5 问题二的模型建立与求解 **22**
5.1 问题二分析 22
5.2 问题二数学模型 24
5.3 问题二模型求解 28
5.4 问题二求解结果 29

6 问题三的模型建立与求解 **40**
6.1 问题三分析 40
6.2 问题三数学模型 42
6.3 问题三模型求解 44
6.4 问题三求解结果 45

7 模型的评价 **55**
7.1 模型的优点 55
7.2 模型的缺点 56
7.3 模型的改进与推广 57

参考文献 **57**

附录 **60**

1 问题重述

1.1 问题背景

情绪在说话时同时经由三条通道表达：文字承担语义，语调承担态度的强弱，面部表情与头部动作承担即时反馈。任何一条通道都无法独立给出判断：反讽依赖语调的上扬，语义上的批评配上笑容会被当作玩笑。三条通道一致时单通道判断大致可用，错位时随即失效。稳定的情绪判断只能建立在三条通道的联合表示上。

把这项工作做成系统，困难有三处。第一处是时间尺度不齐：语音按毫秒级推进，画面每秒出数十帧，文字以词为单位逐个给出。时间轴不先统一，逐位置融合便无从下手；对齐精度又直接决定融合效果的上限。第二处是采集不完整：镜头会被遮挡，环境噪声持续存在，转写也会出错，某条通道因此可能连续一段时间没有可用数据，融合方式固定的网络在这种情形下性能下降很快。缺失补全的既有工作分三条路线：把缺失位置视为图上的待补节点，靠通道间的消息传递恢复表示 [1]；用生成模型直接合成缺失处的特征 [2]；绕开补全、直接学习对缺失不敏感的代理表示 [3]。第三处是判断依据无法追溯。多数模型只给出一个分数，无法说明判断来自语音还是画面，在需要人工复核的场景中不可信。近年的工作从两个方向推进：按通道区分各自贡献 [4]，以及定位情绪在对话中的成因 [5]。该领域的整体进展与遗留问题见综述 [6]。

本文的数据对象是 CMU-MOSEI [7]，一份英文多模态情感数据集，将公开视频切分为片段，每个片段用视频标识与片段编号联合定位，并附英文转写、$[-3, 3]$ 区间上的情感强度标注以及情感极性标签。该值小于零为负向，等于零为中性，大于零为正向，绝对值给出情绪强弱。全篇只使用题目给出的四个附件，不使用外部情感数据。

1.2 问题提出

问题一解决输入端的表示与对齐。输入为附件 1 的 100 条原始视频，要求建立三条通道统一处理的特征提取与时序对齐模型，说明处理链路、每条通道的特征量与计算方法、通道间的对齐方式以及实现环境。输出的特征文件还需通过三道核查：样本编号、各模态文件名与该行特征三者一致；序列位置、长度与补零规则留有记录，可复核也可回溯原始素材；所用工具、参数与处理日志归档，他人可据此复现相同结果。该链路称为语音锚点词元对齐模型。

问题二的目标是在通道局部失效时保持预测稳定。局部缺失指某条通道有一整段连续时间取不到数据，而非该通道整段不存在。模型需在信息残缺下同时给出情感强度与极性，并说明缺失所在的通道、位置与持续长度各自对预测的影响，最后对附件 3 的 30 条测试样本完成推理并提交结果文件。该模型称为缺失感知融合网络。

问题三要求预测依据可以回看。模型在给出强度与极性的同时，还需说明结论依据所在：哪条通道贡献最大，各通道内部又是哪一段内容推动了该判断。依据必须能对回原始素材，语音定位到具体时段，文本定位到具体片段，视觉定位到具体帧。随后对附件 4 的 20 条测试样本做推理，一并提交预测与解释结果。该模型称为四层归因回溯模型。

模型参数取自附件 2 的训练划分，网络结构与各项阈值在验证划分上确定，附件 3 与附件 4 不带标签，只做前向推理。评价以平均绝对误差为主指标，另给皮尔逊相关系数、准确率与 F1 值。附件 1 的 100 条视频来自 37 个视频标识，同一标识下的若干片段共享同一段原始素材。

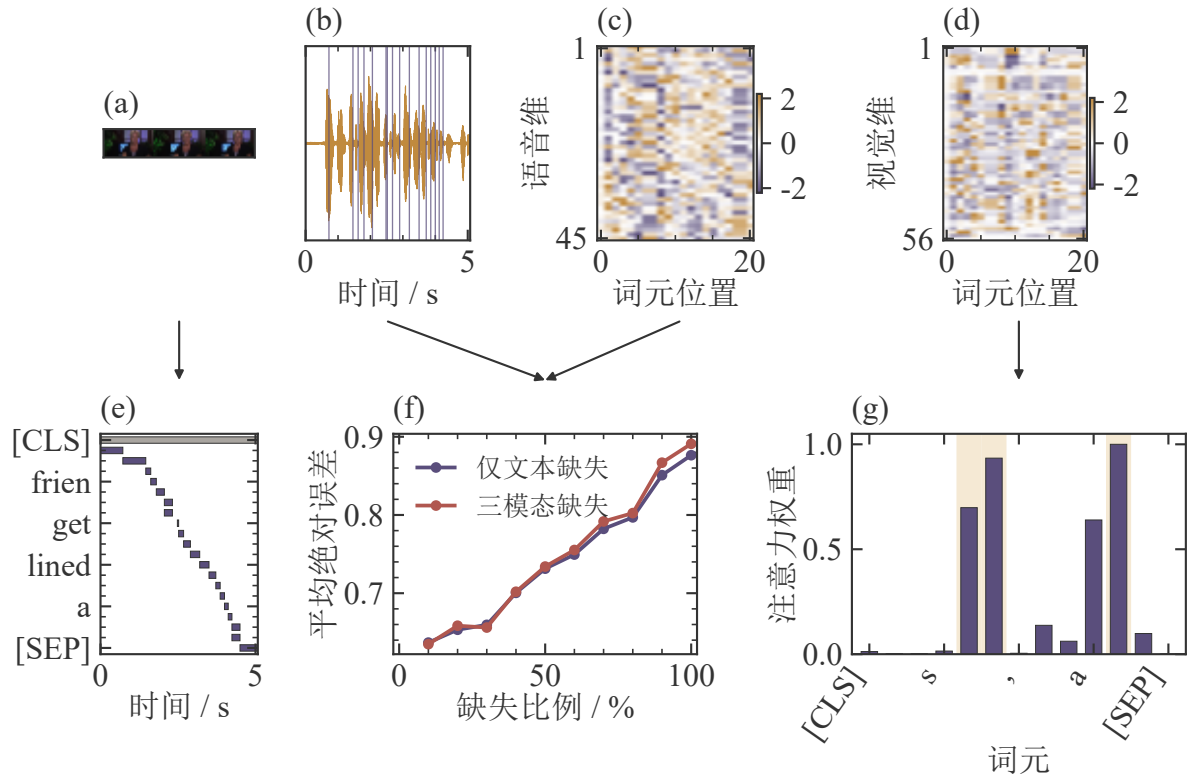


图 1-1　一条真实样本与三问的产物

图 1-1 以附件 1 的一条真实样本贯穿全文，七格均取自该样本。上排四格是从素材到特征的过程：(a) 等间隔抽取的三帧画面；(b) 音轨波形，竖线为恢复出的逐词边界，17 个词的疏密差异很大；(c)(d) 为按词元取窗均值得到的语音与视觉特征矩阵，两格共用 21 个有效词元的位置轴，色阶为逐维标准化后的取值。两幅矩阵的色块纵向成片、横向分段，分界与 (b) 的竖线一致，说明特征纹理按词切开。下排三格是三问在该样本上的产物：(e) 逐词元时间窗，横条长度即该词元时长；(f) 缺失比例与误差曲线，两条线分别为只缺文本与三模态同缺；(g) 另一个样本的逐词元注意力权重，底纹标出被选为依据的三个位置。

1.3　数据说明

题目共给出四个附件。附件 2 是本文的主体数据，含 4850 条标准化样本，每条带情感强度与极性标注，训练、验证、测试三份依次含 3395、728 和 727 条，各有一个对齐版与一个非对齐版。附件 1 为 100 条原始视频片段，用于问题一提取特征、统一时间轴。附件 3 含 30 条样本，三条通道中被人为挖除一段，考察局部缺失下的稳定性。附件 4 含 20 条样本，三条通道完整，考察模型能否说明判断依据。

本文全篇使用对齐版，三个问题的输入口径一致。对齐版把三条通道安排为最多 50 个一一对应的位置，文本每位置 768 维，语音 74 维，视觉 35 维。非对齐版给文本 50 个位置，语音与视觉各 500 个位置，通道之间不存在一一对应。位置编号与时刻的换算关系由问题一给出，后两问均按此取特征。

读数据时有三处易出错，本文均未采用。第一处出自附件 3 的非对齐版，其 raw_text 字段还留有完整原文，对齐版中改记为未登录记号的词在此处可原样读取。以它为输入等于补全了本应缺失的文本，问题一关于文本缺失的讨论将失去意义，故读附件 3 时只使用对齐版并只取词元编号。第二处在附件 4 的视频元数据中，混有影评摘要与平台标

题，如 There is nothing good about this film，情感倾向十分明确。附件 4 只读画面与音轨，元数据一律不用。第三处是重合：附件 3 的 30 条与附件 4 的 20 条中，分别有 4 条和 5 条落在附件 2 的测试划分内，标签可直接对应，本文未取用。

还有一处口径需先说明。题目文档给出的时长区间是 2.648 秒到 34.567 秒。逐条核对后，该数值与 mp4 容器中的记录一致，却比实际内容偏长。音轨真实长度落在 2.228 秒到 29.110 秒之间，100 条的容器时长无一例外都长于音轨，其中 90 条多出 0.200 秒以上，平均多 3.430 秒，最大差值 8.453 秒。真实内容长度以视频流与音频流为准，两者几乎相等；若按容器时长铺开时间轴，整段起始时刻都会随之偏移。本文的时间轴一律以音轨为准，汇总表中三种时长并列，可逐条比对。

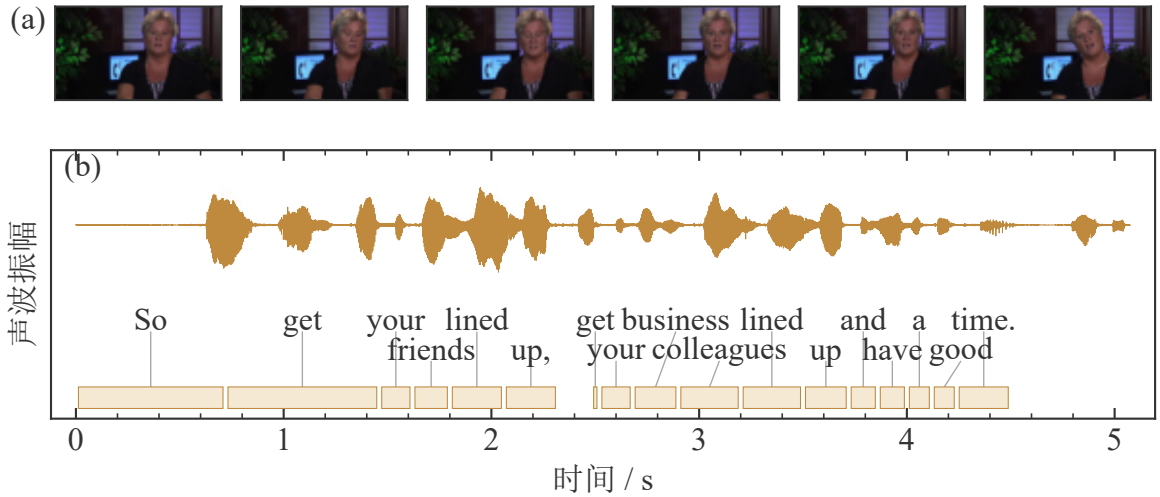


图 1-2　样本 -RfYyzHpjk4$_$11 的画面与语音

图 1-2 取附件 1 中的片段，标识 -RfYyzHpjk4$_$11，音轨长 5.070 秒，转写为 So get your friends lined up, get your business colleagues lined up and have a good time，标注情感强度为 2.000。(a) 联把整段等间隔切成六份各取一帧，说话人的嘴形与神情随之变化。(b) 联给出同一段音轨的波形，17 个词的起点以竖线画在波形上，由三角符号与上方六帧连线对应。词的跨度差异很大，最短的只有 0.040 秒，开头两个词均在 0.700 秒以上。两路共用一根时间轴而采样密度不同，文本还需按词切开，问题一要处理的错位即在此处。整段只有一个强度标注，三条通道若不先合并为整体表示，便无法与标注比对。

1.4　数据预处理与评价指标

本节先说明后文反复使用的记号，再给出评价指标。一条多模态样本由三条通道的特征与一个标注构成，记作四元组

$$\mathcal{S} = \left(\mathbf{X}^{(\mathrm{t})},\ \mathbf{X}^{(\mathrm{a})},\ \mathbf{X}^{(\mathrm{v})},\ y\right), \tag{1-1}$$

其中上标 t、a、v 依次指文本、语音和视觉，$\mathbf{G}^{(u)} \in \mathbb{R}^{N_p \times f_u}$ 是通道 u 的时序特征矩阵，位置总数 $N_p = 50$，$y \in [-3, 3]$ 是情感强度标注。附件 2 对齐版的三条通道维度为 $f_{\mathrm{t}} = 768$、$f_{\mathrm{a}} = 74$、$f_{\mathrm{v}} = 35$。极性无需另建模型学习，题目已给出由强度换算的规则

$$c = \begin{cases} 0, & y < 0 \ \text{（负向）}, \\ 1, & y = 0 \ \text{（中性）}, \\ 2, & y > 0 \ \text{（正向）}. \end{cases} \tag{1-2}$$

模型输入固定为三行整数：第一行为词元编号，第二行为注意力掩码，第三行为分段编号，合记作 $\mathbf{B} \in \mathbb{Z}^{3\times N_p}$。某个位置是否承载内容、整条样本的有效长度，均按下式读出

$$\nu_t = \mathbb{I}\left[B_{2,t} = 1\right], \qquad L = \sum_{t=0}^{T-1} \nu_t. \tag{1-3}$$

位置编号从 0 开始，0 号位与 $\ell - 1$ 号位分别留给句首、句尾记号，其后位置都是对齐长度所需的填充零。附件 2 训练划分上 ℓ 最短 3，最长 50。

特征矩阵中整行为零的位置有多种来源，需先区分。一是有效长度之外为对齐长度填充的零；二是数据固有的零行，句首、句尾两处特殊位置上的语音与视觉恒为零；三是人为挖除造成的缺失。三类情况由同一套判据识别

$$\chi_t^{(u)} = \begin{cases} \mathbb{I}\left[B_{1,t} = \mathrm{id}_{\mathrm{unk}}\right] \vee (1 - \nu_t), & m = \mathrm{t}, \\ \mathbb{I}\left[\left\|\mathbf{G}_{t,:}^{(u)}\right\|_1 = 0\right] \vee (1 - \nu_t), & m \in \{\mathrm{a}, \mathrm{v}\}, \end{cases} \tag{1-4}$$

其中 $\mathrm{id}_{\mathrm{unk}}$ 是未登录记号的编号。文本通道的缺失不写成零向量，而将该处词元改写为未登录记号，附件 3 采用这套编码，30 条逐条统计均可对应。通道 u 在有效区间内的缺失占比为

$$\beta_u = \frac{1}{L} \sum_{t=0}^{\ell-1} \chi_t^{(u)}. \tag{1-5}$$

句首、句尾两个特殊记号位上语音与视觉恒取零值，属数据本来的零行，不计为缺失。按式 (1-4) 的写法，模型输入也会把这两处标为缺失，与训练阶段口径一致；只在统计附件 3 人为缺失时才予剔除。按此口径，附件 3 的 30 条样本中 27 条存在缺失，三条通道的缺失比例均值依次为 0.186、0.186 和 0.190。

三条通道的取值量级相差很大：语音各维最大绝对值之间相隔两个数量级，视觉集中在个位数，不加处理时语音会在融合中盖过另外两路。因此语音与视觉两路需逐维标准化，均值与标准差只统计训练集中有效且非缺失的位置

$$\tilde{X}_{t,j}^{(u)} = \frac{X_{t,j}^{(u)} - \bar{x}_j^{(u)}}{\varkappa_j^{(u)} + \varepsilon}, \qquad m \in \{\mathrm{a}, \mathrm{v}\}, \tag{1-6}$$

式中 $\bar{x}_j^{(u)}$ 与 $\varkappa_j^{(u)}$ 为该维在训练集上的均值与标准差，$\varepsilon = 10^{-6}$。文本通道取冻结语言模型的隐状态直接使用，各维本就在同一量级，不再做标准化。标准化完成后，缺失与填充两类位置一律重新置零，0 仍作为不可用的标记。

结果从两个方面衡量。情感强度一侧为回归，主指标取平均绝对误差，另配皮尔逊相关系数反映预测序列与标注序列的贴合程度

$$\mathrm{MAE} = \frac{1}{N} \sum_{i=1}^{N} \left|\hat{o}_i - y_i\right|, \qquad r = \frac{\sum_i \left(\hat{o}_i - \bar{\hat{o}}\right)\left(y_i - \bar{y}\right)}{\sqrt{\sum_i \left(\hat{o}_i - \bar{\hat{o}}\right)^2}\sqrt{\sum_i \left(y_i - \bar{y}\right)^2}}. \tag{1-7}$$

情感极性为分类任务，采用准确率与 F1 值。式 (1-2) 三类对应的准确率记为 Acc_3，加权 F1 值记为 $\mathrm{F1}_3$。此外，多模态情感分析的既有工作常附一个只在非中性样本上计算的二分类指标，便于横向对照，即取出标注不为零的样本，比较预测值与标注值的符号是否一致

$$\mathrm{Acc}_2 = \frac{1}{|\mathcal{N}|} \sum_{i \in \mathcal{N}} \mathbb{I}\left[\operatorname{sgn} \hat{o}_i = \operatorname{sgn} y_i\right], \qquad \mathcal{N} = \{i : y_i \neq 0\}. \tag{1-8}$$

配对的加权 F1 值记为 $\mathrm{F1}_2$。模型的选取在验证划分上完成，测试划分仅用于最终报数。

2 模型的假设

后文的推演建立在以下六条假设之上。

第一，一段视频只配一个人工标签，本文据此认定该片段的情绪倾向在整段内不转向；若片段内部发生情绪翻转，该分数只能代表占上风的一方。问题二把整条序列池化为片段级向量，依据即在此条；片段内部若有转折，池化会把两种相反情绪平均，所得向量既不像前半段也不像后半段。

第二，一个词覆盖的区间很短，其间声调高低与面部肌肉活动的变化幅度有限，区间内对帧取平均仍能保留有判别力的起伏。词的平均长度在零点几秒量级，与一次表情动作的持续时间相当，该近似才成立。问题一按式 (4-9) 对窗内语音帧与视觉帧取均值得到该位置的向量，依据即在此条。语速极快、一个词内出现多次表情变化时，均值会削平变化，此时位置向量更接近词的中点状态。

第三，能与官方转写配对的词，直接采用语音识别输出的时间戳；未能配对的词按左右锚点之间的词数线性分摊，这等价于假定锚点之间语速不变。问题一的时间戳恢复与词元继承均建立在此之上。锚点稀疏且中间语速骤变时，如一处停顿或拖长音正好落在两锚点之间，插值位置会整体偏移；词匹配率 ζ 越低，偏差越易累积，问题一因此逐条记录匹配率，以便判断哪些样本的时间窗可信度低。

第四，矩阵中某行数值全为零时，其含义取决于该位置所在的范围：在有效长度以内为该通道此刻未取到内容，越过有效长度为对齐固定长度所补的填充，句首与句尾两个记号位上语音与视觉本为零，同样按不可用处理。这是判别缺失与填充的唯一准则，问题二统计附件 3 的缺失形态、替换缺失词元均照此执行，式 (1-4) 即该假设的写法。反向情形也存在：某条通道在某个时刻确实取到了内容，而内容恰好全为零，如静音段或中性帧，会被这条规则误报为缺失。此类位置数量很少，本文未专门修正，问题二在缺失网格上评测时也未区分。

第五，某个位置是否缺数据与那一时刻的情绪强弱无关，即缺失随机发生、不由强烈情绪引起。据此，问题二训练阶段人为掩蔽的区段与附件 3 中真实缺失的区段才可视为同一情形，训练所得的抗缺失能力才可迁移。若缺失集中在情绪最激烈的片段上，如说话人激动时镜头晃动导致画面连续失效，人工掩蔽与真实缺失便分属两个分布，问题二在缺失网格上的结论会偏乐观。

第六，附件 2 的两个划分与两份专项测试集取自同一批素材，彼此没有系统性分布偏移，标准化参数在训练划分上估计后可直接用于附件 3 与附件 4。式 (1-6) 的均值与标准差只在训练划分的有效非缺失位置上估计，问题二对附件 3、问题三对附件 4 推理均沿用这套参数，未重新估计。两个专项测试集若更换了录制设备、语言或场景，特征各维分布会移出该参数的覆盖范围，此时应就地重估标准化参数，再作预测。

3 符号说明

后文反复出现的符号统一列在表 3-1 中，按用途分为四组。

表 3-1　符号与单位

符号	说明	单位
位置与时长的量		
u	通道编号，文本记 t、语音记 a、视觉记 v	—
N_p	一条样本在时间轴上统一采用的槽位数，取 50	个

符号	说明	单位
f_u	通道 u 上一帧特征的维数	维
$\mathbf{G}^{(u)}$	通道 u 输入网络的时序矩阵，行数为 N_p、列数为 f_u	—
ℓ	一条样本实际占用的位置数，不足 N_p 时其余位置均为填充	个
$[\gamma_t, \Gamma_t]$	位置 t 对应时间窗的起止时刻	s
$\varrho(t)$	位置 t 对应的词	—
A	时间轴的长度，即音轨时长	s
ζ	官方转写与识别结果成功对齐的词比例	—
缺失与有效性		
ν_t	位置 t 可用与否的标志，可用记 1	—
$\chi_t^{(u)}$	通道 u 在位置 t 上缺失与否的标志	—
$\vartheta_t^{(u)}$	通道 u 位置 t 既在有效长度内又未缺失的标志	—
β_u	通道 u 在可用位置上被判为缺失的比例	—
模型内部的量		
d_{h}	隐状态的维数，取 128	维
$\Delta\mathbf{\Omega}$	语言模型注意力投影上的可学习低秩修正	—
$\mathbf{E}_p$	各位置通用的可学习位置编码	—
$\mathbf{E}_u$	通道 u 专属的可学习通道编码	—
$\boldsymbol{\xi}^{(u)}$	通道 u 用于替换缺失位置的向量	—
$\mathbf{S}^{(u)}$	通道 u 在自身内部编码完成后的隐状态	—
$\mathbf{C}^{(u)}$	通道 u 与其他通道交换信息后的隐状态	—
$\sigma_t^{(u)}$	通道 u 在位置 t 加权汇总时的权重	—
$\mathbf{y}^{(u)}$	通道 u 按权重汇总后得到的向量	—
w_u	通道 u 在融合中的权重，三条通道的权重之和为 1	—
$\mathbf{z}$	三路汇总之后的整体表示	—
$\hat{o}$	模型输出的强度数值	—
$\hat{k}$	模型输出的极性类别	—
$\hat{o}_u$	仅用通道 u 的池化向量得到的强度预测	—
解释与归因的量		
k	每条通道取出的依据位置数，取 3	个
n_s	积分梯度计算归因时的等分步数	步
Δ_u	通道 u 整条遮蔽前后两次预测的差值，记作必要性偏移	—
$\iota_t^{(u)}$	通道 u 位置 t 上积分梯度给出的归因值	—
$q_t^{(u)}$	通道 u 位置 t 汇总后的重要性得分	—
$\mathcal{Q}^{(u)}$	通道 u 上得分排前 k 位的位置集合	—

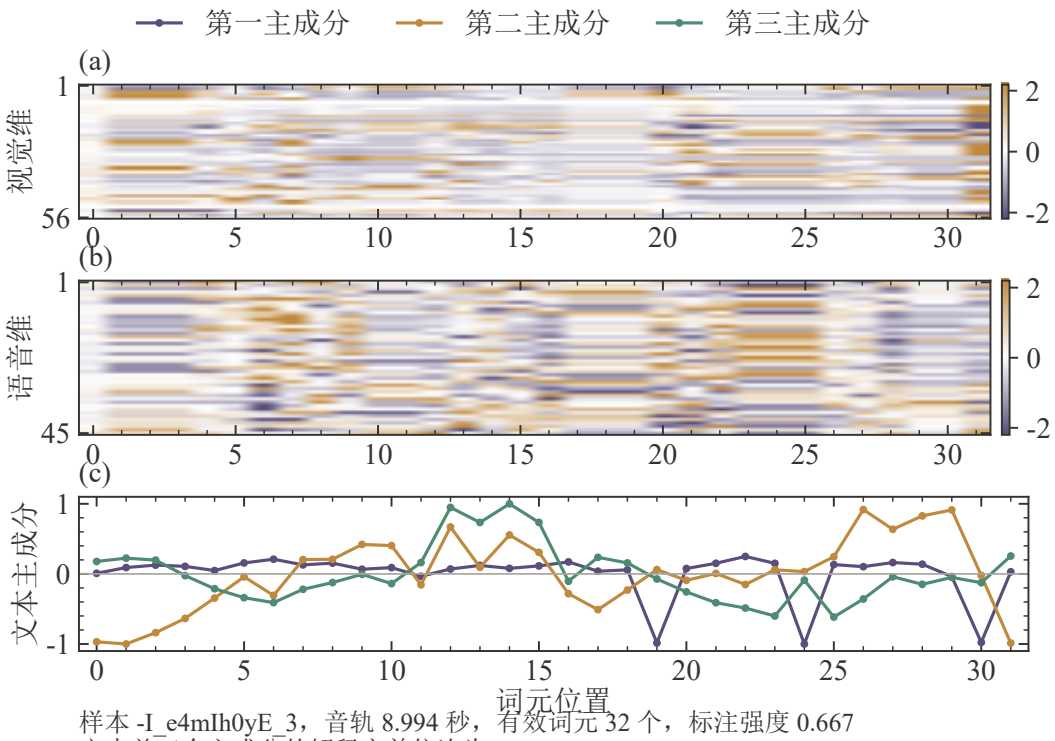
表中未列出的符号在首次使用处就地说明含义与取值范围。

全篇符号写法统一：上标标注通道，下标标注位置或序号，标量用普通斜体，向量与矩阵用粗斜体。

4 问题一的模型建立与求解

4.1 问题一分析

问题一要办两件事：每条通道提什么特征，节奏不等的三条通道如何落到同一套时刻上。对齐后每条样本得到三张同规模特征矩阵，见图 4-1。



样本 -I_e4mIh0yE_3，音轨 8.994 秒，有效词元 32 个，标注强度 0.667
文本前三个主成分的解释方差依次为 14.4%、10.6%、8.0%

图 4-1　一条样本对齐后的三模态特征矩阵

图 4-1 三格共用位置轴，色阶为逐维标准化值。(a)(b) 是视觉与语音的特征矩阵：前者色块纵向成片，几处横向窄白带即该段人脸未检出；后者纹理细密，同为 10 与 100 毫秒一帧的差别。(c) 是文本前三个主成分的走向，方差依次占 14.4%、10.6% 与 8.0%。三张矩阵的横向分段一致，边界即词与词的交界。

把样本的有效位置摞起来算相关系数，两条通道内部各有结构，见图 4-2。

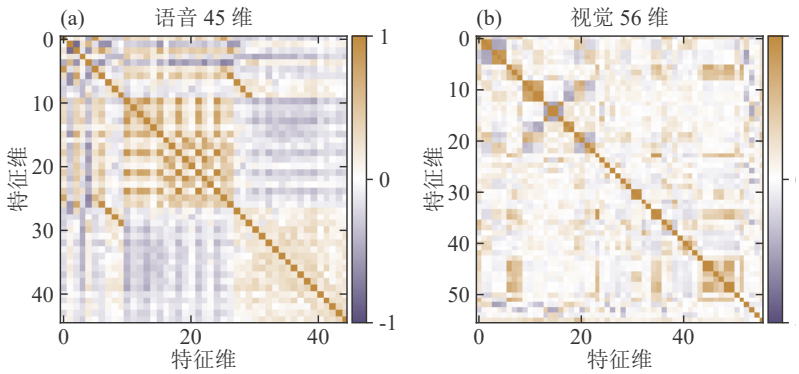


图 4-2　语音与视觉特征的相关矩阵

图 4-2(a) 为语音的 45 维，沿对角线排出一串方块，同族描述子如前四阶梅尔倒谱系数之间相关系数普遍在 0.6 以上，跨族的块接近零，可见 45 维里有一部分是冗余的。(b) 为视觉的 56 维，结构与语音不同：52 个表情系数彼此相关很弱，多数块偏白，只有开头几个与口部相关的维度成块，三个姿态角与检出标志几乎不与谁相关。这种差别决定了两条通道在融合中的角色，语音一路的价值在于族内的整体强弱，视觉一路的价值分散在单个动作上。

三条通道的天然节奏互不相同，这是对齐的难点。

语音的情绪线索落在韵律上。说话用力的大小反映在响度里，语调的起伏反映在基频与其抖动里，音色松紧反映在谱倾斜与 Hammarberg 指数里。这些量随发音连续变化，须在短窗上计算；10 毫秒的窗移既能跟上音素一级的变化，曲线又不会抖动过大。按此尺度，一条 7.8 秒的素材约合 780 个语音帧。

视觉的情绪线索体现在面部动作上。表情由四件事组合：眉毛抬高还是压低、眼睛睁开还是闭拢、嘴角向哪一侧牵、下巴张开多少；头部朝向由俯仰、偏航与翻滚三个角给出。一次表情动作从起到落不过零点几秒，每秒采十帧即可描出其轮廓，算量为原始帧率的三分之一。按此尺度，同一条素材得到约 78 个视觉帧。

文本里携带情绪的是语义，语义的单位是词。词的时长并不固定，快时只占零点一秒，慢时超过一秒，同一条 7.8 秒的素材平均只切出 19 个词。三者的个数比约 780:78:19，即 41:4:1。

图 4-3 三层共用底下一根时间轴，取的是样本 -HeZS2-Prhc$_$2，音轨 8.150 秒。最上层是等间隔抽出的六帧画面；中层画声波，竖线打在每个词的起点上；最下层把词元的窗画成横条，词元名标在横条上方。三层对照可见两件事。一是横条首尾相接，时间轴上没有空档，说明按时序铺开的窗把片段切得完整；二是同一个词分出的若干词元占同一段窗，几条横条叠在一起，说明到词元这一级尚未把词打散。这两条性质正是 4.2 节归并规则的前提。

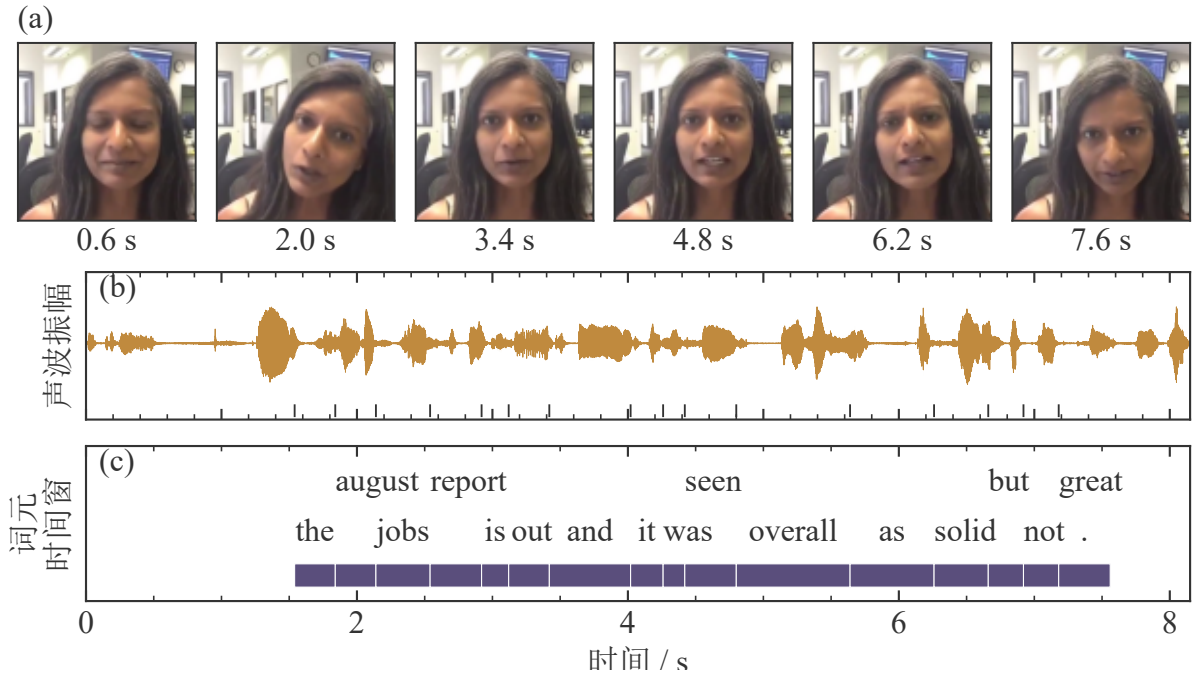


图 4-3　一条样本的三层时间结构

三者节奏相差悬殊，以任一条为基准拉伸或压缩另两条都不合适。按位置数平均切开时间轴的代价尤其大：一个长词可能被切成两半，语义单元被拆散，词的起点时刻也随之失真。因此本问不按时间等分，而是先找一种与语音、语义都好对应的公共刻度。官方转写由赛题给定，按词切开即得词的序列；英文词拼写与读音对应稳定，用声学模型可恢复每个词的起止时刻，这些时刻即锚点。锚点钉住时间轴，词以下的单位继承锚定结果，等分只发生在两个锚点之间，切点不会落入词的内部。

以词元而不以词为刻度，还有两个原因。英文词形变化多，词一级的单位常出现词表之外的写法，WordPiece 把词切成子词后单位数量固定、覆盖完整，长词由几个词元分担，短词也至少有一个词元。附件 2 的对齐版同样按词元组织出 50 个位置，本问交付的序列与它排列一致，后续两问可直接替换使用。

刻度定下之后，交付的序列固定为 50 个位置，与附件 2 一致；每个位置记录实际收到的帧数，只有收到零帧的位置算填充，其余均为实测；逐条样本的时间窗与命中帧数另存一份记录，供逐步回查：某个位置为何取该值，查记录即可看到它落在哪一段时间、收进了哪几帧。

时间轴的基准先定。附件 1 的 mp4 文件中，容器记录的时长普遍长于真实内容，音轨与容器两种时长分别落在 2.228 至 29.110 秒与 2.648 至 34.567 秒之间，容器长于音轨的样本恰好是 100 条，逐条数值见附录表 7-1。视频流与音频流的长度几乎相等，二者才是内容的真实长度，题目给出的区间指容器时长。若以容器时长铺轴，整段的时间戳会一起后移。本问以音轨长度为时间轴长度，视觉一侧的帧时刻取自解码器上报的呈现时间戳。

取帧的口径同理。附件 1 的素材帧率并不统一，100 条样本落在 23.690 到 30.000 帧每秒之间；按帧号除以标称帧率定位，同一秒里的画面在不同素材上会对不齐。改用解码器上报的呈现时间戳，每 100 毫秒取一帧，得到的即画面真实呈现的时刻，与音轨读数同处一套坐标。语音一侧帧移固定取 10 毫秒，帧时刻由采样点序号直接算出，不受采样率高低影响。

对齐完成后还必须可查。核验指标分两层：一层看覆盖，即每个位置是否收到真实

的帧观测，由窗宽、窗内命中帧数与替代次数反映；另一层看内容，即词元与语音内容是否对应，由词匹配率、时刻是否倒退、是否越界反映。两层指标都不需要真值，可在 100 条样本上逐条算出，4.4 节按这两层给出结果。

特征与时刻缺一不可：特征提得再细，三条通道的时刻对不上就只能以整段均值互相迁就，位置之间的对应关系随之丢失；时刻对得再准，特征不带情绪信息也没有用处。本问做扎实前一件事，把后一件事留给问题二与问题三。

4.2 问题一数学模型

本问模型以语音识别给出的词时刻为锚点，由词元继承锚点时间，故取名**语音锚点词元对齐模型**。模型分四步：定义三条通道的特征，补出词级时间戳，词元继承时间窗，帧按窗归并。

4.2.1 三条通道的特征定义

语音一侧每秒取一百帧，即帧移 10 毫秒，每帧向量由两段拼接。前一段用 openSMILE [8] 的 eGeMAPSv02 低层描述子，共 25 维，含响度与基频这类韵律量、抖动、闪烁、谱斜率、alpha 比与 Hammarberg 指数这类音质量，以及共振峰与前四阶的梅尔倒谱系数；后一段用 librosa 计算 20 阶梅尔倒谱系数，分析窗 400 点、相邻窗隔 160 点，补足短时谱包络的细节。两段拼接共 45 维

$$\mathbf{A} = \left[\mathbf{A}^{\mathrm{ege}} \,\|\, \mathbf{A}^{\mathrm{mfcc}}\right] \in \mathbb{R}^{L_a \times 45}, \qquad t_k^a = 0.01k. \tag{4-1}$$

eGeMAPS 是为情感计算选出的最小参数集，响度与基频刻画说话的力度与语调，抖动、闪烁与谱倾斜刻画嗓音的粗糙与紧张，都直接对应听感上的情绪色彩；梅尔倒谱系数展开短时谱包络，补上音色中更细的差别。两段并用比只留一段更全面，维数又不至于涨到样本量无法支撑。

视觉一侧的步长是 100 毫秒，人脸检测分两步。面部网格模型 [9] 的检测器只适用于近景，画面为 1280×720、人脸边长只有 120 像素上下时便无法定位，只用这一步，100 条里有 14 条整段检不出人脸。因此第一步交给 MTCNN [10]：在整帧上框出人脸 $\mathbf{r}_k$，按 0.6 倍向外扩展边距后裁下，短边不足 192 像素的放大到该尺寸，再送入第二步的面部网格模型。模型输出 52 个表情系数，每个落在 0 到 1 之间，衡量一块面部肌肉的活跃程度；姿态角另有三项，由面部变换矩阵 $\mathbf{R} \in \mathbb{R}^{3\times3}$ 解出

$$\theta_{\mathrm{pitch}} = \arctan\frac{R_{32}}{R_{33}}, \quad \theta_{\mathrm{yaw}} = \arctan\frac{-R_{31}}{\sqrt{R_{11}^2 + R_{21}^2}}, \quad \theta_{\mathrm{roll}} = \arctan\frac{R_{21}}{R_{11}}. \tag{4-2}$$

最后一位为人脸检出标志，检出填 1，未检出填 0，同时把前面 55 维清零，三段合计 56 维

$$\mathbf{V}_k = \left[\mathbf{V}_k^{\mathrm{blend}} \,\|\, \boldsymbol{\theta}_k \,\|\, \mathbb{I}_{\mathrm{face},k}\right] = \mathrm{FaceMesh}\left(\mathrm{Crop}\left(\mathbf{I}_k,\, \mathbf{r}_k\right)\right) \in \mathbb{R}^{56}, \qquad t_k^v = 0.1k, \tag{4-3}$$

式中 $\mathbf{I}_k$ 是第 k 个视觉帧的图像。扩展边距是为把额头上方与下巴一并圈入，放大是让远处的脸在网格模型中占够像素，系数才稳定。姿态角与表情系数分列，是因为朝向本身不是情绪，却会改变表情系数的读数。保留一维标志，是因为未检出与中性表情在数值上均贴近零向量，单看数值无法区分。两步检测的效果见图 4-4。

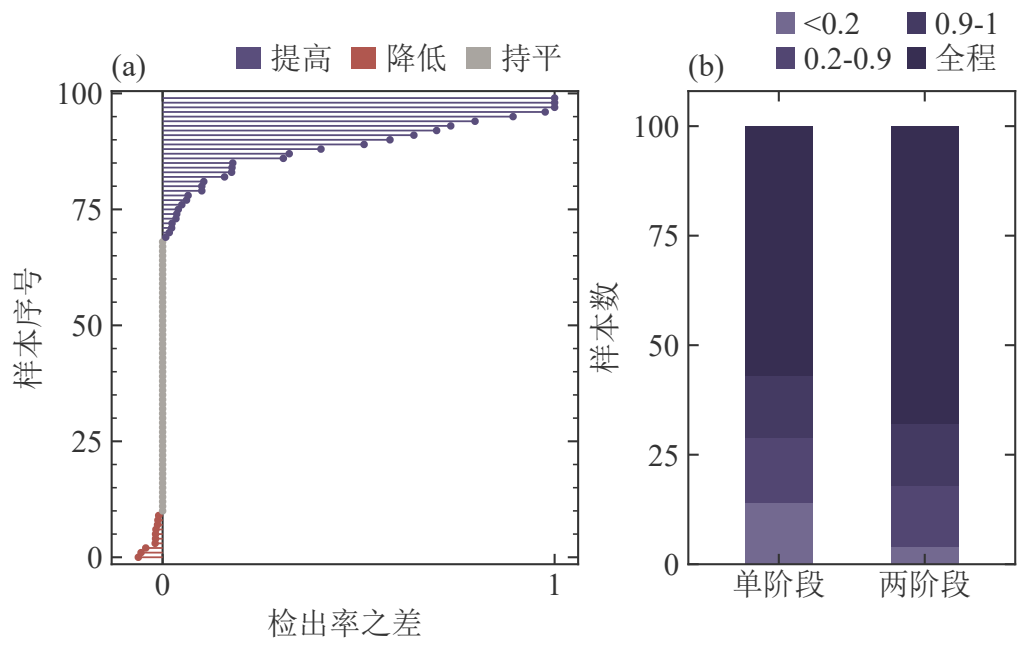


图 4-4　两步检测与单步的检出率对比

图 4-4(a) 竖棒高为两步与单步检出率之差，样本按差值自左向右排列，零线以上为绿、以下为赤。右端连片绿棒说明两步检测起了作用：差值超过 0.01 的 30 条，另有 5 条从接近零升过 0.9，属远景小脸一类；差值在正负 0.01 之内的 60 条可视为未变；左端 10 根赤棒略降，最大降幅 0.062，这些素材本已接近全程检出。图 4-4(b) 按检出率把样本分成四档，两列堆叠竖条对应单步与两步：全程检出一档由 57 条升到 68 条，不足 0.2 一档由 14 条降到 4 条，平均检出率由 0.789 升到 0.898。剩下 4 条逐帧查看，画面里本就没有人，空镜与物品特写即属此类。

文本一侧用冻结的 bert-base-uncased [11]，隐状态只取最后一层。词元编号序列写作 $\mathbf{b}$，注意力掩码写作 $\mathbf{u}$，于是

$$\mathbf{X}^{(\mathrm{t})} = \mathrm{BERT}\,(\mathbf{b}, \mathbf{u}) \in \mathbb{R}^{T\times 768}. \tag{4-4}$$

参数在提取阶段固定不动，原因有两个：本问只负责把三条通道变为可对齐的特征，不引入训练；权重不动，所得表示才能与附件 2 直接比对。以附件 2 的验证集逐元素比对，本问算的隐状态与附件数值平均只差 0.000，相关系数 1.000；逐层比对，第 12 层完全一致，第 11 层平均绝对差 0.276，可见附件 2 用的正是末层输出，两者处在同一表示空间。另两条通道不能照搬附件 2：那一套语音 74 维、视觉 35 维，出自原数据集的专用工具，本问改用开源工具，得到 45 维与 56 维，维数与含义均不相同，故另成一套、不与附件 2 混用。

4.2.2　词时刻的恢复与传递

赛题只提供整句转写，词的起止时刻需先补出，再逐词传递。做法是用 Whisper 的 small.en 模型 [12] 处理音轨，一并输出词级时间戳，识别词序列即 $\{(w_j^r,\ t_j^s,\ t_j^e)\}_{j=1}^{n_r}$；官方转写按词切开，得到 $\{w_i^o\}_{i=1}^{n_w}$。两份词表对应同一句话，写法与切分却未必相同。故先统一为小写并删去标点，再求两者的最长公共子序列，落在子序列上的词即配成一对

$$\mathcal{A} = \left\{(i,j)\ \middle|\ w_i^o \text{ 与 } w_j^r \text{ 落在同一条公共子序列上}\right\}. \tag{4-5}$$

配成对的官方词直接采用识别时刻；识别文字到此为止，后文一概以官方转写为准。未能配对的官方词位于相邻两个锚点之间，按中间词数线性内插

$$\gamma_i = t_{\text{left}} + \left(t_{\text{right}} - t_{\text{left}}\right)\frac{i - i_{\text{left}} - 1}{n}, \qquad \Gamma_i = t_{\text{left}} + \left(t_{\text{right}} - t_{\text{left}}\right)\frac{i - i_{\text{left}}}{n}, \tag{4-6}$$

式中 i_{left} 与 i_{right} 为两个锚点的序号，$n = i_{\text{right}} - i_{\text{left}} - 1$ 为两者之间未能配上的词数；t_{left} 取左锚点的收尾时刻，t_{right} 取右锚点的起始时刻，插出的区间与两侧锚点相接。句首无左锚点取 0，句末无右锚点取音轨长度；全句配不出锚点时，退化为按词数把整段时长分摊给每个词。所有算出的时刻一律截入 $[0, A]$ 区间，A 为音轨长度。词匹配率定义为

$$\zeta = \frac{|\mathcal{A}|}{I}, \tag{4-7}$$

它既可衡量插值是否可靠，也可判断该文本与该段语音是否成套。

此处用最长公共子序列而非逐位比对，是因为两份词表长度往往不等：识别可能把一个词听成两个，也可能把相邻两词连成一个。逐位比对一旦错位，其后所有词都会连带出错；最长公共子序列只要求配上的词在两边保持同样的先后次序，插入与删除都不影响配对结果。配对结果还可作为质量指标：词匹配率偏低说明这份转写与这段语音不成套。4.4 节据此核查了全部样本。

4.2.3 词元继承与帧归并

接下来把官方词按 WordPiece 切成词元。序列首位放句首记号，其窗取整段；中间每个词元沿用所属词的窗；末位放句尾记号，窗从末词结束处延到片段末尾；词元多于 50 个的截去尾端，不足的位置补零。位置与时间由此对应

$$t \mapsto [\gamma_t,\ \Gamma_t], \qquad t = 0, 1, \ldots, \ell - 1. \tag{4-8}$$

首尾两个记号也占位置，是因为它们标记序列的起止。上限取 50 与附件 2 的位置数一致，长素材超过 50 个词元的尾部被截去；短素材不足 50 的位置填零，填充位置由掩码标出，不会被误判为真实内容。

两条连续通道的处理方式相同：先找出窗内的帧，再合成为一个向量。设通道 u 的第 k 帧时刻为 t_k^m、特征为 $\mathbf{F}_k^{(u)}$、帧间隔为 Δ_m，位置 t 的取值由下式给出

$$\mathbf{G}_{t,:}^{(u)} = \begin{cases} \dfrac{1}{|\mathcal{K}_t|}\displaystyle\sum_{k \in \mathcal{K}_t} \mathbf{F}_k^{(u)}, & \mathcal{K}_t \neq \varnothing, \\ \mathbf{F}_{k^*}^{(u)}, & \mathcal{K}_t = \varnothing, \end{cases} \qquad \mathcal{K}_t = \left\{k \,\middle|\, \gamma_t \le t_k^m < \max\left(\Gamma_t,\ \gamma_t + \Delta_m\right)\right\}, \tag{4-9}$$

其中 $k^* = \arg\min_k \left|t_k^m - (\gamma_t + \Gamma_t)/2\right|$ 是与窗中点最近的帧序号。取均值使长词内各帧共同参与，而非只由开头一帧代表；窗内无帧时取最近的一帧替代，不填零，以免把短词误判为缺失。归并之后，语音与视觉在每个位置各得一个向量，文本向量由该位置的词元给出，三条通道长度相同，后续两问得到一套等长序列。取均值而不把窗内帧逐帧拼接的好处是向量长度固定为 45 与 56，与窗内帧数无关，长词与短词处在同一量级。

归并规则有三条性质，保证每个位置都取得真实观测。第一条是时刻单调：锚点取自识别给出的逐词时刻，随词序递增；落单的词按词数内插，插出的时刻落在两锚点之间并随序号前移；词元继承所属词的窗，同词的几个词元共用一段窗。三者合起来，各窗的起点与终点都随位置不减；截入 $[0, A]$ 是单调变换，不减性不受破坏。第二条是无缝覆盖：第 i 个词的结束时刻在插值时取为第 $i+1$ 个词的起始时刻，锚点处由识别输出保

证，相邻两窗首尾相接；链的两端由句首与句尾两个记号覆盖，所有窗的并集正是 $[0,A]$。第三条是每窗有帧：帧时刻在 $[0,A]$ 内以间隔 Δ_m 等距排布，网格写作 $\Delta_m\mathbb{Z}\cap[0,A]$，其补集由若干段开区间组成，每段长度不超过 Δ_m，而窗长不小于 Δ_m，不可能整段落在其中，故至少含一个帧时刻。

$$
\begin{cases}
\mathbf{A}=\left[\mathbf{A}^{\mathrm{ege}}\,\|\,\mathbf{A}^{\mathrm{mfcc}}\right],\quad t_k^{a}=0.01k & \text{语音，45 维}\\
\mathbf{V}_k=\mathrm{FaceMesh}\left(\mathrm{Crop}\left(\mathbf{I}_k,\mathbf{r}_k\right)\right),\quad t_k^{v}=0.1k & \text{视觉，56 维}\\
\mathbf{X}^{(\mathrm{t})}=\mathrm{BERT}\left(\mathbf{b},\mathbf{u}\right) & \text{文本，768 维}\\
\mathcal{A}=\mathrm{LCS}\left(\mathbf{w}^{o},\mathbf{w}^{r}\right),\quad \gamma_t \text{ 按式 (4-6) 插值并截入}[0,A] & \text{时刻的传递}\\
\left[\gamma_t,\Gamma_t\right]=\left[\gamma_{\varrho(t)},\Gamma_{\varrho(t)}\right],\quad \varrho(t) \text{ 是位置}t \text{ 所属的词} & \text{词元的继承}\\
\mathbf{G}_{t,:}^{(u)} \text{ 按式 (4-9) 归并},\quad t=0,\ldots,\ell-1,\ \ell\le N_p=50 & \text{窗内归并}
\end{cases}
\tag{4-10}
$$

4.3 问题一模型求解

整个求解以样本为单位逐条推进，完整步骤见算法 1。逐条处理而非整批处理，是因为素材长短相差十几倍，逐条便于随时把每个位置的命中帧数写入磁盘，出现问题也能追到具体样本；算法含两处退化处理，样本因此不会丢失，100 条原始素材一条不少。

算法 1　词元锚点对齐与窗内归并

输入： 视频文件 v，赛题给出的整句转写 o，识别模型 M，位置数上限 N_p
输出： 三通道对齐特征 $\mathbf{X}^{(\mathrm{t})},\mathbf{X}^{(\mathrm{a})},\mathbf{X}^{(\mathrm{v})}$，位置与时间窗的对应

用 ffprobe 量出三种时长：容器、视频流与音频流，时间轴长度取音频流时长 A
用 ffmpeg 从 v 解出 16 kHz 单声道音轨
在 10 毫秒的帧移上提出 45 维语音向量 $\left\{\left(\mathbf{F}_k^{\mathrm{a}},t_k^{\mathrm{a}}\right)\right\}$
按解码器上报的时间戳每 100 毫秒取一帧，先由 MTCNN 定框并裁脸，再交面部网格模型，输出 56 维视觉特征 $\left\{\left(\mathbf{F}_k^{\mathrm{v}},t_k^{\mathrm{v}}\right)\right\}$
用 M 识别音轨，取回带词级时间戳的识别结果 $\left\{\left(w_j^{r},t_j^{s},t_j^{e}\right)\right\}$
把 o 与识别词统一成小写、去掉标点，用最长公共子序列求配对集 $\mathcal{A}$
if $\mathcal{A}=\varnothing$ **then**
　　把 $[0,A]$ 按词数等分，作为逐词时间戳
else
　　配对词继承识别时刻；配不上的词按词数在左右两锚点之间内插，见式 (4-6)
end if
把逐词时间戳截进 $[0,A]$，记下词匹配率 $\zeta=|\mathcal{A}|/n_w$
按 WordPiece 切出词元，逐词元继承时间窗，句首与句尾两个记号各补一段，超过 N_p 的截掉
把词元序列喂给冻结的语言模型，输出 768 维文本特征 $\mathbf{X}^{(\mathrm{t})}$
for 每个位置 $t=0,\ldots,\ell-1$ 与通道 $m\in\{\mathrm{a},\mathrm{v}\}$ **do**
　　窗内有帧则求均值，无帧则用离窗中点最近的一帧替代，并记录命中帧数
end for
return 各通道的对齐特征、逐位置的命中帧数、每个词元的窗与对应的视频帧区间

算法 1 中间两个判断处理两处退化，收尾把特征与逐位置的命中帧数写入磁盘；保存命中帧数是因为核验对齐质量时以它为凭据，见 4.4 节。整条流程中唯一带随机性的

环节是识别解码：语言固定为英文，解码以温度 0 的贪心搜索起始，只有输出质量判据不过关才升温重采。识别结果与词级时刻已存入 words 目录，复核时直接读取，无需重新运行识别。整套流程在本机 RTX 3080 Ti 上运行，100 条样本共用 683 秒。

两个判断留下的退路同样可核验：走按词数等分那一条，样本的词匹配率记为零；走取最近帧那一条，该位置的命中帧数记为零。两种痕迹都留在汇总表与逐位记录中，事后可查出哪条样本触发了退化处理。100 条样本中，第二种退路一次也未触发，第一种只出现在文本与语音不成套的少数样本上，见 4.4 节。

4.4 问题一求解结果

4.4.1 全量提取的总体结果

100 条全部提取成功，输出特征、模态文件与样本编号三者对应，也没有一条因检不到人脸或配不上词被丢弃。总体统计见表 4-1，逐条明细见附录表 7-1，支撑材料中的 summary.csv 与之相同。

表 4-1　100 条样本的提取结果

统计量	音轨长度/s	词数	有效词元数	语音帧个数	视觉帧个数
极小值	2.228	5	7	218	23
下四分位	4.978	12	17	493.500	51.750
中位数	6.586	18	23	654	67.500
上四分位	8.578	22	30	853	87.250
极大值	29.110	65	50	2906	293
平均值	7.771	19.320	24.470	772.610	78.890
特征维度	—	—	768	45	56
对齐单位	—	—	词元	10 ms	100 ms

表 4-1 中三列帧数均值为语音 772.610、视觉 78.890、有效词元 24.470，三者之比约 41:4:1，与 4.1 节按尺度估计的量级一致。词数一列最小 5、最大 65，长度一列最大 29.110 秒与最小 2.228 秒相差十几倍，可见素材长短分布很宽。触及 50 这一上限的样本有 7 条，余下 93 条未被截断，上限对多数样本不起作用。素材平均帧率每秒 29.4 帧，按 100 毫秒取一帧等于每三帧取一帧。人脸检出率平均 0.898，其中 68 条全程检出，4 条整段为零；词匹配率平均 0.763。整套提取用去 683 秒，单条平均 6.83 秒。四个量的分布见图 4-5。

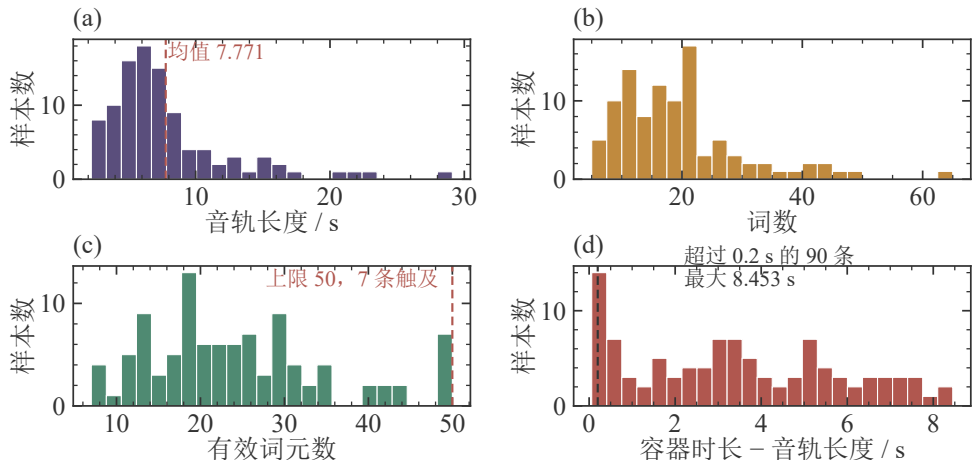


图 4-5　一百条样本的四个分布

图 4-5 四格都取自 summary.csv 的实测值。(a) 为音轨长度，分布右偏，大半样本落在 4 至 9 秒，均值 7.771 秒，最长的两条接近 30 秒。(b) 为词数，峰值在 15 至 25 之间，尾部延伸至 65。(c) 为有效词元数，(d) 为容器时长与音轨长度之差，后者全部为正，90 条超过 0.2 秒，最大 8.453 秒，这正是本文时间轴取音轨而不取容器的实测依据。

判定一条样本提取成功，看三件事：音轨解出且长度不为零，三条通道的帧数均大于零，文本与语音至少能配上一部分词。100 条中音轨最短 2.228 秒，语音帧最少 218 个，视觉帧最少 23 个，都远在零以上；人脸检出率为零的 4 条照样输出特征，只是视觉 56 维全为零，由标志位标出未检出。问题二的缺失与此处的未检出是两回事：前者指某条通道整段没有特征，后者指某一帧未检到人脸。

提取成功并不等于对齐质量高。长度 2.228 秒、词数只有 5 的样本同样能完成提取，只是 50 个位置中真实内容少、填充多；它能否使用要看有效词元数与词匹配率两列，而非是否报错。

4.4.2　对齐质量的核验

附件 1 未提供人工标注的逐词时刻，毫秒量级偏差无从直接度量，因此另取三个可由数据复核的指标：匹配率管内容，覆盖率管时间轴切得是否完整，帧命中数管每个位置是否有真实观测，结果见表 4-2。

表 4-2　对齐质量的核验指标

指标	结果
官方转写包含的词数	1932
识别结果里自带时刻的词数，即词级对齐率	1559，占 80.7%
样本级词匹配率，均值与中位值	0.763，0.944
词元时间窗合计占片段时长的比例，均值与中位值	85.4%，86.2%
有效词元的个数，句首与句尾记号一并计入	2447
词元窗的宽度，中位值与均值	0.300 s，0.370 s
每个窗收进的语音帧数，中位值与最小值	30，1
每个窗收进的视觉帧数，中位值与均值	3，3.740
窗内没有帧、靠最近帧补上的词元数	0
时刻倒退的次数，越出片段边界的次数	0，0
宽度为零的词，按一帧补齐	30

指标	结果

把两个核验指标与帧数画成散点，可见这些指标并不彼此独立，见图 4-6。

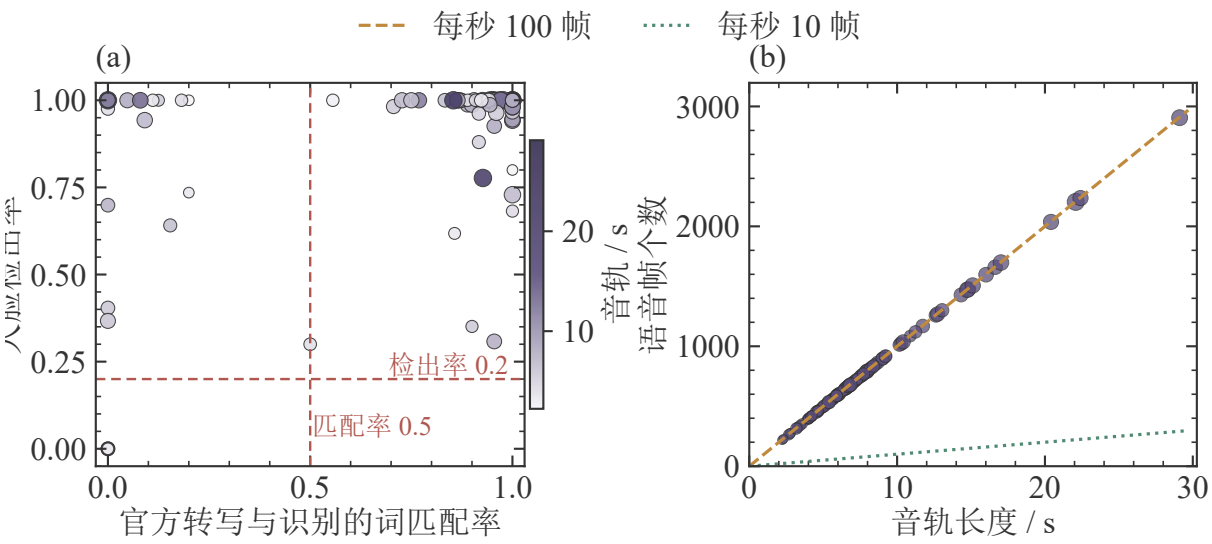


图 4-6　100 条样本的对齐质量

图 4-6(a) 点大多集中在右上角：匹配率一侧 20 条落在 0.5 左侧，检出率一侧只有 4 条落在 0.2 下方，左下角为空，没有一条两项都差，转录对不上的片段画面反而干净。点的大小按有效词元数，右上最大的几颗为长片段，其匹配率普遍更高，可见匹配率低并非内容难对。图 4-6(b) 换一角度自检：横轴为音轨长度，纵轴为语音帧个数，赭黄虚线为每秒一百帧的理论线，各点均贴合该线，说明十毫秒帧移在 100 条上执行一致。绿点线为每秒十帧的位置，视觉帧数离它更远，因为视觉按解码器时间戳抽帧，不按标称帧率反算。

表 4-2 可读出三件事。80.7% 的词由识别直接给出时刻，其余 373 个靠插值补出，其中 283 个集中在转录与语音不对应的那 20 条上，占插值总量的 75.9%，可见插值只是补缺手段，对齐骨架仍由识别给出的实测时刻支撑。2447 个位置上三条通道各有实测值，未出现需要替代的情形，不存在凭空构造的数值。时刻序列单调，也未超出片段范围，任何一位词元都能查到它在素材中对应的时间段。覆盖率均值 85.4%，片段中剩下约一成半时间未被词覆盖，这部分是首尾无人声的静音段，与词窗首尾相接并不冲突。

三个指标的分工不同：词匹配率衡量文本与语音内容是否对应，不看窗宽与特征本身；覆盖率反映素材中人声的疏密，与对齐是否准确没有直接关系；帧命中数说明每个位置的取值来自真实观测。三者都不需要真值，只能互相印证，无法给出毫秒级误差。

典型核验取样本 -3g5yACwYnA$_$13。该素材音轨长 5.399 秒，标注强度 0.667，属正向；15 个词切出 20 个有效词元，语音侧 535 帧，视觉侧 55 帧；全程检出人脸，词匹配率 0.933。对齐结果见图 4-7。

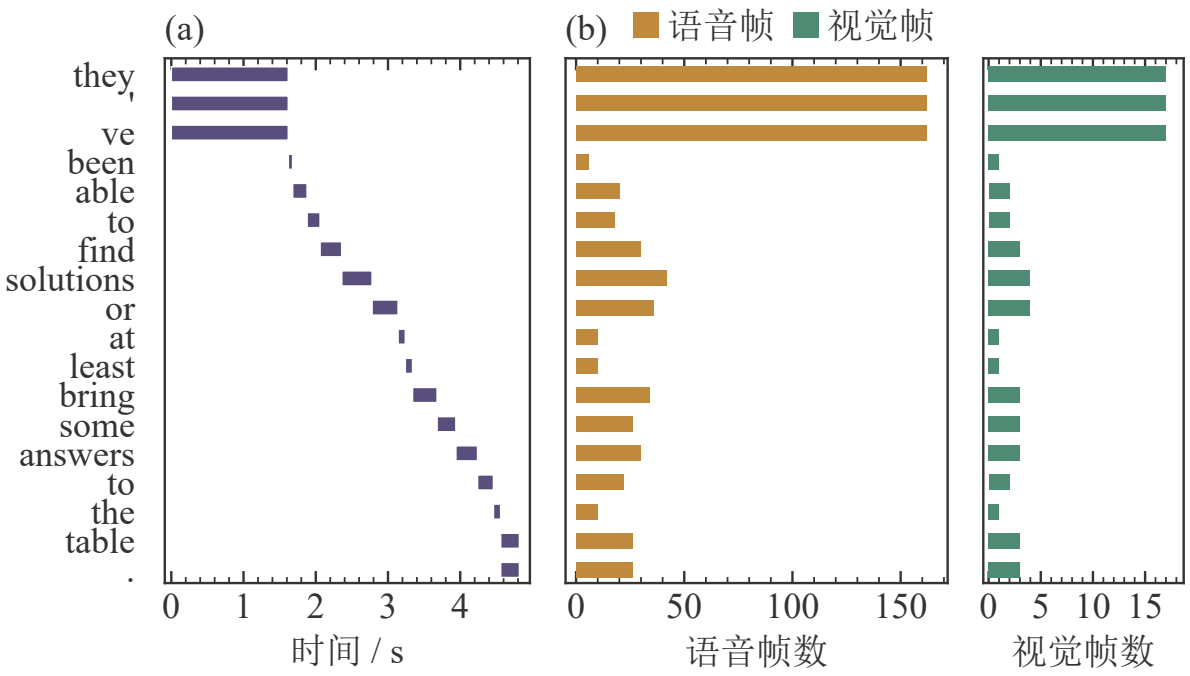


图 4-7　典型样本的词元窗与窗内命中帧数

图 4-7 上下两联共用一根纵轴，纵轴自上而下排着 18 个词元，句首与句尾两个记号未进图。上联横条为各词元的窗，向右依次推进成阶梯，说明时刻只增不减、窗与窗之间没有断口。下联给每个词元配一对竖线，一种颜色为窗内命中的语音帧数，另一种为视觉帧数，线头小点标出高度。两联对照可见窗宽与命中帧数同步：长窗收到数十个语音帧、几个视觉帧，短词的窗内只有个位数帧，该位置同样有实测帧。

逐位置的核验记录列于表 4-3。

表 4-3　典型样本的窗与命中数

位置	词元	所属词	起点/s	终点/s	语音帧	视觉帧	视频帧区间
0	[CLS]	—	0.000	5.399	535	54	0–159
1	they	They’ve	0.000	1.620	162	17	0–48
2	’	They’ve	0.000	1.620	162	17	0–48
3	ve	They’ve	0.000	1.620	162	17	0–48
4	been	been	1.620	1.680	6	1	48–49
5	able	able	1.680	1.880	20	2	49–55
6	to	to	1.880	2.060	18	2	55–61
7	find	find	2.060	2.360	30	3	61–69

表 4-3 印证三处。位置 1 至 3 同属 They’ve，窗与命中帧数完全相同，词元没有拆散词的时间信息。命中帧数随词长增减：位置 4 的 been 只占 60 毫秒，收到 6 个语音帧；位置 1 的 They’ve 长 1.620 秒，收到 162 个；两个数字之比 27 与两段时长之比 27 相等，说明窗越宽收到的帧越多，比例关系稳定。最后一列的视频帧序号区间由窗的秒数乘帧率换算得出，据此可回到原视频中对应的画面，第六章的视觉依据回看正用这一列。另有一处细节：句首记号所在的位置上窗铺满整段，命中的视觉帧却是 54 个而非 55 个，少掉的那一帧时刻在 5.399 秒之外。

4.4.3 数据一致性核查

本问还有 20 条样本的词匹配率不到 0.5，需查明原因：识别不准，或该官方转写与这段语音本来就不成对。若属后一种且只是片段号错位，则在同一个视频标识的其他片段中应能找到与之相配的语音，因此把每份官方转写依次与同视频各片段的识别结果比对，只保留匹配率最高的一次，结果见表 4-4。

表 4-4　转写与音轨的成套核查

核验状态	样本数	判定依据
转写与音轨成套	80	本片段的匹配率在 0.5 以上
转写属于同视频的别的片段	1	本片段匹配率低，换到同视频别的片段能过 0.5
同视频内找不到对应	19	本片段与同视频别的片段都低于 0.5

这 20 条中真正属于片段编号错位的只有 1 条，为 -iRBcNs9oI8$_$3，把它的转录移到片段 8 的语音上比对，相似度升至 0.625；另外 19 条移到同一视频的任意片段上都对不上，可见其转录与音轨原本就不成对。题目要求原样保留内容与标注，这 20 条一条未动，不换文本、不补内容、不删样本；词的起止时刻仍按式 (4-6) 插出，其中连一个词也配不上的，改为把片段时长按词数分摊给各词，匹配率逐条写入汇总表。成套样本占八成，编号错位只占百分之一，剩下近两成是数据本身的配对问题，与本问的处理流程无关。问题二与问题三使用的是附件 2 的标准化特征，不受此影响；第六章回看视觉依据的时间窗由本文从附件 4 算出，其质量另在那一章核查。

4.4.4 输出文件与工具版本

交付的特征文件沿用附件 2 的字段安排，内容见表 4-5。对齐版按 `data['all'][字段名][j]` 取用，第 j 条样本的有效长度等于 `text_bert[j][1]` 之和，有效长度之外一律填零。

表 4-5　问题一交付的文件

文件	内容
q1_aligned_50.pkl	对齐版。各字段的规模如下：id、raw_text、text 为 $100\times50\times768$，text_bert 为 $100\times3\times50$，audio 为 $100\times50\times45$，vision 为 $100\times50\times56$，另有两类标签与各维名称
q1_unaligned.pkl	非对齐版。语音按样本存成帧数乘 45 的矩阵，视觉是帧数乘 56，另记每帧的起始秒与有效帧数
words/*.json	逐条样本一个文件，存官方转写的逐词时刻、识别给出的原始输出、每个词元的窗与窗内命中帧数
summary.csv	逐条样本的汇总，也就是附录表 7-1
mismatch_check.csv	转写与片段语音是否成套的核查记录
env_versions.json，run.log	各工具的版本与关键参数、逐条处理日志

题目对特征文件有三条要求，表 4-5 逐条对应：编号与模态文件一致，由对齐版与汇总表保证；每一位的序号、样本实际长度、不足处如何补零，由 words 目录中逐位记录保证；工具、参数与日志可查，由 env_versions.json 与 run.log 保证。

流程所用工具均为公开发布版本，参数已固化在代码中，运行环境与复现步骤见附录；除识别解码外，其余各步都是确定性的。

以词元为公共刻度、以语音锚点为基准、以覆盖与内容两层指标核验，是本问交付的三样东西，每个位置都因此对应到素材中的一段真实时间。100 条样本一条未丢，词级对齐率 80.7%，2447 个有效词元中每个窗都收进了实测的语音帧与视觉帧；时刻既单调又不出界，人脸检出率 0.898；文本表示与附件 2 的对应字段逐元素吻合。语音与视觉特征另提一套，维数不同于附件 2，问题二以附件 2 的标准化特征作主干、以本问结果作对照。第六章要借助这里的对应关系，把模型指出的位置还原为原视频中的具体时刻。由于没有真值，验收只能依靠间接指标，时间戳的毫秒级偏差无法给出。

5 问题二的模型建立与求解

5.1 问题二分析

本章依次做缺失标注、双视图前向与四项损失反传，再做集成与选型、网格评测，附件 2 与附件 3 的预测接在后两步。双视图前向承担主要计算量，同一批样本要进网络两次。全章先查明附件 3 的缺失形态，再把处理缺失的各部件组成网络，最后交代训练、选型与评测的口径。

附件 3 的缺失落在特征矩阵的若干连续位置上，整行取零，边界由样本自身确定。对 30 条样本在有效长度内的缺失逐位置统计，结果列于表 5-1。

表 5-1　附件 3 的缺失形态

统计项	取值
有缺失的样本条数	27 / 30
三条通道一起失效的条数	29 / 30
一条样本里的缺失段数	1 到 9
每段缺失的长度	1 到 4 个位置
文本、语音与视觉的缺失比例均值	0.186，0.186，0.190
带缺失样本的比例跨度	0.061 到 0.462

表 5-1 的几条事实决定部件配置。缺失呈多段短区间，最多 9 段，最长一段只占 4 个位置，不到全部位置的一成，按单条长缺口设计补全并不适用。30 条中有 29 条三通道缺失位置完全重合，说明失效在同一时刻发生，通道之间因此可以互相提供信息。文本缺失留下的是被替换为未登录记号的词元，判定规则与另外两条通道不同，须按式 (1-4) 分开处理。缺失比例均值不到两成，两端比值却超过七倍，模型不能只按固定缺失强度设计。

附件 3 是人为制造的缺口，附件 2 里还另有一批本来就带缺失的样本，两处的性质不同，见图 5-1。

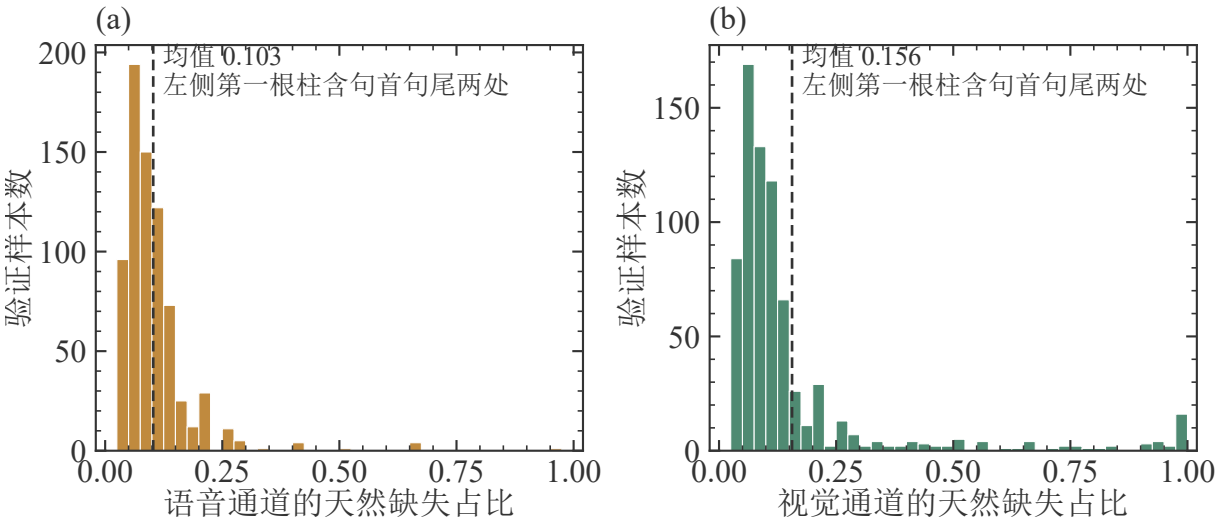


图 5-1　附件 2 的天然缺失占比

图 5-1 两格统计验证集 728 条上语音与视觉在有效位置内的整行零，扣掉句首句尾两处记号后除以有效长度。两条分布都集中在低值一端，语音均值 0.103，视觉 0.156，但均呈长尾，视觉一路有 20 余条超过 0.5。缺失并非只在附件 3 出现，附件 2 自身就带着可观的自然缺失，训练阶段按式 (1-4) 一并标注，模型见到的缺失才与推理时一致。

缺失的位置分布与逐条缺失比例见图 5-2。

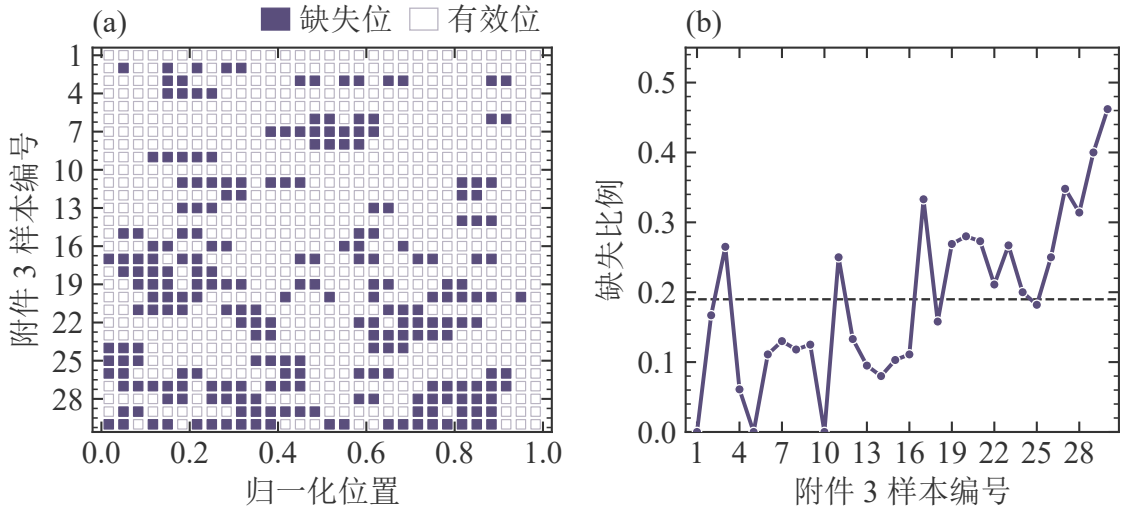


图 5-2　附件 3 有缺失样本的缺口分布

图 5-2(a) 中每条样本的三根横条几乎重合，每片都短，与表 5-1 的统计一致。图 5-2(b) 的竖棒加圆点给出逐条缺失比例，取三通道中的最大值，多数样本的柱高在 0.2 以下，最高的三条接近 0.46。有效长度最短的两条是样本 01 与样本 05，仅 8 与 14，可用信息少时判断最易随种子波动。

三类位置在矩阵中的分布见图 5-3。

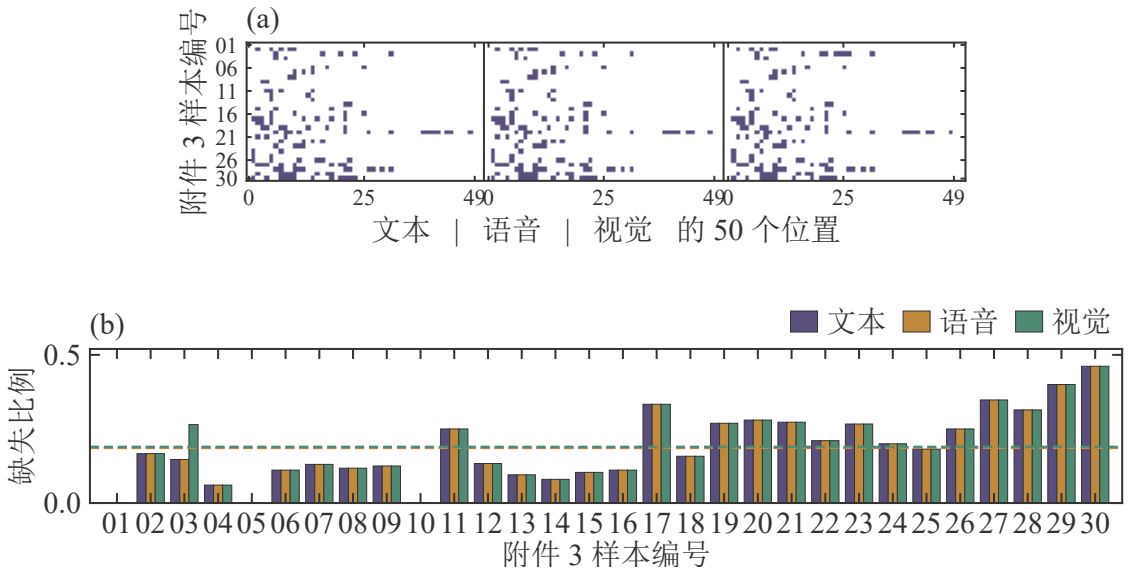


图 5-3　附件 3 的缺失矩阵与逐条缺失比例

图 5-3(a) 一行一条样本，三段各 50 个位置，深色格为人工缺口，白格可用，浅灰格落在有效长度之外。灰段只出现在每行右端，长短随样本而异，是补长度的定长填充；三路深色格几乎落在同一批列上，30 条中 26 条同步，缺口最长只 4 个位置。图 5-3(b) 的虚线为三通道缺失比例均值 0.186、0.186、0.190，只有样本 03 的视觉那根明显偏高，缺失成片出现，并非各通道独立。三类位置必须分开：定长填充要被屏蔽，自带零行与人为缺口都按式 (1-4) 算作缺失，重建损失只作用于人工缺口。混同处理会使式 (1-5) 算出的缺失比例整体偏大，掩蔽增广随之失去意义。

文本缺失须在词元一级处理，不能只改特征向量。附件 2 的文本特征是冻结语言模型给出的隐状态，同一位置的向量由整句词元经自注意力共同算出，清零该处并不能消除词义，句首两个特殊记号仍会把被删词的语义带入后续表示。早期评测按清零做法进行，查出属于评测泄漏后该批数字全部作废，改用未登录记号替换并整句重编。与开源方法对照的口径统一为按替换后的词元重算文本表示，凡以冻结文本特征为输入的方法都照此办理，避免原文残留带来不当增益。代价有二：重编码须多执行一次语言模型前向，训练与推理变慢；被替换位置本身没有信息，只能由上下文推断，本节后续用重建与一致性两项约束补偿。

缺失对预测的损害经三条路径传导，分清路径才能确定可控程度。信息路径指缺失位置原有的判别信息已经丢失，无法挽回，只能由上下文补充。表示路径出在零值：编码器把零值当作合法输入，隐空间中多出一个位置表示，注意力随之被引偏，显式标出缺失即可消除。权重路径指融合时仍对已失效的通道分配分量，误差因此被放大，可由池化与融合只统计可用位置减轻。本文的处理是消除后两条路径，再用重建与一致性两项约束补偿第一条。

5.2　问题二数学模型

本节把路径分析落实为网络结构，模型记为**缺失感知融合网络**。各层按数据处理先后排列：文本先回到词元一级重编，三条通道各自投影、替换缺失处取值并做通道内编码，三路拼接后做跨通道交互，再按可用位置池化并融合，最后经两个输出头给出结果。训练时另加一层增广，把自带缺失与人工缺失混合训练，记为**两级掩蔽增广**。三个做法分居链首、链尾与汇聚处，分别对上一条的三条路径。三者并非各自独立，缺失词元同时标出不可信位置并给出一致表示，须与重建损失配合才能把损失降到最低。

5.2.1 文本缺失的词元级处理

文本通道的缺失须在进入网络之前处理。记第 t 个位置的词元编号为 b_t，缺失标志 $M_t^{(\mathrm{t})}$ 按式 (1-4) 给出，送进编码器的词元序列与文本特征写成

$$\tilde{b}_t = \begin{cases} \mathrm{id}_{\mathrm{unk}}, & M_t^{(\mathrm{t})} = 1, \\ b_t, & M_t^{(\mathrm{t})} = 0, \end{cases} \qquad \mathbf{X}^{(\mathrm{t})} = \mathrm{BERT}_{\mathbf{W}_0 + \Delta\boldsymbol{\Omega}}\left(\tilde{\mathbf{b}}, \boldsymbol{\nu}\right), \tag{5-1}$$

式中 $\mathrm{id}_{\mathrm{unk}}$ 是未登录记号的编号，$\boldsymbol{\nu}$ 是式 (1-3) 给出的有效位置标志，用于把定长填充排除在注意力之外，$\mathbf{W}_0$ 是预训练权重，$\Delta\boldsymbol{\Omega} = \mathbf{W}_{\mathrm{up}}\mathbf{W}_{\mathrm{down}}$ 是只接在注意力查询投影与值投影上的低秩增量，秩取 8，缩放取 16。

该编码器既不整体微调，也不完全冻结。整体微调需要更新一亿多个参数，而训练集只有 3395 条，更新方向容易被少量极端样本主导；完全冻结又使文本表示停留在通用语义，偏离情感判别任务。折中做法是照 LoRA [13] 的思路，在十二层注意力的查询投影与值投影上各加一对低秩矩阵，可训练参数合计 294 912 个，约占编码器规模的千分之三，文本表示因此向任务靠近一步，预训练语义又不受破坏。低秩增量的学习率与其余超参数一并见 5.3 节。

5.2.2 缺失处换词元与通道内编码

三条通道先各自投影到公共维度，取 $d_{\mathrm{h}} = 128$

$$\mathbf{U}^{(u)} = \mathrm{LN}\left(\mathbf{G}^{(u)}\right)\mathbf{W}_{\mathrm{in}}^{(u)} + \mathbf{b}_{\mathrm{in}}^{(u)} \in \mathbb{R}^{N_p \times d_{\mathrm{h}}}, \tag{5-2}$$

投影之前先做层归一化，使三条通道量级一致，之后才可比较。落在缺失位置上的那部分投影不可信，整体替换为该通道学出的向量

$$\tilde{\mathbf{U}}_{t,:}^{(u)} = \chi_t^{(u)}\,\boldsymbol{\xi}^{(u)} + \left(1 - \chi_t^{(u)}\right)\mathbf{U}_{t,:}^{(u)}. \tag{5-3}$$

此处无内容与取值恰为零因此成为两种不同的记号：前者是可训练的专属向量，后者仍是普通零向量，注意力可以区分。替换之后叠加位置编码与通道编码

$$\mathbf{H}^{(m),0} = \tilde{\mathbf{U}}^{(u)} + \mathbf{E}_p + \mathbf{E}_u, \tag{5-4}$$

式中 $\mathbf{E}_p \in \mathbb{R}^{N_p \times d_{\mathrm{h}}}$ 为可学习的位置编码，$\mathbf{E}_u \in \mathbb{R}^{d_{\mathrm{h}}}$ 为通道编码，加上这两项，三条序列即使拼接也仍保留各自的来源与先后。此后每条通道各经一层自注意力编码器 [14]，屏蔽掉填充位置

$$\mathbf{S}^{(u)} = \mathrm{Enc}_{\mathrm{intra}}^{(u)}\left(\mathbf{H}^{(m),0};\ \mathrm{mask} = \neg\boldsymbol{\nu}\right). \tag{5-5}$$

通道内只设一层，样本有效长度多在几十个位置以内，一层自注意力足以混合邻近位置的信息。缺失位置在这一层不进入屏蔽名单，因为它携带的缺失词元正是后续判断可用程度的依据。

5.2.3 跨通道交互与按可用位置池化

三条序列沿位置维首尾接起来，长度变成 $3N_p$，再送进两层自注意力编码器，任何一个位置都能看到其余两条通道上的所有位置

$$\left[\mathbf{Z}^{(\mathrm{t})};\mathbf{Z}^{(\mathrm{a})};\mathbf{Z}^{(\mathrm{v})}\right] = \mathrm{Enc}_{\mathrm{cross}}\left(\left[\mathbf{H}^{(\mathrm{t})};\mathbf{H}^{(\mathrm{a})};\mathbf{H}^{(\mathrm{v})}\right];\ \mathrm{mask} = \neg\left[\boldsymbol{\nu};\boldsymbol{\nu};\boldsymbol{\nu}\right]\right). \tag{5-6}$$

通道内一层加跨通道两层，合计三层注意力，即表 5-2 中编码器规模的全部。跨通道比通道内多一层，因为某条通道缺失一段后所需信息只能取自另外两条通道，这种取用须跨过序列边界。

池化层为每条通道各配一个注意力头，将序列汇总为一个向量。可用位置记为 $\vartheta_t^{(u)} = \nu_t \wedge \neg\chi_t^{(u)}$，即位置既要在有效长度内，又不能带缺失标志，打分函数与归一化系数取

$$e_t^{(u)} = \mathbf{w}_2^{(m)\top} \tanh\left(\mathbf{W}_1^{(u)} \mathbf{C}_{t,:}^{(u)}\right), \qquad \sigma_t^{(u)} = \frac{\vartheta_t^{(u)} \exp\left(e_t^{(u)}\right)}{\sum_{t'} \vartheta_{t'}^{(u)} \exp\left(e_{t'}^{(u)}\right)}, \tag{5-7}$$

池化向量记作 $\mathbf{y}^{(u)} = \sum_t \sigma_t^{(u)} \mathbf{C}_{t,:}^{(u)}$。乘上指示变量即把缺失位置的权重置零，汇聚范围只剩可用位置。平均池化没有这一约束，缺失越多，池化结果偏离越大。

记可用位置集合 $\mathcal{A}_m = \left\{t : \vartheta_t^{(u)} = 1\right\}$，该权重是对非负量 $\exp(e_t^{(u)})$ 在 $\mathcal{A}_m$ 上的归一化，分子与分母同为正，集合非空时 $\sum_t \sigma_t^{(u)} = 1$ 恒成立。若整条通道没有可用位置，分子分母同时为零，式 (5-7) 无定义，此时改在有效位置集合 $\mathcal{V} = \{t : \nu_t = 1\}$ 上归一化。$\mathcal{V}$ 非空，$\sum_{t\in\mathcal{V}} \exp(e_t^{(u)}) \geq |\mathcal{V}| \min_t \exp(e_t^{(u)}) > 0$，分母不为零，退化后的权重同样非负且求和为 1。整条通道全缺由掩蔽增广造出，这一处理保证它不会使损失变为非数。

5.2.4 通道分量融合与两个输出头

融合有两个候选。第一个候选是学习式门控，其权重由三条通道的池化向量与三条缺失比例拼接后经线性映射与 softmax 得到

$$\mathbf{w} = \operatorname{softmax}\left(\mathbf{W}_g \left[\mathbf{y}^{(\mathrm{t})}; \mathbf{y}^{(\mathrm{a})}; \mathbf{y}^{(\mathrm{v})}; \beta_{\mathrm{t}}; \beta_{\mathrm{a}}; \beta_{\mathrm{v}}\right] + \mathbf{b}_g\right), \tag{5-8}$$

缺失比例进入门控输入，权重才可能随可用程度变化，无须从池化向量的起伏中推断。第二个候选是平均融合，三条通道各占三分之一。无论选哪一种，融合表示均写成

$$\mathbf{z} = \sum_m w_u \, \mathbf{y}^{(u)}. \tag{5-9}$$

门控更灵活，但多出的参数须在 3395 条样本上训练，能否换回收益不确定；平均融合不增加参数，也不会因通道失效而调整分量。两个候选都训练，由验证集裁定，准则见 5.3 节。

融合表示之后接两个输出头，分别给出强度回归与极性分类

$$\hat{o} = \mathbf{w}_r^{\top} \mathrm{MLP}_r(\mathbf{z}), \qquad \hat{\mathbf{k}} = \operatorname{softmax}\left(\mathrm{MLP}_c(\mathbf{z})\right). \tag{5-10}$$

强度这一路还可以换一种参数化。把 $[-3, 3]$ 按步长 $\Delta = 0.5$ 等分出 13 个边界点 $e_0, \ldots, e_{12}$，网络不再直接给出标量，而是给出强度越过每个边界的累积概率

$$p_k = \sigma\left(\mathbf{w}_k^{\top}\mathbf{z} + b_k\right), \qquad k = 0, \ldots, 11, \tag{5-11}$$

其中 $\mathbf{z}$ 是式 (5-9) 给出的融合表示。标注 y 先落到格 $\beta = \operatorname{clip}\left(\operatorname{round}\left((y - e_0)/\Delta\right), 0, 12\right)$，第 k 个边界的训练目标取 $\mathbb{I}[\beta > k]$，损失为这 12 个累积量与目标的二元交叉熵。预测时按累积概率的期望解码

$$\hat{y} = e_0 + \Delta \sum_{k=0}^{11} p_k. \tag{5-12}$$

在等距网格上这一式恰好还原连续强度的期望，输出仍是 $[-3, 3]$ 内的连续值，平均绝对误差这一口径不必改动。这个版本与直接回归版本的对照见 5.4.5 节。

极性由分类头独立给出，不由强度 $\hat{o}$ 的正负号推断。中性类需要独立的判别边界，用正负号无法划出；强度接近零的样本上，由符号推得的极性与分类头也容易互相矛盾。单模态辅助支路为每条通道的池化向量各接一个强度头 $\hat{o}_u = \mathbf{w}_m^{\top}\mathbf{y}^{(u)}$，这要求每条通道单独也可判别，否则融合把分量集中到一条通道后，其余两路失去学习动力。跨通道输出另接一个重建头 $\hat{\mathbf{G}}^{(u)} = \mathbf{C}^{(u)}\mathbf{W}_{\mathrm{rec}}^{(u)}$，仅服务于重建损失。

5.2.5　两级掩蔽增广与四项损失

每个训练批次都造出两个视图。掩蔽视图先施加连续区段掩蔽：各通道以概率 $p_{\mathrm{mod}} = 0.5$ 独立决定是否选中，被选中的通道在有效区间内任取一个起点，从该点起连续掩蔽一段，长度按有效长度的 0.1 到 0.7 均匀抽取。再叠加一层整模态丢弃，以概率 $p_{\mathrm{drop}} = 0.2$ 将一条通道整段置空。文本侧凡被掩蔽的位置，词元一律改写为未登录记号后重编，口径与式 (5-1) 相同。两层合称**两级掩蔽增广**，人工掩蔽的位置集合记为 $\mathcal{M}_{\mathrm{art}}^{(u)}$。区段掩蔽产生与附件 3 同形的多段短缺口，整模态丢弃产生附件 3 没有而融合最易受损的极端情形。

四项损失的定义如下。主任务损失把强度误差与极性交叉熵合起来

$$\mathscr{L}_{\mathrm{task}} = |\hat{o} - y| + \lambda_c \,\mathrm{CE}\left(\hat{\mathbf{k}}, c\right), \tag{5-13}$$

辅助损失里只有该通道还留着可用位置的那一份才计入

$$\mathscr{L}_{\mathrm{uni}} = \frac{1}{3} \sum_{m} \mathbb{I}\left[\textstyle\sum_t \vartheta_t^{(u)} > 0\right] |\hat{o}_u - y|, \tag{5-14}$$

指示函数把全缺的通道排除在外，否则该通道的强度头没有任何输入，却仍被要求给出准确回归，梯度只会把它拉向标注均值。重建损失只作用在人工掩蔽的位置上，目标是恢复这些位置的原始特征

$$\mathscr{L}_{\mathrm{rec}} = \frac{1}{|\mathcal{Q}|} \sum_{m \in \mathcal{Q}} \frac{1}{\left|\mathcal{M}_{\mathrm{art}}^{(u)}\right|} \sum_{t \in \mathcal{M}_{\mathrm{art}}^{(u)}} \left\| \hat{\mathbf{G}}_{t,:}^{(u)} - \mathbf{G}_{t,:}^{(u)} \right\|_2^2, \tag{5-15}$$

式中 $\mathcal{Q}$ 为本批次真正被置空的通道，两条同时被置空时先按通道求平均再按批次求平均，避免缺失多的样本放大损失。一致性损失度量掩蔽视图与完整视图融合表示之间的距离

$$\mathscr{L}_{\mathrm{con}} = \left\| \tilde{\mathbf{z}} - \mathrm{sg}\left(\mathbf{z}\right) \right\|_2^2, \tag{5-16}$$

其中 sg 表示梯度截断。该项只将掩蔽视图拉近完整视图，完整视图不受影响：sg 的雅可比矩阵 $\mathbf{J}_{\mathrm{sg}} = \partial\,\mathrm{sg}(\mathbf{z})/\partial \mathbf{z}$ 每一处都取零，求导时相当于一个不含 $\mathbf{z}$ 的常数向量，由链式法则 $\partial \mathscr{L}_{\mathrm{con}}/\partial \mathbf{z} = 2\left(\tilde{\mathbf{z}} - \mathrm{sg}(\mathbf{z})\right)^{\top} \mathbf{J}_{\mathrm{sg}} = \mathbf{0}$。完整视图一侧只有主任务损失与辅助损失两条梯度路径，两项损失因此可按视图分别更新；$\mathscr{L}_{\mathrm{con}}$ 对 $\tilde{\mathbf{z}}$ 的梯度为 $2(\tilde{\mathbf{z}} - \mathbf{z})$，方向单一。

四项损失按视图分成两组，优化目标即式 (5-17)

$$\mathscr{L} = \underbrace{\mathscr{L}_{\mathrm{task}} + \lambda_u \mathscr{L}_{\mathrm{uni}}}_{\text{完整视图}} + \underbrace{\tilde{\mathscr{L}}_{\mathrm{task}} + \lambda_u \tilde{\mathscr{L}}_{\mathrm{uni}} + \lambda_r \mathscr{L}_{\mathrm{rec}} + \lambda_n \mathscr{L}_{\mathrm{con}}}_{\text{掩蔽视图}}. \tag{5-17}$$

两组损失的权重并不相等，掩蔽视图一侧多出重建与一致性两项，这是有意的取舍。完整视图保证信息齐全时的精度，掩蔽视图使其在缺失条件下保持精度；两侧任务损失权重相同，可比性才成立。

5.2.6 模型的完整形式

把上面各步合到一起，**缺失感知融合网络**写成

$$
\begin{cases}
\mathbf{X}^{(\mathrm{t})} = \mathrm{BERT}_{\mathbf{W}_0+\Delta\mathbf{\Omega}}\left(\tilde{\mathbf{b}}, \boldsymbol{\nu}\right), \quad \tilde{b}_t = \mathrm{id}_{\mathrm{unk}} \text{ 当 } M_t^{(\mathrm{t})} = 1 & \text{词元替换后重编} \\
\tilde{\mathbf{U}}_{t,:}^{(u)} = \chi_t^{(u)} \boldsymbol{\xi}^{(u)} + \left(1 - \chi_t^{(u)}\right)\left(\mathrm{LN}\left(\mathbf{G}^{(u)}\right)\mathbf{W}_{\mathrm{in}}^{(u)}\right)_{t,:} & \text{缺失处换词元} \\
\mathbf{S}^{(u)} = \mathrm{Enc}_{\mathrm{intra}}^{(u)}\left(\tilde{\mathbf{U}}^{(u)} + \mathbf{E}_p + \mathbf{E}_u\right) & \text{通道内一层} \\
\left[\mathbf{Z}^{(\mathrm{t})}; \mathbf{Z}^{(\mathrm{a})}; \mathbf{Z}^{(\mathrm{v})}\right] = \mathrm{Enc}_{\mathrm{cross}}\left(\left[\mathbf{H}^{(\mathrm{t})}; \mathbf{H}^{(\mathrm{a})}; \mathbf{H}^{(\mathrm{v})}\right]\right) & \text{通道间两层} \\
\mathbf{y}^{(u)} = \sum_t \sigma_t^{(u)} \mathbf{C}_{t,:}^{(u)}, \quad \sigma^{(u)} \text{ 权重只落在可用位置} & \text{按可用位置池化} \\
\mathbf{z} = \sum_m w_u \mathbf{y}^{(u)}, \quad w_u \text{ 取式 (5-8) 或者1/3, 由验证集裁定} & \text{分量融合} \\
\hat{o} = \mathbf{w}_r^{\top}\mathrm{MLP}_r(\mathbf{z}), \quad \hat{\mathbf{k}} = \mathrm{softmax}\left(\mathrm{MLP}_c(\mathbf{z})\right) & \text{强度与极性两头} \\
\min \ \mathscr{L} = \mathscr{L}_{\mathrm{task}} + \lambda_u \mathscr{L}_{\mathrm{uni}} + \tilde{\mathscr{L}}_{\mathrm{task}} + \lambda_u \tilde{\mathscr{L}}_{\mathrm{uni}} + \lambda_r \mathscr{L}_{\mathrm{rec}} + \lambda_n \mathscr{L}_{\mathrm{con}} & \text{总的优化问题}
\end{cases}
\tag{5-18}
$$

式 (5-18) 自上而下八行对应模型的八个环节，前三行处理数据本身缺失的部分，后五行处理缺失进入网络后的传导。其中的 $\mathbf{E}_p$、$\mathbf{E}_u$、$\vartheta_t^{(u)}$ 与各权重矩阵均为可训练参数，形状与含义列于表 3-1。

5.3 问题二模型求解

5.3.1 训练流程与关键参数

训练方法与所用参数汇总于表 5-2，完整步骤见算法 2。两点需说明：同一批数据前向两次，分别经过完整视图与掩蔽视图，四项损失在一次反传中一并更新；验证集只参与早停判断与打分，不参与梯度计算。

表 5-2　问题二的训练超参数

超参数	取值	超参数	取值
隐层宽度 d	128	注意力头个数	4
模态内编码的层数	1	跨模态交互的层数	2
Dropout 比例	0.2	批次大小	64
融合网络的优化器	AdamW [15]，学习率 5×10^{-4}，权重衰减 0.01	低秩增量的学习率	2×10^{-4}
低秩增量的秩与缩放	8，16	学习率调度方式	余弦退火
最大训练轮数	40	早停的耐心轮数	12 轮
λ_c，λ_u	0.5，0.2	λ_r，λ_n	0.5，0.5
区段掩蔽概率 p_{mod}	0.5	掩蔽区段的长度占比	0.1 到 0.7 均匀抽取
整模态被丢掉的概率	0.2	随机种子	42，43，44

表 5-2 的编码器规模取得较小：隐层 128 维，通道内一层、跨通道两层注意力，因为训练样本只有 3395 条，参数再多无法充分训练。文本侧可训练参数仅为低秩增量，学习率 2×10^{-4}，不到融合网络 5×10^{-4} 的一半，以免有限样本使文本表示偏离预训练语义。批次取 64，最多训练 40 轮，验证集得分连续 12 轮不降则停止；早停耐心给得较宽，因

为四项损失一并反传时曲线中段会出现小平台，耐心不足会停在尚未收敛的位置。梯度范数裁到 1.0，防止某一批把权重推得过大。两个融合候选均需训练，随机种子 42、43、44 各训练一次，报告值取三种子的平均，单次训练不足以分辨细微差别，种子波动的量级见 5.4 节，训练步骤见算法 2。

算法 2　缺失感知融合网络的训练

输入： 训练数据 $\mathcal{D}$，验证数据 $\mathcal{V}$，权重 $\lambda_c, \lambda_u, \lambda_r, \lambda_n$，掩蔽概率 $p_{\mathrm{mod}}, p_{\mathrm{drop}}$，种子集合 $\mathcal{R}$

输出： 入选的融合方式下三个种子的权重

```
按式 (1-6) 与式 (1-4) 分别做标准化与缺失标注
for 融合方式 g 取学习式门控或者平均融合，种子 r ∈ R do
    初始化网络，在注意力的查询与值投影两处加低秩矩阵
    for 每一轮训练 do
        取一个批次，按式 (5-1) 重编文本后前向完整视图
        同一批次先掩蔽连续区段，再按 p_drop 丢弃一条整通道，文本重编后送入掩蔽视图
        按式 (5-17) 将四项损失一并反传，梯度范数裁到 1.0
        在验证集上按式 (5-19) 打分，分数下降即保存参数，连续 12 轮不降则停止
    end for
end for
同一种融合方式先把三个种子的分数取平均，均分低者入选
return 入选方式下三个种子的权重，最终模型由三者平均得到
```

5.3.2　评测口径与选型准则

对照与选型分开进行，掩码按 EMT-DLFR [16] 与 MMSA [17] 两个仓库的做法生成：每条通道以概率 r 丢弃自身的可用位置，文本换为未登录记号，首尾两个特殊记号不动，语音与视觉的缺失位置置零。全部方法共用同一批掩码，生成一次后不再改动，差异只来自模型本身。测试集每档缺失率取三套掩码的平均，选型一侧只用两套，少用一套是为控制反复训练的开销。

选型只看验证集，测试集留到选完之后报告一次。事先定下的评分准则为

$$S = \mathrm{MAE}_{r=0} + \frac{1}{3}\left(\mathrm{MAE}_{r=0.2} + \mathrm{MAE}_{r=0.4} + \mathrm{MAE}_{r=0.6}\right), \tag{5-19}$$

第一项为完整输入下的误差，后三项为三个缺失率下的平均误差，完整输入占四分之一，缺失三档占四分之三，该加权使选型偏向本问关注的缺失条件，代价是完整输入一侧的余量被压缩。两个候选各换三个随机种子训练，同一种子按式 (5-19) 计算得分后对种子取平均，均分低者入选，最终模型取入选版本三种子的平均权重。准则只用平均绝对误差，不含分类指标，因为极性指标会随阈值附近样本的微小移动而变化，纳入后会引入随机性。整个流程在验证集上完成，测试集不参与任何一次比较，与第 1 章的数据使用规则一致。

5.4　问题二求解结果

本节先给模型选择的结论，再逐档对比各方案并分析缺失的影响方式，随后用消融与灵敏度确认各部件作用和超参数余量，最后交付附件 3 的推理结果。除另作说明外，测试集数字取三种子均值或集成。

5.4.1 模型选择

门控融合比平均融合多出一套由缺失比例驱动的权重，形式上更灵活，但在 3395 条训练样本上能否换回收益并不确定，仍由验证集裁定。两个候选各训三个随机种子，按式 (5-19) 算验证集综合得分，结果列于表 5-3。

表 5-3　两种融合候选的选型得分

候选版本	验证集综合得分均值	标准差	入选
学习式门控融合	1.232	0.000	否
平均融合	**1.229**	0.015	是

两组得分的均值分别为 1.232 与 1.229，对应学习式门控与平均融合，标准差 0.000 与 0.015。两者均值差仅 0.003，不到平均融合自身种子波动的五分之一，按准则取均值较小的一侧，入选的是平均融合。仅更换一组随机种子，验证集得分的变动就会超过门控带来的收益，门控无法给出可分辨的改进。门控一组的三个种子得分几乎重合，其结果由结构决定，与初始化无关，但并未压低均值。门控的额外权重换不到实测收益，最终模型取平均融合三个种子的平均。

Self-MM [18] 按同一准则在验证集上得到 1.197，比本文入选版本低 0.032，是全部对照中唯一低于本文的方法。该优势集中在完整输入一侧，该列它 0.610，本文单模型 0.625；缺失一侧相反，从缺失 20% 起本文单模型的误差持续低于它，见表 5-6。本问交付的是通道失效时的稳定性，本文在该侧余量更足，因此 1.197 不构成改选的理由。

入选模型在验证集 728 条样本上逐条预测与标注的对照见图 5-4。

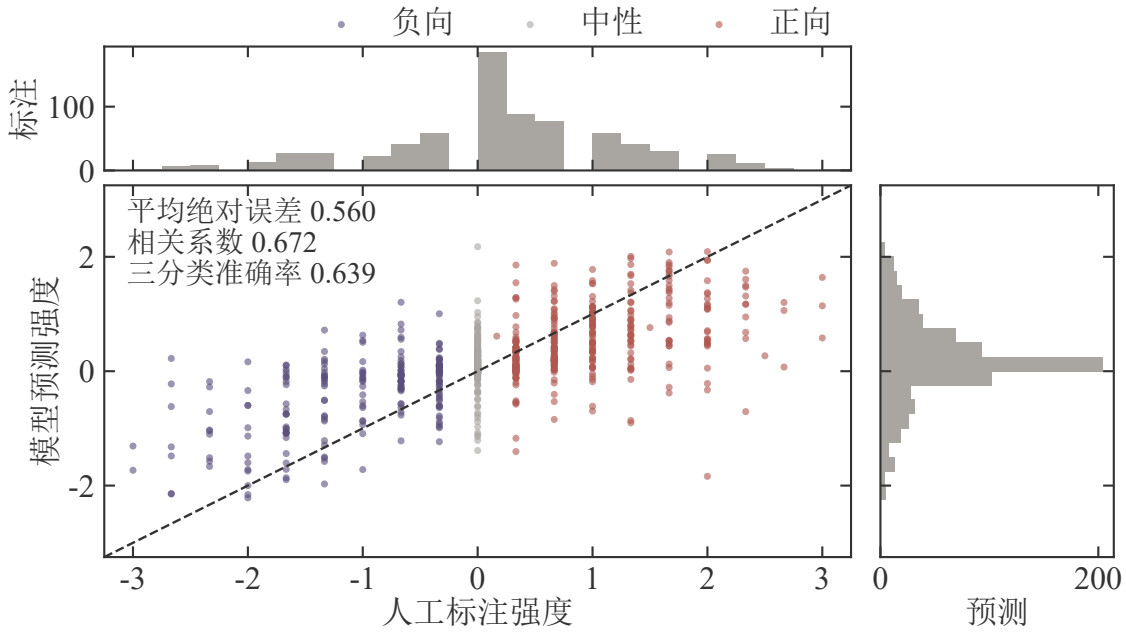


图 5-4　验证集逐条预测与标注的对照

图 5-4 以人工标注为横轴、模型预测为纵轴，虚线为对角线。散点集中在对角线靠中间的一段，标注在 ±3 附近的点几乎全部被拉回 ±2 以内，即后文将说明的朝均值收缩。两条边缘直方图显示，上方标注的分布两端较厚，右侧预测的更陡、尾部更短；标注在零处密度最高，模型预测在同一处分布更宽。这一差异是三分类中中性类最难判别的直接原因。

5.4.2　与开源方法的对比

三条通道各自的信息贡献可在同一框架内度量。表 5-4 的八种方案共用附件 2 的同一划分，报告值为三种子均值，其中三种为单模态、三种为朴素融合，另两种为跨模态注意力方案与本文模型。

表 5-4　八种方案的测试集表现

方案	参数量	完整输入误差	相关系数	二分类准确率	仅文本全缺误差	三模态缺 50%	命中最优比例
文本单模态	100,484	0.658	0.650	0.836	0.885	0.678	0.000
语音单模态	10,264	0.868	0.217	0.658	0.864	0.865	0.000
视觉单模态	5,194	0.852	0.241	0.650	0.848	0.849	0.000
早期拼接融合	131,166	0.653	0.652	0.835	0.853	0.704	0.000
晚期等权融合	114,910	0.670	0.645	0.823	0.860	0.688	0.000
双向 LSTM 融合	462,174	0.652	0.653	0.823	0.870	0.692	0.000
跨模态注意力	1,359,956	0.627	0.671	0.835	0.853	0.671	0.667
本文模型	1,359,956	**0.636**	0.670	0.832	0.863	**0.670**	0.333

单模态一组中，文本通道的平均绝对误差 0.658，与标注的相关系数 0.650，二分类准确率 0.836；语音通道依次为 0.868、0.217 与 0.658，视觉通道为 0.852、0.241 与 0.650，后两条的相关系数均不到文本的一半，判别信息主要来自语义。朴素融合一组中，早期拼接 0.653、双向 LSTM 融合 0.652，均略优于文本单模态；晚期等权融合 0.670 反而更差，原因是它给两条弱通道与文本同等的分量，弱通道噪声因此进入融合表示。

跨模态注意力方案的完整输入误差 0.627，为全表该列最低。本文模型与它参数量相同，均为 1,359,956，区别只在缺失位置的处置方式。本文完整输入 0.636 比它高 0.009，仅文本全缺 0.863 比它的 0.853 高 0.010，多条通道同时失效的档位上本文以 0.670 低 0.001。命中最优比例一列差异更明显：它在三分之二的档位误差最低，本文为三分之一。该设计换回的不是完整输入下的精度，而是通道大面积失效时的损失减小。

参数量两列还说明一点。单模态方案中参数最少的是视觉通道，仅 5,194 个，文本通道为 100,484 个，两者误差 0.852 与 0.658 相差 0.194；朴素的早期拼接仅用 131,166 个参数即达到 0.653，双向 LSTM 融合用到 462,174 个才达到 0.652。规模在本问中不是决定性因素，关键在于表示的组织方式与缺失的处置方式。

表 5-5　完整输入下的测试集对照

方法	平均绝对误差	相关系数	二分类准确率
TFN	0.677	0.613	0.817
LF-DNN	0.678	0.604	0.812
MISA	0.645	0.699	0.847
Self-MM	**0.610**	0.697	0.848
EMT-DLFR	0.615	—	—
本文单模型三种子均值	0.625	0.680	0.847
本文三种子集成	**0.602**	**0.697**	**0.866**

完整输入条件下与开源方法的对照见表 5-5。张量融合 TFN [19] 0.677，LF-DNN [20] 0.678，MISA [21] 0.645，Self-MM 0.610 居首，EMT-DLFR [16] 0.615 次之，本文单模型的三种子均值 0.625 位列第三，三种子标准差 0.006。集成后误差降至 0.602，比单模型

均值低 0.023，相关系数 0.697 与 Self-MM 相同，二分类准确率 0.866 为全表最高。集成行代表提交模型的水平，同口径比较应看单模型一行。

取舍的关键在缺失条件，对照见图 5-5 与表 5-6。

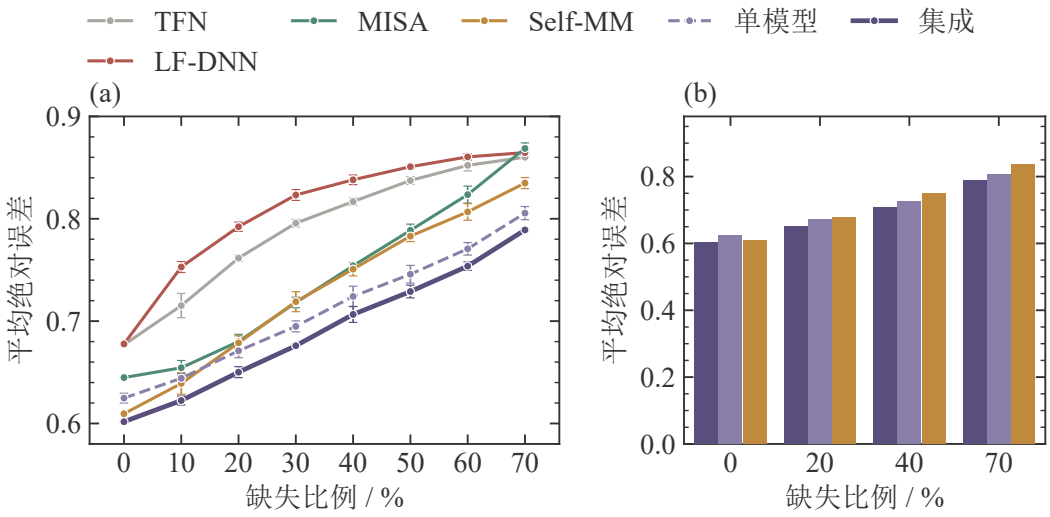


图 5-5　同一组掩码下各方法的误差走向

表 5-6　各方法的平均绝对误差

方法	0%	10%	20%	30%	40%	50%	60%	70%
TFN	0.677	0.715	0.762	0.796	0.817	0.837	0.852	0.860
LF-DNN	0.678	0.753	0.792	0.823	0.838	0.851	0.860	0.865
MISA	0.645	0.654	0.680	0.718	0.754	0.789	0.824	0.869
Self-MM	0.610	0.639	0.679	0.719	0.751	0.783	0.807	0.835
EMT-DLFR*	0.615	—	0.667	—	0.730	—	0.789	—
本文单模型三种子均值	0.625	0.644	**0.671**	**0.695**	**0.724**	**0.746**	**0.771**	**0.805**
本文三种子集成	0.602	0.622	0.650	0.676	0.707	0.729	0.754	0.789

注：标有星号的 EMT-DLFR 为每档缺失率单独保存一份权重，训练与测试的缺失比例相同；其余方法只训练一次，各档数字来自同一份权重。加粗者为仅训练一次的方法中该档最低者，无数值的档位记作短横。

图 5-5(a) 为坡度图，六条折线各对应一种方法，左端为完整输入、右端为缺失 70%，右端外侧以引线牵至端标给出方法名，折线的陡缓即该路缺失造成的退化速度。TFN 与 LF-DNN 两条最陡；Self-MM 起点最低，右端被本文两条线超越；本文集成线整段位于其余各线之下。图 5-5(b) 把同一批数字排成矩阵，行是方法，列是缺失比例，格子越深误差越大：TFN 与 LF-DNN 两行在缺失 20% 一列已明显变深，本文两行变深最慢，集成一行到缺失 40% 之后才明显上升。

表 5-6 给出逐档的绝对误差。缺失 10% 时 Self-MM 以 0.639 领先，本文单模型 0.644。从缺失 20% 起，只训练一次的方法中本文单模型最低，0.671 比 Self-MM 的 0.679 低 0.008，比 MISA 的 0.680 低 0.009；40% 档本文 0.724，MISA 与 Self-MM 分别为 0.754 与 0.751，差距在 0.027 以上；50% 档差距最大，本文 0.746，Self-MM 0.783，相差 0.037；再往上差距略有收窄，70% 档本文 0.805，仍比 Self-MM 的 0.835 低 0.030。两种朴素方

法各档均未进入前列，缺失 20% 时误差已超过 0.760；三种子集成各档均最低，70% 档 0.789，比单模型均值低 0.016。

EMT-DLFR 的设计目标即缺模态一侧，为每档缺失率单独保存权重，适应最充分。缺失 20% 时它为 0.667，比本文单模型的 0.671 低 0.004；40% 时本文 0.724，比它低 0.006，两处差距均在 0.006 的种子波动以内，可视为持平；60% 时本文 0.771，它 0.789，低 0.018，已超出种子波动。部署时缺失率无法预知，本文训练一次即覆盖从完整输入到缺失 70% 的整条曲线，更适合实际使用。

5.4.3 缺失影响规律

规律分析以门控版本的权重为样本，它能直接读出融合随缺失的调整。该版本未入选，与入选版本仅融合方式不同。评测在测试集上把通道组合、缺失比例与缺口位置三个维度铺成完整网格，缺失量用缺失位置数占有效长度的比例衡量。附件 1 的平均音轨长度为 7.771 秒，缺失 20% 折合 1.554 秒，40% 折合 3.108 秒，全缺即整段 7.771 秒。

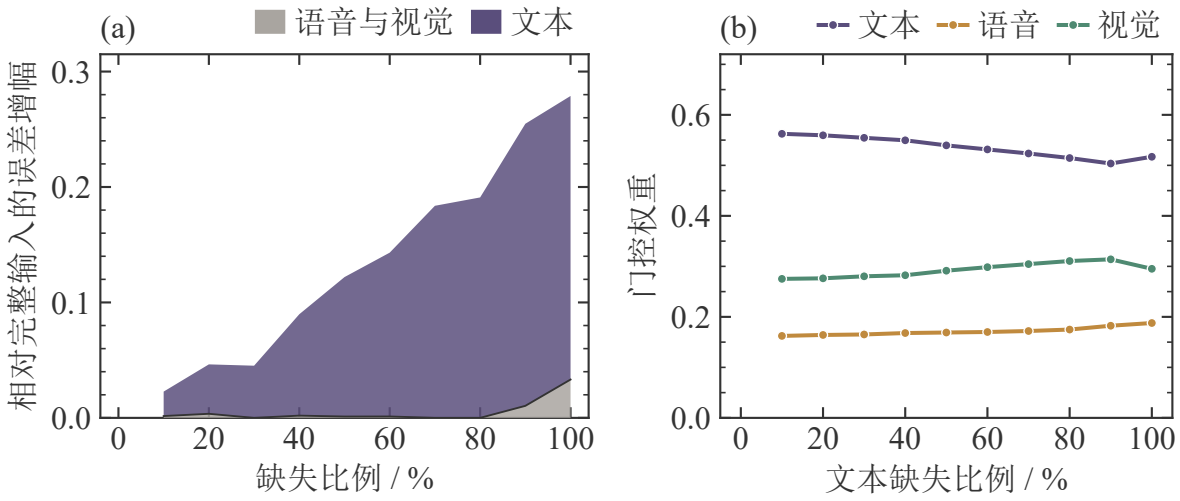


图 5-6　缺失比例的作用

表 5-7　通道组合与缺失比例的交叉网格

缺失模态	0%	20%	40%	60%	80%	100%
仅语音	0.612	0.614	0.614	0.614	0.614	0.624
仅视觉	0.612	0.614	0.610	0.612	0.614	0.621
语音与视觉	0.612	0.616	0.614	0.613	0.611	0.645
仅文本	0.612	0.653	0.700	0.749	0.797	0.876
三模态	0.612	0.658	0.702	0.755	0.802	0.891

首先，三条通道中最经不起缺失的是文本，依据为图 5-6(a) 与表 5-7。图 (a) 为四组堆叠柱，每组三段按缺失 20%、60% 与 100% 自下而上叠加。文本一组最高，累计高度为 6.7%、22.4% 与 43.2%；三模态一组与它几乎等高，为 7.6%、23.4% 与 45.6%；语音与视觉两组均不到 2%。

表 5-7 给出对应的绝对误差。仅缺文本时，缺失 20%、40%、60%、80% 与 100% 的误差依次为 0.653、0.700、0.749、0.797 与 0.876。仅缺语音时全缺 0.624，仅缺视觉时全缺 0.621，语音与视觉同时缺时全缺 0.645，比完整输入的 0.612 高 5.4%。三模态同时缺

一行与仅缺文本一行几乎重合，各档差值均在 0.006 以内，即三模态缺失的后果与文本缺失基本相同。表内 0.612 为门控版本在该组掩码下的完整输入误差，与表 5-6 的 0.625 不是同一份权重，只在同表内比较。

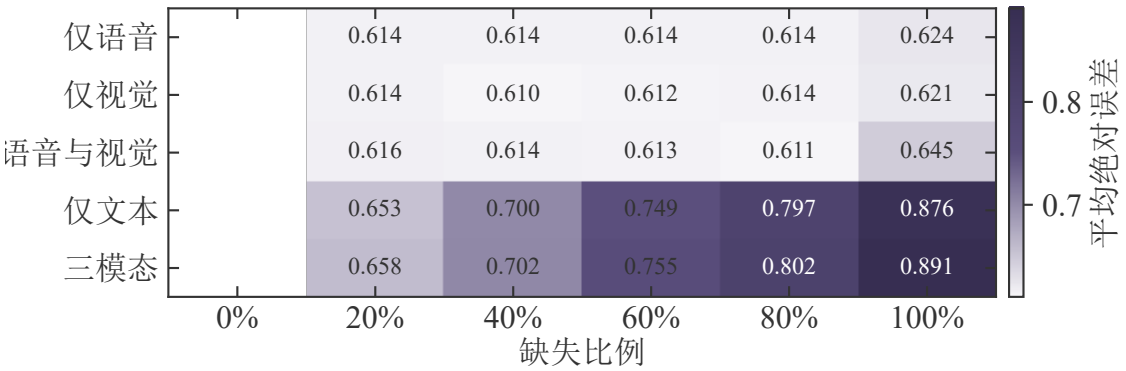


图 5-7　交叉网格上的误差色块

图 5-7 把表 5-7 的数值涂成色块，行是通道组合，列是缺失比例，颜色越深误差越大。仅语音、仅视觉与语音加视觉三行几乎不变，最右一格只到 0.645；仅文本与三模态两行从 0.653 升到 0.876 与 0.891，深浅只随文本那一维变化。

其次，这一路误差随文本缺失比例大致匀速上升。从完整输入到全缺，仅缺文本的误差由 0.612 升到 0.876，平均每多缺 10% 增加 0.026；逐档实测增幅在 0.006 到 0.054 之间，十个十分档中无一档突变，也没有某一档之后增速明显改变。

门控权重随该路缺失的变化见图 5-6(b)。文本一路始终最高、随缺失比例缓降，视觉居中缓升，语音最低且起伏最小。文本缺到 90% 时，文本权重由完整输入的 0.571 降至 0.504，视觉由 0.271 升至 0.314，语音由 0.158 升至 0.182；文本全缺一档，文本与视觉回到 0.517 与 0.295。整套缺失下文本权重只下降 0.067，说明门控的调整方向对而幅度很小，与上一小节两种融合方式不相上下。

门控权重的样本间离散无法从均值看出，图 5-8 给出逐条取值分布。

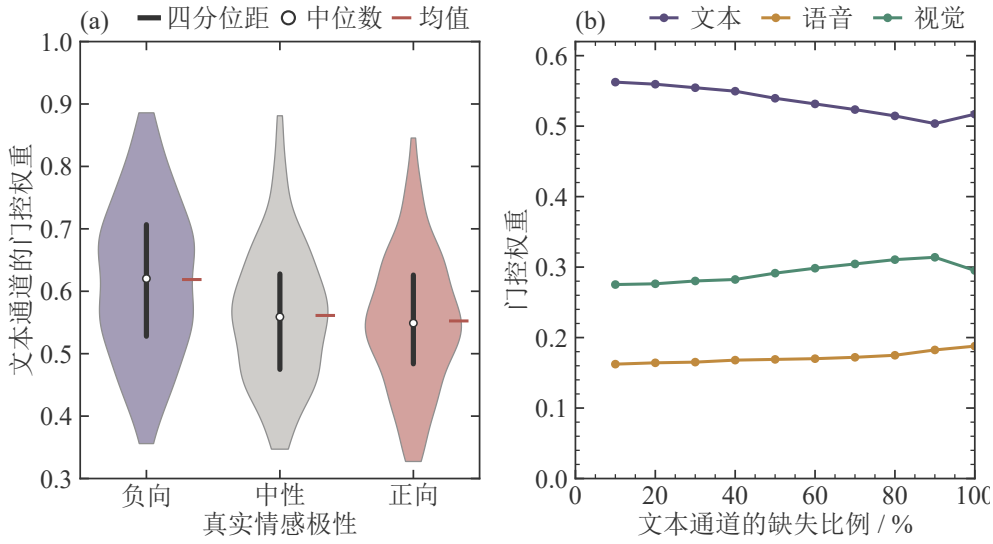


图 5-8　门控权重的分布

图 5-8(a) 每组为一把半宽小提琴图，黑白点线为四分位距与中位数，短横线为均值。三组的箱体均铺开 0.2 以上，即同一极性内各样本间的离散大于三种极性之间的整体位

移；负向组中位数最高，正向组最低，均值与中位数有一定距离，分布偏斜。图 5-8(b) 中三条线在整段横轴上均较平，文本一条由 0.57 缓降至 0.50，语音与视觉各上升不到 0.03。门控确实随样本内容与可用程度变化，但幅度远小于样本自身的离散，这也是它换不回实测收益的原因。

最后是关于缺口位置的规律，见图 5-9。

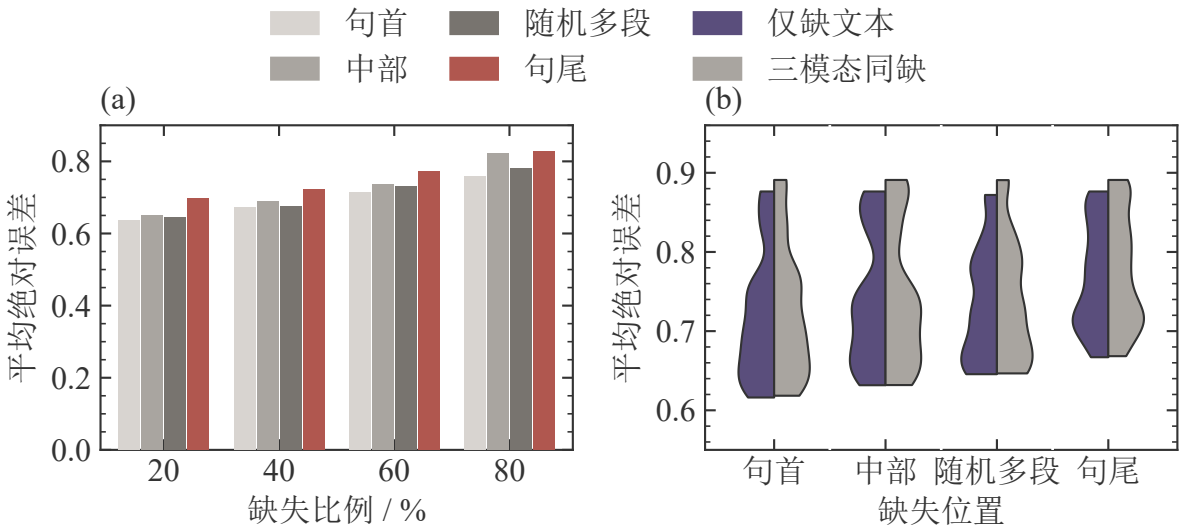


图 5-9　缺口位置的作用

图 5-9(a) 为哑铃图，纵轴为缺失比例的四档，每档上面一根对应仅缺文本，下面一根对应三模态同时缺，线两端为缺在句首与缺在句尾的误差，线越长两端差距越大。四档的线均向右伸，句尾缺失始终更不利。仅缺文本且缺口 40% 时，句首 0.673，句尾 0.721，两端相差 0.048；缺口位于中部的 0.690 介于两者之间；同样缺 40% 而将缺口拆成多段随机分布时误差 0.675，与缺在句首接近，比集中在随机一段的 0.700 低 0.025。三模态同时缺时两端形状几乎相同，句首 0.679，句尾 0.725，说明三条通道同时缺失时起主要作用的仍是文本。

图 5-9(b) 以阶梯线给出仅缺文本时四种缺口位置的误差。句尾一条各档均最高，句首一条各档均最低，中部一条紧随句首，随机多段一条的散点偏下。缺失到 90% 时四条线收进 0.817 到 0.856 的窄带，全缺一档合为同一值 0.876，缺口位置已无影响。

句尾缺失最不利，一种可能是英文口语把评价性结论放在句末，句末缺失即丢失判断依据。情感词在句中的位置分布本文未作统计，该解释只能视为推测。缺口拆散后危害减小，合理解释是多段小缺口可由上下文分别补充，一段连续空洞只能由两侧外推。附件 3 的缺口本身即数段短区间，据此属于较易处理的一类。

5.4.4　消融实验

七项配置的消融结果列于表 5-8，各项相对完整方法的差值见图 5-10，每次只撤掉一项设计。完整方法一行取入选版本主种子训练所得的权重，完整输入误差 0.619，缺失网格均值 0.660。

表 5-8　逐项去掉一个设计后的指标

配置	完整输入误差	二分类准确率	仅文本缺失均值	语音缺失均值	视觉缺失均值	三模态缺失均值	三模态缺 50%
完整方法	**0.619**	**0.838**	**0.698**	0.618	0.616	**0.660**	**0.674**
去掉掩蔽增广	0.623	0.836	0.781	0.632	0.630	0.704	0.730
去掉缺失词元	0.625	0.835	0.723	0.624	0.622	0.673	0.676
去掉整模态丢弃	0.632	0.826	0.699	0.631	0.625	0.665	0.690
去掉重建损失	0.642	0.820	0.744	0.640	0.635	0.694	0.685
去掉一致性损失	0.631	0.843	0.679	0.636	0.634	0.659	0.656
去掉门控融合	0.642	0.833	0.699	0.635	0.633	0.667	0.688

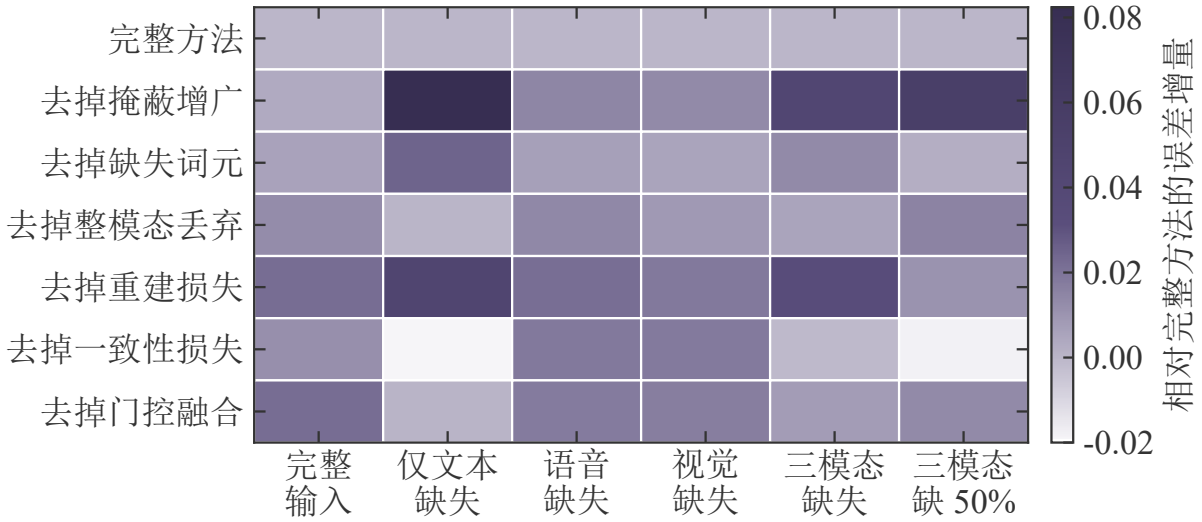


图 5-10　六项消融的误差增量

去掉两级掩蔽增广的代价几乎全部落在缺失一侧。仅文本缺失均值由 0.698 升至 0.781，升幅 0.083；缺失网格均值由 0.660 升至 0.704；三模态同时缺、缺口 50% 一档由 0.674 升至 0.730。完整输入误差仅由 0.619 升至 0.623，语音与视觉两列均值也只由 0.618 与 0.616 升至 0.632 与 0.630。增广提升的是缺失条件下的表现，完整条件下的精度不受影响，训练阶段见过缺失是该模型耐缺失的首要原因。

缺失词元与重建损失两项被去掉后后果相似，都指向同一点：当前位置没有信息这一事实需要有显式的载体，否则模型只能面对零值。前者将仅文本缺失均值抬到 0.723，后者抬到 0.744，缺失网格均值分别升至 0.673 与 0.694，二分类准确率分别降至 0.835 与 0.820。整模态丢弃一层针对极端情形，去掉后三模态同时缺、缺口 50% 一档由 0.674 升至 0.690，仅文本一列几乎不变，为 0.699，说明整条通道完全消失的情形须由该层覆盖。

最后两项需单独说明。去掉一致性损失后，缺失网格均值降至 0.659、仅文本缺失均值降至 0.679，两项均低于完整方法，二分类准确率升至 0.843；代价在另一侧，完整输入误差由 0.619 升至 0.631。融合方式由门控改为平均后，完整输入误差反升至 0.642，缺失一侧只变动 0.007 左右。这两项各自只训练一个种子，而种子本身可带来 0.006 到 0.015 的波动，仅凭这组数字无法判断它们是否起作用；门控是否保留应回到前文三种子各三遍的验证集选型，其结论为两种融合方式持平。一致性损失予以保留，它提升的是完整输入下的精度。

图 5-10(a) 中每个配置占一行，行内两点：方点为完整输入误差相对完整方法的差

值，圆点为三模态缺失时平均误差相对完整方法的差值。零点竖线即完整方法，点位于竖线右侧表示差于完整方法。圆点右伸最多的是去掉掩蔽增广与去掉重建损失两行，方点右伸最多的是去掉门控融合与去掉重建损失两行；去掉一致性损失一行是唯一在缺失侧反而更优的配置。

5.4.5 把强度回归换成有序回归的对照

第 7 章把有序分类加期望解码列为应对收缩的一条改进路径。本节将其实现，与现行版本做对照。两个版本只差强度这一路：直接回归头换成式 (5-11) 的 12 个累积边界，训练目标加一项二元交叉熵，预测按式 (5-12) 解码；其余结构、增广方式、损失权重与早停准则一律不动。每个版本各跑三个随机种子，缺失掩码沿用 5.4.3 节的同一套生成规则，报告三种子均值。

表 5-9　直接回归与有序回归的对照

缺失条件	直接回归	有序回归	差值
干净输入	0.628	**0.614**	−0.014
仅语音全缺	0.627	**0.617**	−0.010
仅视觉全缺	0.663	**0.622**	−0.041
语音与视觉全缺	0.667	**0.629**	−0.038
文本缺失 80%	0.699	**0.680**	−0.019
仅文本全缺	**0.859**	0.907	+0.048
文本与语音全缺	**0.868**	0.906	+0.038
文本与视觉全缺	**0.874**	0.938	+0.064
三模态全缺	**0.885**	0.939	+0.054

表 5-9 里两种版本的差别分成两段。文本还留着的时候，有序回归各档均更低：干净输入低 0.014，语音或视觉单独全缺时低 0.010 与 0.041，文本缺到八成时仍低 0.019。文本一旦整条没了，次序就翻过来，三模态全缺一档高出 0.054，文本与视觉全缺一档高出 0.064。

翻转的来路可以从门控权重上看到。直接回归的三个种子把文本权重定在 0.641 到 0.766 之间，语音与视觉各留一成到两成；有序回归的三种子文本权重是 0.952、0.999 与 1.000，另两条通道几乎归零。累积边界这一参数化把训练信号集中到最强的文本通道上，所以文本在场时表现更好，文本缺席时没有可退的地方。收缩问题与缺失鲁棒性在这套结构里互相牵制：换回归头能换来常见档位的精度，代价是极端缺失档位的稳定性，一处改动无法兼顾两端。本文主体因此仍用直接回归的版本，这条对照作为一条取舍记录留在这里，同时说明第 7 章那条改进路径的实际代价。

5.4.6 稳定性与灵敏度

差异属于真实效果还是噪声，可由更换随机种子重训同一配置判断。两个候选版本各换三个种子，验证集上的完整输入误差列于表 5-10。

表 5-10 前两行的门控一组为 0.579、0.584 与 0.585，平均融合一组为 0.570、0.597 与 0.572。门控一组随种子几乎不变，平均融合波动达 0.027，可见种子影响与模型结构有关。末行换为测试集，三个成员依次为 0.619、0.624 与 0.631，标准差 0.006；同一批实验中选型得分在种子间的标准差为 0.015，比它大一倍以上。凡小于该幅度的差异，本文均不作结论，结果报告三种子均值或集成。

四个关键超参数各取五档重训，结果列于表 5-11，相对入选档的变化画在图 5-11。

表 5-10　两套融合方式的种子误差

候选版本	指标	第一个种子	第二个种子	第三个种子
学习式门控	验证集完整输入误差	0.579	0.584	0.585
平均融合	验证集完整输入误差	0.570	0.597	0.572
学习式门控	测试集完整输入误差	0.619	0.624	0.631

表 5-11　四个关键超参数的测试集指标

参数	取值	完整输入误差	二分类准确率	缺失网格均值	仅文本全缺误差	综合得分
隐藏维 d	64	0.639	0.829	0.654	0.859	1.290
	96	0.622	0.841	0.646	0.841	1.265
	128*	0.633	0.833	0.656	0.857	1.286
	192	0.643	0.822	0.661	0.864	1.301
	256	0.637	0.841	0.657	0.861	1.291
整模态丢弃概率 p_{drop}	0.00	0.631	0.845	0.661	1.060	1.289
	0.10	0.638	0.820	0.661	0.849	1.296
	0.20*	0.623	0.833	0.646	0.856	1.266
	0.30	0.636	0.829	0.660	0.851	1.293
	0.40	0.638	0.817	0.659	0.869	1.294
重建损失权重 λ_r	0.00	0.640	0.841	0.660	0.863	1.297
	0.25	0.641	0.838	0.666	0.861	1.303
	0.50*	0.629	0.848	0.653	0.857	1.279
	1.00	0.626	0.840	0.652	0.857	1.275
	2.00	0.619	0.826	0.643	0.854	1.259
区段掩蔽概率 p_{mod}	0.20	0.626	0.852	0.652	0.878	1.274
	0.35	0.625	0.829	0.652	0.848	1.274
	0.50*	0.638	0.826	0.660	0.857	1.294
	0.65	0.622	0.838	0.645	0.850	1.264
	0.80	0.630	0.838	0.650	0.863	1.277

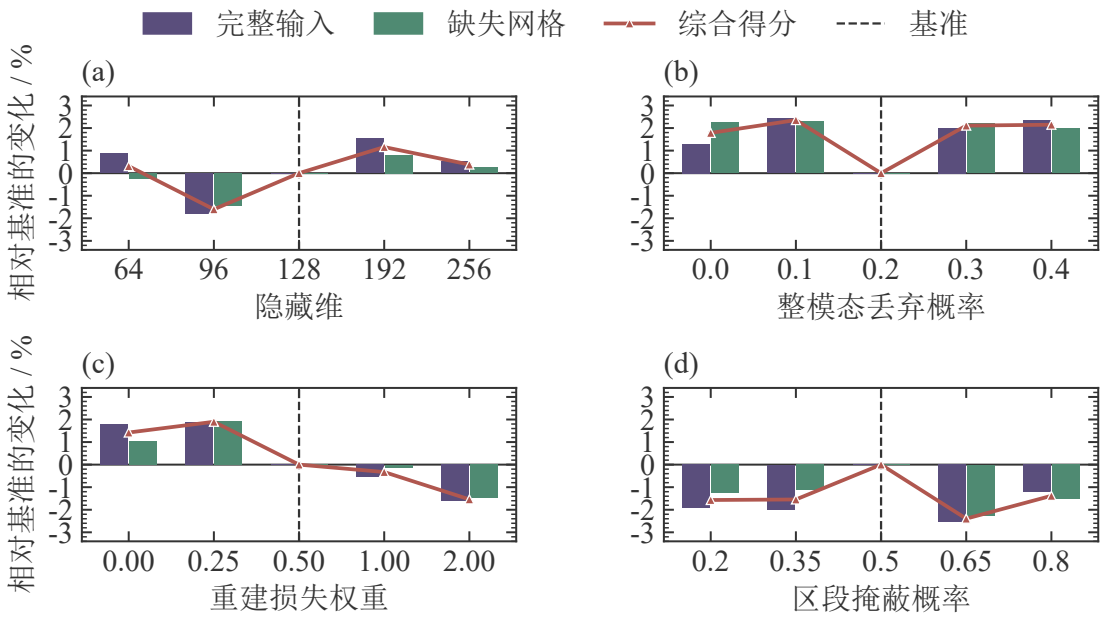


图 5-11　四个关键超参数的响应曲线

四项参数中敏感度最高的是整模态丢弃概率。取 0 时其余各项均正常，唯独仅文本

全缺一列的误差由 0.856 增至 1.060，为全表唯一一处跳变；取值在 0.1 到 0.4 之间时，该列稳定在 0.849 到 0.869。关键不在概率大小，而在训练时是否见过整条通道消失。隐藏维的曲线最平，64 到 256 之间完整输入误差最多相差 0.021，缺失网格均值最多相差 0.015，加宽网络无明显收益。重建损失权重由 0 加到 2.0，缺失网格均值由 0.660 降到 0.643，完整输入误差由 0.640 降到 0.619，方向单调，但 0.25 一档的缺失网格均值比 0 高 0.006，曲线并非处处下降。区段掩蔽概率的最低得分出现在 0.65，为 1.264，入选值 0.5 为 1.294，相差 0.030，约为选型得分种子标准差的两倍，其余三档在 1.274 到 1.296 之间，该参数可选范围较宽。

图 5-11 四个面板各对应一个参数，横轴为参数取值，纵轴为相对入选档的倍数，三条曲线分别为完整输入误差、缺失网格均值与综合得分。入选档上三条曲线均为 1.0，横贯面板的水平线即基准，四个面板量程一致，起伏可直接比较。最平的是隐藏维面板，三条线几乎沿 1.0 走；起伏稍大的是重建损失权重与区段掩蔽概率两个面板；整模态丢弃概率面板的三条线均在 1.03 以内，图上未见异常，真正的异常须回到表 5-11 的仅文本全缺一列。

综合本节与前几节，有三条结论不随种子或超参数变化。文本主导在两种融合方式、七项消融配置与缺失网格各档上均成立，依据为表 5-7 与表 5-8。掩蔽增广是缺失鲁棒性的首要来源，消融中去掉它时缺失一侧升幅最大，灵敏度中整模态丢弃概率取 0 时仅文本全缺的误差显著上升。缺失率超过 20% 后，本文单模型优于全部只训练一次的方法，该结论由三种子均值支撑，且仅在测试集上核对，验证集未作同样对照。

5.4.7　附件 3 的预测结果

将附件 3 的 30 条样本逐条输入入选模型，缺失标志按式 (1-4) 由样本本身判定，逐条结果列于表 5-12，同一结果也收在支撑材料的附件 3 测试集预测结果.csv 中。

表 5-12　附件 3 的预测结果

样本	有效长度	文本缺失位	语音缺失位	视觉缺失位	情感强度	极性
附件 3_01	8	0	0	0	-0.708	负向
附件 3_02	30	5	5	5	-0.057	中性
附件 3_03	34	5	5	9	0.144	正向
附件 3_04	33	2	2	2	0.292	正向
附件 3_05	14	0	0	0	-1.481	负向
附件 3_06	27	3	3	3	1.175	正向
附件 3_07	23	3	3	3	0.068	中性
附件 3_08	17	2	2	2	-0.003	中性
附件 3_09	16	2	2	2	1.569	正向
附件 3_10	8	0	0	0	-0.005	中性
附件 3_11	16	4	4	4	0.243	正向
附件 3_12	15	2	2	2	0.773	正向
附件 3_13	21	2	2	2	0.272	正向
附件 3_14	25	2	2	2	-0.309	负向
附件 3_15	29	3	3	3	0.826	正向
附件 3_16	36	4	4	4	1.337	正向
附件 3_17	24	8	8	8	0.010	中性
附件 3_18	19	3	3	3	0.533	正向

样本	有效长度	文本缺失位	语音缺失位	视觉缺失位	情感强度	极性
附件 3_19	26	7	7	7	-0.059	负向
附件 3_20	50	14	14	14	0.003	中性
附件 3_21	11	3	3	3	0.417	正向
附件 3_22	19	4	4	4	0.141	正向
附件 3_23	15	4	4	4	0.462	正向
附件 3_24	10	2	2	2	-0.354	负向
附件 3_25	11	2	2	2	0.350	正向
附件 3_26	24	6	6	6	0.524	正向
附件 3_27	23	8	8	8	0.716	正向
附件 3_28	35	11	11	11	0.436	正向
附件 3_29	20	8	8	8	0.590	正向
附件 3_30	26	12	12	12	0.594	正向

30 条中判为负向的 5 条，中性的 6 条，正向的 19 条；情感强度在 −1.481 到 1.569 之间。强度最负的为样本 05 的 −1.481，该条无缺失；最强的为样本 09 的 1.569，仅缺 2 个位置。三个种子在强度上的标准差平均为 0.152。分歧最大的两条为样本 01 与样本 05，标准差 0.507 与 0.411，其有效长度分别为 8 与 14，可用位置本就较少，集成可消除该分歧。

缺口最多的单条为样本 20，缺 14 个位置，但有效长度为 50，比例仅 28.0%；比例最高的是样本 30，26 个位置中缺 12 个，占 46.2%，其后为样本 29 的 40.0%。样本 30 在该状态下仍给出 0.594 的正向强度；缺 8 个位置以上的还有样本 17、27、28 与 29，连同样本 30 在内五条中四条判为正向，样本 17 判为中性。判为中性的六条为样本 02、07、08、10、17 与 20，判为负向的五条为样本 01、05、14、19 与 24。附件 3 没有标签，这些数字只能说明缺失达到四成左右时模型仍给出明确的方向，判断是否正确无法检验。30 条中有三条无缺失，为样本 01、05 与 10，对应强度为 −0.708、−1.481 与 −0.005。

6 问题三的模型建立与求解

6.1 问题三分析

问题三要在预测之外给出解释，且解释须经得起复核。复核有两层含义：模型指认的位置确实承载判据，删除后预测随之改变；指认结果能落回原始素材的某一秒，读者可自行核对。题面要求分处多个粒度，本文将其拆为四层。多模态情感分析近来有工作把情感原因的抽取与摘要合到一处做 [5]，思路相通，本文的落点更靠后一步，要求解释最终落到具体时刻。四层中最需交代的是局部重要性，它要同时说清模型内部关注哪里、该位置对输出占多大分量。图 6-1 并排画出两条真实样本上的两路归因。

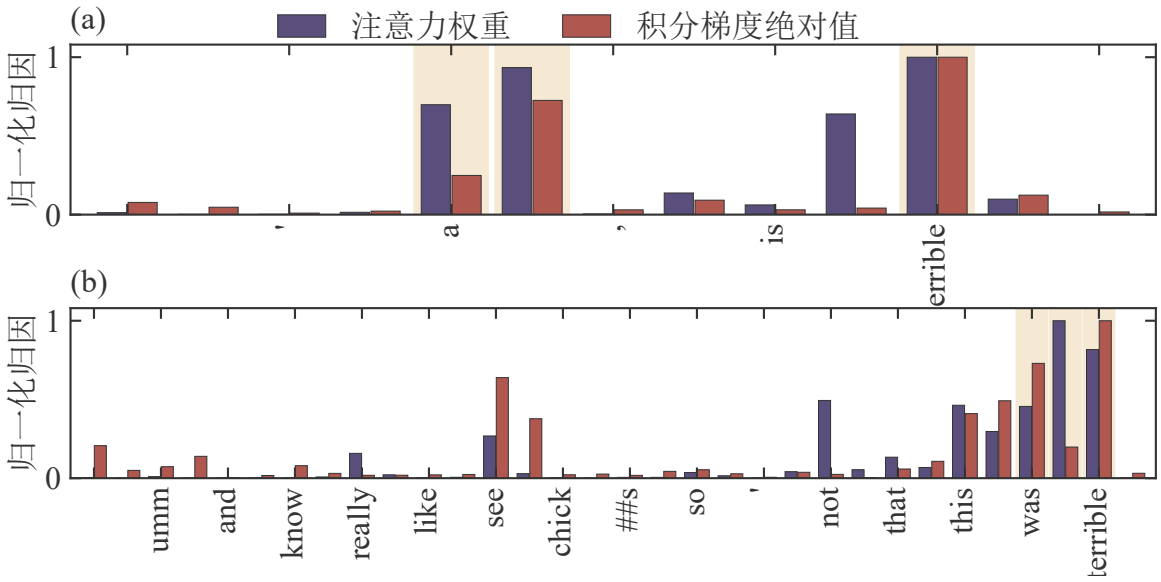


图 6-1　两条样本的注意力权重与积分梯度

图 6-1 每一格画一条样本，横轴为该样本自身的词元，纵轴为归一化后的归因强度，墨紫棒是注意力池化权重，陶红棒是积分梯度的绝对值，底纹标出按式 (6-7) 合成后排在前三的依据位置。(a) 为样本 16，是这批样本中负向最强的一条，两个 terrible 在两路归因里都排在最前，两个视角结论一致。(b) 为样本 10，前半段说自己爱看这类片子，后半段以 but 转折，两路归因的最高峰都压在 but 之后的 pretty 与 terrible 上，模型未被前半段的正向说法带偏。两路归因并不总是一致，(b) 中注意力在 not 与 that 上留有较高权重，积分梯度却几乎不动，说明这两个位置参与汇聚但不改变输出。

复核要落在两处。模型指出某个时刻重要，就删去该时刻再看预测，这是解释与模型行为自洽；读者把视频定位到那一秒，画面内容也应当与结论相关，这是解释与人的认知自洽。两条都过，解释才成立；只过前一条，得到的是忠实却可能反直觉的归因；只过后一条，得到的是看似合理却与模型无关的说法。本章的忠实性检验管前一条，依据回看管后一条，两者缺一不可。

题面列出的三项要求落在不同粒度上，位置级的结论还差一步才落到素材上，本文为此拆成四层。多出的这一层并非另加要求，按分数排序给出的只是模型内部的名次，换成时刻后才能到外部核对。四层的分工也便于定位问题来源：位置排序不可靠，说明注意力与梯度这一路有偏；时刻换算对不上，说明时间窗这一路有偏；通道一层若与事实相悖，问题出在融合处的门控上。哪一层失真，都可从结果倒查回去找到来源。

最上面两层都针对通道，度量的对象却不同。作用程度直接取融合处的门控权重，反映模型分给各条通道的信任，权重最大的通道即定为主要参考模态。必要性由一次反事实给出：把整条通道遮蔽后重新运行前向，看预测偏移多少，偏移小说明该通道的分量可由其他通道替代，偏移大才说明它不可缺。前者在样本进入网络时即确定，属于事前分配；后者需重新运行网络才能得到，属于事后验证，两者不能互相替代。一条通道的权重高，可能只是融合处习惯性偏向它，其他通道携带同义信息时，将其移除预测也不会偏移，只看权重会高估这条通道的分量。

第三层落到单个位置，问的是一段时间里哪些片段重要，它有两个来源。注意力池化权重 $\sigma_t^{(u)}$ 记录序列汇聚阶段模型的关注分布，视角出自模型内部，长处是离融合过程最近，短处是权重高不等于对输出有分量。积分梯度 [22] 换个角度，在零基线与实际输入之间连一条直线，沿线累加输入梯度，度量输入端小扰动传到输出端还剩多少。它有

完备性保证，短处是易受噪声影响。两路反映的偏差方向并不一致，各自归一化到同一尺度后相加，排序结果比单用一路更可靠。

最下面一层管位置如何回到素材。问题一已把每个词元位置与一段时间窗绑定，帧率记为f时还可落到具体某一帧。前三层算出的都是模型内部的位置编号，缺少这段绑定，编号便止于模型内部，无法核对。附件 4 的 20 条视频也按问题一的流程切出逐词时间窗，供本章的依据回看使用。

四层解释都出自同一张网络。若另起一套简化模型计算解释，得到的分量与真正做预测的网络无关，读者核对的就不是模型的依据。本章所有量都取自式 (5-18) 的前向：门控权重、注意力权重与遮蔽前后的预测出自同一份权重文件，回看用的时间窗又与问题一逐条对齐，四个层次因此是同一条链上的不同环节。

6.2 问题三数学模型

本章的模型为**四层归因回溯模型**，由问题二的骨架接上四个解释量组成。编码与融合两段照式 (5-18) 与式 (5-8) 不变，后者保留学习式门控，因为作用程度正是门控权重本身。本问三条通道齐全，不存在缺失，文本一路取附件已备好的冻结特征，编码器不在训练中更新。

名字的两截对应模型的输出，前一截给出四个层次的归因量，后一截把归因排出的位置换成素材上的时刻；缺掉后半截，前面几层给出的位置只是一串下标。

6.2.1 网络结构的改动

第一处改动是单模态预测头的位置。问题二中该头接在跨模态输出之后，那份表示已纳入其他通道的信息，再称为单模态并不合适。本问要由单模态预测值看每条通道各自的判别力，因此把它移回跨模态交互之前，直接接在模态内表示 $\mathbf{S}^{(u)}$ 上，并另配一个注意力池化头

$$\mathbf{y}_{\mathrm{uni}}^{(u)} = \sum_{t} \sigma_{t}^{(m),\mathrm{uni}} \mathbf{S}_{t,:}^{(u)}, \qquad \hat{o}_{u} = \mathbf{w}_{m}^{\top} \mathbf{y}_{\mathrm{uni}}^{(u)}. \tag{6-1}$$

这个头引入的参数很少，只多一组池化权重与一个线性映射。它的用处不止在解释：三条通道各自被要求把强度预测做准，融合那一路便不至于把全部负担压给文本，判别力弱的两条通道也能留在网络里继续提供信息。

第二处改动针对注意力分布的形状。依据要按重要程度排名，池化权重若过于分散，名次几乎没有分辨率，本文因此在损失里补一项熵正则，使这组权重趋向尖锐

$$\mathscr{L}_{\mathrm{ent}} = -\frac{1}{3} \sum_{m} \sum_{t} \sigma_{t}^{(u)} \log \sigma_{t}^{(u)}. \tag{6-2}$$

系数取 $\lambda_{e} = 0.01$，偏低是担心注意力全部集中到一个位置，依据的分布形态便无法显现；该系数未做对照实验确定。

本问三条通道都在，掩蔽增广必要性不大，全部去掉也不会使精度下降；本文只保留一小部分批次，按 0.3 的比例随机抽出做轻度掩蔽，使门控见过可用信息多寡不同的样本，避免其收敛为与输入无关的常数。去掉掩蔽这一路同样未做对照实验。四项损失合起来得到

$$\mathscr{L}^{(3)} = |\hat{o} - y| + \lambda_{c}\, \mathrm{CE}\left(\hat{\mathbf{k}}, c\right) + \lambda_{u} \mathscr{L}_{\mathrm{uni}} + \lambda_{e} \mathscr{L}_{\mathrm{ent}}. \tag{6-3}$$

6.2.2 四个解释量的定义

第一层的量不必另算，门控权重直接取用

$$w_{m} = w_{u}, \qquad \sum_{m} w_{m} = 1. \tag{6-4}$$

权重最大的通道即该样本的主要参考模态，记作 $m^{*}=\arg\max_{m} w_{u}$。

必要性的定义是一次反事实比较：把通道 u 的有效位置整段标成缺失，记扰乱后的输入为 $\mathcal{S}^{\setminus m}$，前后预测相减即得

$$\Delta_{u}=\hat{o}\left(\mathcal{S}\right)-\hat{o}\left(\mathcal{S}^{\setminus m}\right). \tag{6-5}$$

偏移带符号。正值表示该通道抬高预测，负值表示压低预测，绝对值表示它被替代的难度。

遮蔽逐通道进行，三条通道各遮蔽一次得到三个偏移，三个数可以横向比较。符号相同的两条把预测推向同一方向，符号相反的两条相互抵消，模型最终给出的中间值正是这种对冲的结果，只看门控权重排序会把这类样本的分量看高。

局部片段的重要性由两路量叠起来。积分梯度这一路的基线取零向量，沿直线路径积分

$$\imath_{t}^{(u)}=\sum_{j=1}^{f_{u}}\left(X_{t,j}^{(u)}-0\right)\int_{0}^{1}\frac{\partial\,\hat{o}\left(\upsilon\mathbf{X}\right)}{\partial X_{t,j}^{(u)}}\,\mathrm{d}\upsilon\approx\sum_{j=1}^{f_{u}}X_{t,j}^{(u)}\cdot\frac{1}{K}\sum_{k=1}^{K}\frac{\partial\,\hat{o}\left(\frac{k}{K}\mathbf{X}\right)}{\partial X_{t,j}^{(u)}}, \tag{6-6}$$

积分步长 $n_{s}=32$。以零向量为基线时，该数度量一个位置从全零变化到真实取值的过程中为预测累计贡献的分量；计算时缺失标志保持原样，因此这里的零指特征取零，并非把该位置视为缺失。

积分梯度满足完备性，各位置分量之和等于预测从零基线到实际输入的总变化量，据此可读作贡献。基线取零向量而非缺失态，因为本问三条通道齐全，没有缺失位置可借用，而特征取零在每条样本上都成立。两路各自归一化后相加，得到综合重要性得分

$$q_{t}^{(u)}=\frac{\sigma_{t}^{(u)}}{\max_{t'}\sigma_{t'}^{(u)}}+\frac{\left|\imath_{t}^{(u)}\right|}{\max_{t'}\left|\imath_{t'}^{(u)}\right|}, \tag{6-7}$$

按分数从高到低取前 k 个位置，即关键依据

$$\mathcal{Q}^{(u)}=\operatorname*{Top\text{-}k}_{t\in\{1,\dots,L-2\}}\,q_{t}^{(u)},\qquad k=3, \tag{6-8}$$

编号自 0 起，第一位留给句首记号，末位留给句尾记号，两处不参与排序，编法与问题一表 4-3 一致。依据数取 $k=3$ 是折中：取得太少，解释易压在个别词上，无法体现整句走向；取得太多，解释卡中位置过密，人工核对耗时过多。

回看这一步交给问题一的时间窗。任取一个进入 $\mathcal{Q}^{(u)}$ 的位置，都能在原始素材上找到三样东西

$$t\longmapsto\left(\underbrace{w_{\varrho(t)}}_{\text{文本词元}},\ \underbrace{[\gamma_{t},\Gamma_{t}]}_{\text{语音时段}},\ \underbrace{\left\lfloor\tfrac{\gamma_{t}+\Gamma_{t}}{2}f\right\rfloor}_{\text{视频关键帧}}\right). \tag{6-9}$$

回看这一步不需重新运行模型，按式 (6-9) 查表即可。前提是附件 4 的词元编号与问题一给出的完全一致，只要错开一位，换算出的时刻就会整体偏移，后续核对随之失去意义。本文逐条比对，20 条全部对得上。

6.2.3　模型的不变性与整体形式

三条通道的注意力与梯度在尺度上相差悬殊，各自的得分能否直接放在一起比较，取决于式 (6-7) 是否对通道内的正比例缩放不变。设某条通道的注意力权重一律放大 λ 倍、积分梯度一律放大 ν 倍，两数均为正：第一项分子分母同时乘以 λ；第二项取绝对值后乘以 ν，分母取同一组数的最大值，也乘以 ν，两者商都不变。综合得分与原值完全相等，跨通道排序因此不受量纲影响。

把两处结构改动与上面六个定义合到一处，**四层归因回溯模型**的整体形式写成

$$\begin{cases} \hat{o},\ \hat{\mathbf{k}},\ \mathbf{w},\ \boldsymbol{\sigma},\ \mathbf{C}^{(u)} \leftarrow \text{编码与融合沿用式 (5-18)，单模态头改接在} \mathbf{S}^{(u)} & \text{前向} \\ w_m = w_u, \qquad m^{*} = \arg\max_m w_u & \text{作用程度} \\ \Delta_u = \hat{o}\left(\mathscr{S}\right) - \hat{o}\left(\mathscr{S}^{\setminus m}\right) & \text{必要性偏移} \\ q_t^{(u)} = \sigma_t^{(u)} / \max\limits_{t'} \sigma_{t'}^{(u)} + \left|\imath_t^{(u)}\right| / \max\limits_{t'} \left|\imath_{t'}^{(u)}\right| & \text{综合得分} \\ \mathcal{Q}^{(u)} = \text{Top-}k\ q_t^{(u)}, \quad t \in \{1, \ldots, L-2\} & \text{关键依据} \\ t \mapsto \left(w_{\varrho(t)}, [\gamma_t^{s}, \gamma_t^{e}], \left\lfloor \frac{\gamma_t^{s}+\gamma_t^{e}}{2} f \right\rfloor\right) & \text{时刻回看} \\ \min\ \mathscr{L}^{(3)} = |\hat{o} - y| + \lambda_c \mathrm{CE} + \lambda_u \mathscr{L}_{\text{uni}} + \lambda_e \mathscr{L}_{\text{ent}} & \text{训练目标} \end{cases} \tag{6-10}$$

四个解释量共用同一次前向，只有必要性需多跑三遍反事实前向，其余都是查表与累加，单条样本的解释开销不大。

6.3 问题三模型求解

6.3.1 训练配置与关键参数

本章仍沿用问题二的训练协议，差别集中在表 6-1。

表 6-1　四层归因回溯模型的训练参数

参数	取值	参数	取值
文本特征	冻结，附件给定	单模态预测头位置	模态内编码之后
优化器	AdamW，学习率 5×10^{-4}，权重衰减 0.01	学习率调度	余弦退火
隐层宽度与头数	128，4	模态内与跨模态层数	1，2
批大小	64	最大轮数与早停耐心	40，12 轮
λ_c，λ_u，λ_e	0.5，0.3，0.01	掩蔽批次比例	0.3
掩蔽概率与区段占比	0.4，0.1 到 0.5	随机种子	42
积分梯度	32 步，零向量基线	每条通道的依据数 k	3

表 6-1 与问题二不同之处共四处：文本一路用附件给定的冻结特征，编码器不进优化器；单模态预测头由跨模态输出之后前移到模态内表示之后；损失中多出一项注意力熵正则；掩蔽只作用于 0.3 的批次，概率与区段占比也都调低。三个损失权重分别为分类 0.5、单模态辅助 0.3、熵正则 0.01。参数总量 1 409 879 个，不含被冻结的文本编码器。每轮在验证集上按完整输入计算一次误差，最低一轮存盘，连续 12 轮未更低即早停，轮数上限 40。

表里另有三处沿用问题二的取值。隐层宽度 128、注意力头数 4、模态内编码一层、跨模态交互两层，结构照旧是为了避免结构差异干扰两问的对照；优化器仍用 AdamW 配余弦退火，学习率 5×10^{-4}，权重衰减 0.01；批大小 64 与梯度截断阈值照旧。

重建项与一致性项在本问中不再使用，整模态丢弃也不做；编码器结构参数照问题二不变，两问的精度因此可以直接并列比较。随机种子只跑一个。

文本一路冻结还有一层考虑。本问的落点在解释，编码器一旦更新，问题一得到的词元与时刻的对应关系就要随之改变，回看的可比性会降低；冻结之后，位置编号与时间窗的绑定在整个解释流程中保持不变，读者核对时面对同一套坐标系。早停判据取完整输入下的误差，而非掩蔽输入下的误差：本问要评的是正常输入的预测，掩蔽只是训练期的扰动，以其为判据会把模型引向抗缺失，与本章目标不合。

6.3.2 依据定位与忠实性检验

四个解释量的计算顺序见算法 3。前向与遮蔽两项整批完成，积分梯度逐样本累加。

算法 3 依据定位与忠实性检验

输入： 已收敛的模型权重、待解释样本集、依据个数 k、积分步长 n_s

输出： 逐样本的通道作用程度、必要性偏移、依据位置及其回看结果、忠实性比值

for 待解释样本集里的每一条样本 **do**
  做一次前向，取出强度预测、极性预测、门控向量与三条通道的注意力权重
  令作用程度 $w_m = w_u$，把权重最大的通道定为主要参考模态
  for 三条通道依次 **do**
    将该通道的有效位置整段标成缺失后重新前向，用前后预测之差作为必要性偏移 Δ_u
    以零向量为基线、按 n_s 步累加输入梯度，得到各位置的 $\iota_t^{(u)}$
    两路归一到同一尺度后相加，按式 (6-8) 取前 k 个非特殊位置组成 $\mathcal{Q}^{(u)}$
    用式 (6-9) 把 $\mathcal{Q}^{(u)}$ 里的位置换成文本词、语音时段与视频关键帧
  end for
  把依据位置置成缺失算出偏移 Δ_{evi}，再从有效位置里随机抽 k 个置缺算出 Δ_{rnd}
end for
return 各样本的四个解释量以及 $\Delta_{\mathrm{evi}}/\Delta_{\mathrm{rnd}}$

算法 3 末一步是本章的可信度关口，把解释指认的位置删掉，看预测偏移多少。删除的方式是把该位置的特征清零并把缺失标志置 1，模型在此处只能读到缺失词元；文本一路的删除要落到词元上，先换词再重编码，否则被删的语义仍留在邻位。对照一路对称，在同一批有效位置中随机抽同样多个位置删掉。两个量都在 728 条验证样本上取平均，比值越大于 1，解释越可信。冻结特征意味着被删位置虽已清零，邻位仍携带其语义，两条路上的偏移都被压小；本文也只用均值之比说明，未做逐样本的显著性检验。

整条流程中开销最大的是积分梯度，每条样本、每条通道都要做 32 步前向与反向；遮蔽一支只需三次前向；门控与注意力权重在第一次前向中即可取得。以验证集 728 条样本计，跑完一遍解释在单张卡上只需几分钟。四个解释量算出后各归其处：作用程度与必要性随样本列入结果表，关键依据与其回看结果写入解释卡，忠实性比值汇总为一个数。

6.4 问题三求解结果

本节按预测精度、通道一级检验、位置一级检验、错误分布的顺序展开，全部结果由种子 42 训练出的同一份权重给出。

6.4.1 预测精度

验证集上误差为 0.574，与标注的相关系数 0.664；三分类的准确率与 F1 都是 0.652，二分类两项同为 0.803。测试集依次为 0.625、0.674、0.649、0.645、0.834 与 0.834，对应关系相同。两个划分之间没有明显落差，相关系数在测试集上略高，三分类准确率略

表 6-2　问题三的六项精度指标

数据划分	平均绝对误差	相关系数	三分类准确率	三分类 F1	二分类准确率	二分类 F1
验证集	0.574	0.664	0.652	0.652	0.803	0.803
测试集	0.625	0.674	0.649	0.645	0.834	0.834

低，其余几项在小范围内变动。728 条验证样本与 727 条测试样本互不重叠，检验用前者，报精度用后者。

标注强度的极值到 3.0，两个误差只有该刻度的一成上下。两个相关系数与之相配，说明模型捕捉到的是强度的整体走势，并非把每条样本都推向零点。三分类的准确率与 F1 在测试集上为 0.649 与 0.645，只差 0.007，验证集上同为 0.652。这说明两端的类别未被忽略，三个类别的样本数虽有差别，模型并未靠预测多数类抬高准确率。二分类两项都在 0.80 以上，与三分类的落差反映任务变粗后难度下降，并非模型偏向某一类。误差与相关系数在两个划分上同向变化，训练未见过拟合迹象。

解释性约束是否降低精度，是本问需要回答的问题。表 5-5 给出问题二的成绩，单模型三个种子在测试集上分别为 0.619、0.624 与 0.631，均值 0.625，本章的 0.625 与之持平。为得到四层解释，本问改动三处结构：单模态头从跨模态输出之后移到模态内表示之后；训练目标加入熵正则，压低池化权重的熵；掩蔽只作用于三成批次，强度低于问题二。改动都朝向使注意力变尖的方向，分布尖锐才便于排序取依据，从这组数看没有牺牲预测能力。

这一对照并不严格。问题二的文本编码随网络一同训练，本问改用附件给的冻结特征；问题二的增广是两级掩蔽增广，本问只保留轻度的一层；种子数也从三个减到一个。变量改得这么多，两组数的差异无法归因。只能得出一个结论：精度这一关已过，解释性约束没有拉低成绩；它是否带来增益，本章的算例无法回答，需另设消融实验。

6.4.2　忠实性检验

解释要成立，先要确认它指认的位置确实承载判据。检验用删位对照，在 728 条验证样本上逐条进行：先把通道 u 中综合得分最高的 3 个位置清除，记下预测偏移的绝对值 Δ_{evi}；再从同一条通道的有效位置中随机取 3 个清除，记下 Δ_{rnd}。清除方式是把这几位的特征置零并置缺失标志 1。若解释忠实，删依据引起的预测变化应明显大于删随机位置。结果见表 6-3，同一组数另绘于图 6-2。

表 6-3　删依据位置与删随机位置的对照

模态	删证据位置的预测偏移	删随机位置的预测偏移	偏移之比	删证据位置后的误差
文本	0.242	0.053	4.53	0.601
语音	0.031	0.018	1.75	0.577
视觉	0.042	0.026	1.62	0.574

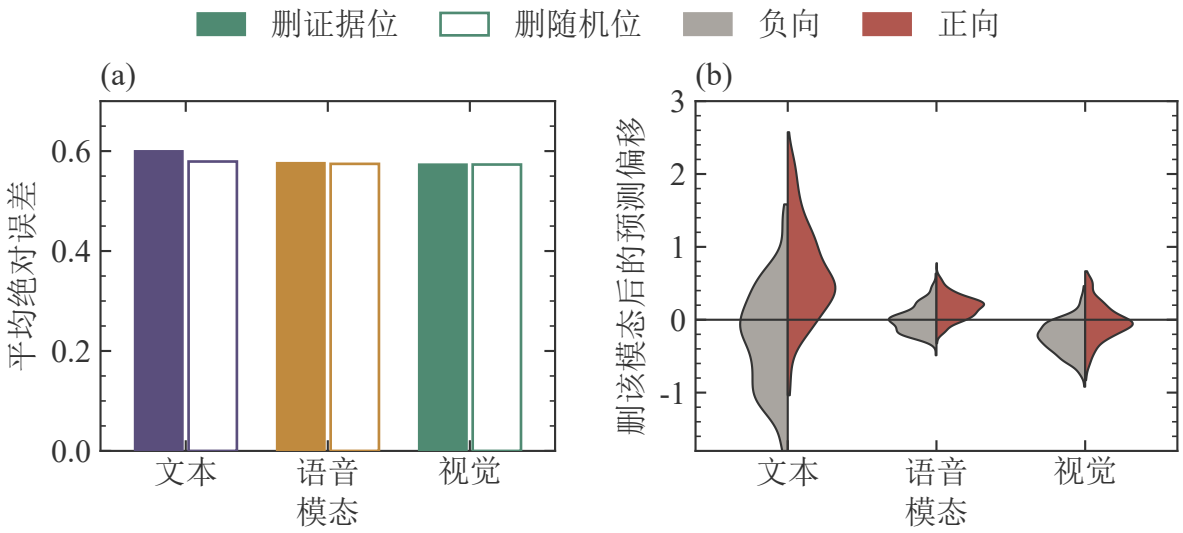


图 6-2　忠实性检验的两个对照

文本一路的两个偏移是 0.242 与 0.053，比值 4.53，删掉模型指认的三个位置带来的预测变化是随机删除三个位置的 4.53 倍，被指认的位置确实在支撑判据，这一路的解释成立。语音与视觉的比值为 1.75 与 1.62，方向无误，幅度小得多。

比值小有两种解释。一是这两条通道自身携带的判别信息本就少，随机清除三个位置预测也几乎不动，这与单模态误差的差距一致；二是它们给出的解释本身不够忠实，位置选偏，删除后自然没有反应。现有数据无法区分这两种解释，只能说文本一路通过了检验，另外两路只通过了方向性检验，幅度不足。

三条通道的偏移之比按文本、语音、视觉排列为 4.53、1.75 与 1.62，次序与单模态误差的次序一致：判别力越强的通道，删除其指认位置的响应越大。这一一致并非必然，判别力强的通道完全可能把得分分摊到无关位置，比值便会回落到 1 附近，本问未出现。

本问的文本用冻结特征，三个位置清除后邻位仍保留这几个词的语义，无论删依据还是删随机位置，预测的变动都被压小，比值大小只能作参考。报出的又是 728 条样本上的均值，逐条样本是否稳定，本文未做检验。

图 6-2(a) 把表 6-3 的数画成配对柱，每个通道两根并排，实心柱是清除依据位置后的验证集误差，空心柱是清除等量随机位置后的误差。文本一对落差最大，实心柱 0.601、空心柱 0.579，相差 0.022；语音与视觉两对几乎等高，空心柱分别为 0.574 与 0.573，落差都在 0.003 以内。

图 6-2(b) 是同一组数的分布，横轴为三条通道，每条上两把背靠背的半小提琴，灰为负向样本、陶红为正向样本，纵轴为整条通道被遮蔽后预测偏移的幅度。三组图形横向跨度都很大，负向一半整体位于零线以下，正向一半整体位于零线以上，说明遮蔽通道会把预测朝反方向拉；文本一组的跨度明显大于语音与视觉，同一条通道内部的样本差异大于两个极性之间的位移。门控权重作为解释量也有分布形态，只看均值会遗漏信息。

6.4.3　三条通道的作用差异

门控权重在验证集上的三路均值为文本 0.723、语音 0.074、视觉 0.203，测试集上为 0.731、0.072、0.196，两个划分几乎重合。逐条统计主要参考模态，验证集中文本占 97.80%，视觉 1.65%，语音 0.55%，均值上的偏向在逐条样本上也得到体现。

单模态头给出另一条独立线索：三个头移到跨模态交互之前，直接读取每条通道自

身的模态内表示，度量这一路单独能达到的水平。测试集误差依次为文本 0.653、语音 0.873、视觉 0.860，验证集为 0.593、0.785 与 0.796。文本一路单独使用，与三模态融合的 0.625 相差很小；语音或视觉单独使用，差距立即拉开。判别力最强的通道分到最多的权重，两条互不相干的证据在文本居首这一点上吻合。

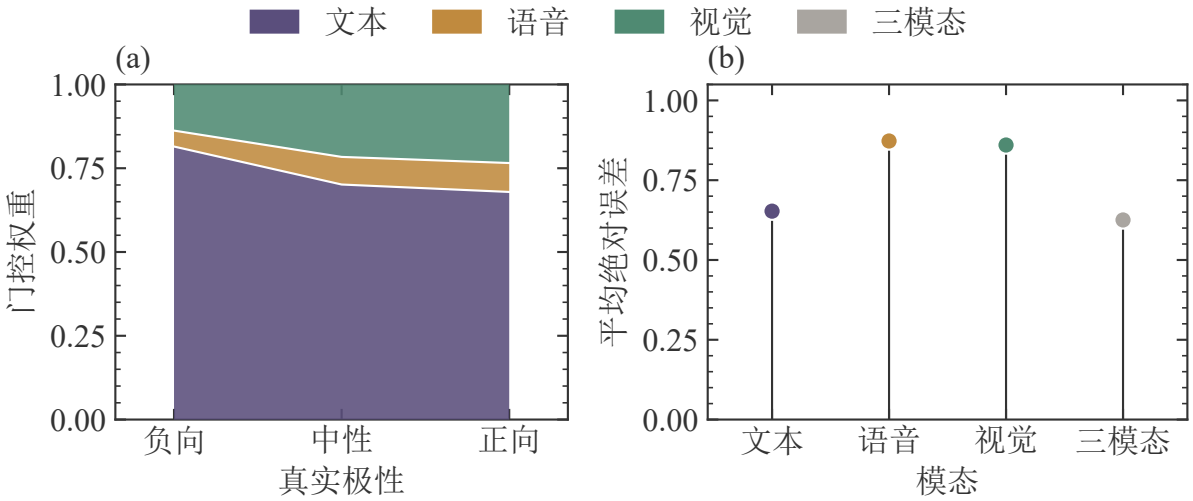


图 6-3　三通道的作用差异

图 6-3(a) 把三组均值画成点线。文本一条始终位于最上方，从负向到正向缓慢下降；视觉一条位于下方，缓慢上升；语音一条贴近底线，几乎无起伏，三条线之间的间隔远大于各自的起伏。

图 6-3(b) 让单模态误差与门控权重共用一个横轴，误差对应左轴，权重对应右轴。文本一格是矮柱配高点，语音与视觉两格是高柱配低点，柱与点的高低在三条通道上均相反，说明判别力与分到的权重不成正比，权重低的两条在融合中主要起补位作用。

把验证集按真实极性切成三块，各块的门控权重均值见表 6-4。

表 6-4　三种极性下的门控权重均值

真实极性	文本权重	语音权重	视觉权重
负向	0.815	0.048	0.138
中性	0.701	0.082	0.216
正向	0.679	0.086	0.234

表 6-4 显示的规律很直接：负向一栏文本 0.815、视觉仅 0.138，正向一栏文本 0.679、视觉升到 0.234，两端相差约 0.14；语音在三行里始终是配角。一种合理的解释是，英文口语表达负向情绪常靠否定词与贬义词明确表态，语义线索强而集中，模型因此更依赖文本；正向情绪中有相当一部分靠面部动作传递，视觉的分量随之上升。这一推测未用表情系数或面部动作单元核实，只能作为解释而非结论。可以确定的是，门控权重并非所有样本共用的常数，它随样本内容变化。

语音与视觉的先后，本文不细究。测试集上视觉的 0.860 低于语音的 0.873，与门控更偏视觉一致；验证集上语音的 0.785 反超视觉的 0.796，与门控方向相反。两个划分结论相反，样本量都在七百条上下，这一差距接近噪声，结论因此只到文本与另外两条通道这一层。

6.4.4 附件 4 的预测与解释

把训练好的模型接到附件 4 的 20 条样本上推理一遍。每条样本输出情感强度与极性，并给出三条通道各自分到的权重、主要参考模态与整段遮蔽后预测的变化；排前三的依据及其落在原始素材上的时刻一并列入解释卡，逐条结果放入支撑材料，文件名为附件 4 预测与解释结果.csv。预测与通道权重的汇总见表 6-5。

表 6-5　附件 4 的预测与通道权重

样本	情感强度	极性	文本作用	语音作用	视觉作用	文本单模态	文本遮蔽效应
1	0.123	中性	0.595	0.129	0.276	0.018	0.333
2	-0.573	负向	0.940	0.006	0.055	-0.202	-0.087
3	-0.061	中性	0.624	0.110	0.266	-0.073	0.181
4	-0.192	负向	0.707	0.076	0.217	-0.765	-1.092
5	0.582	正向	0.469	0.198	0.333	-0.048	0.020
6	0.408	正向	0.684	0.081	0.236	0.332	0.498
7	0.968	正向	0.758	0.055	0.187	0.701	1.502
8	0.150	中性	0.479	0.131	0.389	0.488	0.634
9	-1.946	负向	0.960	0.009	0.030	-1.840	-2.029
10	-1.708	负向	0.956	0.004	0.040	-1.733	-1.535
11	-0.908	负向	0.990	0.001	0.010	-0.507	-0.421
12	-0.854	负向	0.920	0.023	0.057	-1.133	-0.199
13	0.082	中性	0.729	0.062	0.209	0.112	0.152
14	0.307	中性	0.724	0.056	0.220	0.031	0.136
15	0.684	正向	0.474	0.216	0.311	0.495	0.305
16	-2.392	负向	0.994	0.001	0.005	-2.266	-2.041
17	1.419	正向	0.744	0.072	0.184	1.405	1.404
18	-0.506	负向	0.716	0.047	0.237	-0.383	0.239
19	1.082	正向	0.787	0.047	0.165	0.797	1.231
20	0.784	正向	0.587	0.057	0.355	0.193	1.173

把 20 条的文本作用程度与遮蔽效应并排画出，两者关系见图 6-4。

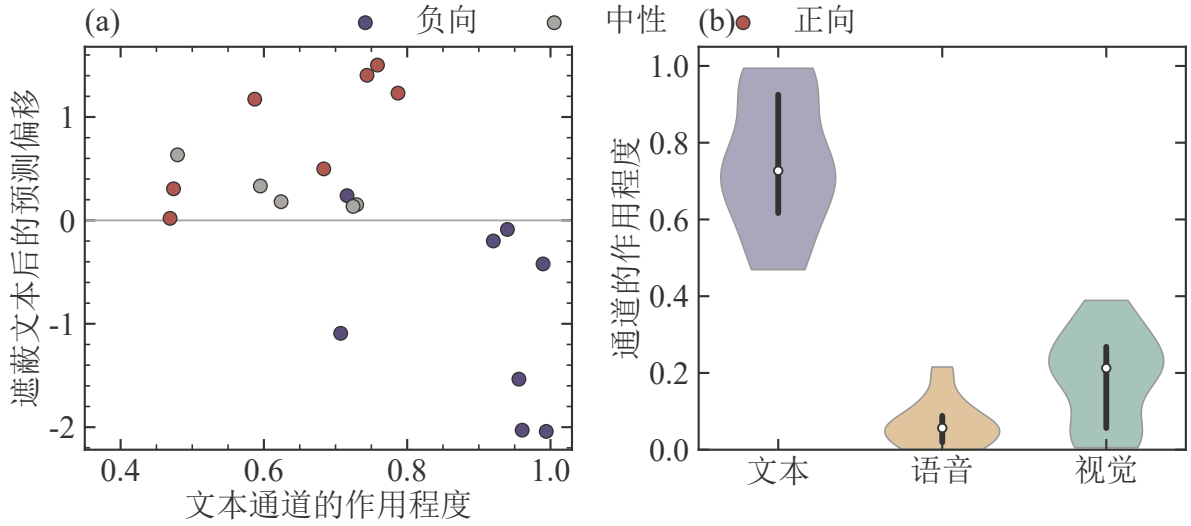


图 6-4　附件 4 的通道作用程度与遮蔽效应

图 6-4(a) 横轴为文本通道的作用程度，纵轴为遮蔽文本后的预测偏移，按真实极性着色。点整体呈右下走向，作用程度越高，遮蔽后的偏移越负，两量方向一致；但同一条竖直线上仍散着若干点，相近的作用程度对应的遮蔽效应能差一倍以上，两列因此并排给出。(b) 是三条通道作用程度的分布，文本一组的中位数接近 0.8，语音与视觉两组都压在 0.25 以下，语音一组的分布最窄，几乎不参与判断。

极性一列中，负向 8 条，正向 7 条，中性 5 条。20 条样本的主要参考模态全部落在文本上，与验证集上 97.80% 的比例一致。文本一路的作用程度均值 0.742，语音 0.069，视觉 0.189；验证集上对应的三个数为 0.723、0.074 与 0.203，两边接近，未见系统性偏移。

权重的分布延续表 6-4 的走向：负向最强的四条样本 9、10、11、16，文本权重都在 0.95 以上，视觉权重不到 0.05。正向与中性样本强度偏弱，比值反转，文本权重落到 0.47 至 0.59，视觉权重升到 0.31 以上。权重与遮蔽效应两列还能互相印证。样本 16 上两者同向：文本权重 0.994，式 (6-5) 的遮蔽效应为 −2.041，判断几乎完全依靠语义。样本 5 上两者不一致：门控把文本排在首位，权重 0.469，但遮蔽效应只有 0.020，移除文本预测几乎不动，另外两条通道仍能给出相近的判断。解释卡把权重与必要性一并列出，由读者自行权衡。

从方向看，文本抬高预测的几条集中在正向样本上，样本 7、19、20 的遮蔽效应为正，以样本 7 最大；压低最多的是样本 16 与样本 9。遮蔽效应的符号与预测极性一致，说明文本这一路既能抬高也能压低分数，并非只朝一个方向作用。

取三条样本细看，细节见表 6-6。三条按极性选取：样本 16 全句负向，样本 10 前半段正向、后半段以转折翻转，样本 17 通篇正向，用于检查模型在不同句法结构下把依据落在何处。

样本 16 的句子只有九个词，terrible 出现两次，两次都被模型选入前三，第三个位置给了它前面的冠词 a。注意力排序最靠前的两处与积分梯度最大的两处落在同一个词上，两套口径结论一致。该样本的文本权重 0.994，为 20 条中最高；文本单模态头给出的 −2.266 与融合后的 −2.392 相差有限，语义这一路的判断压过另外两路。

样本 10 带一个转折，解释卡见图 6-5。

表 6-6　三条样本的解释卡细节

样本	原始文本	预测强度	主导模态	前三个文本依据与时间定位
16	It’s a terrible, this is a terrible movie	−2.392	文本	terrible 位置 10，1.76–2.06 s；terrible 位置 5，0.78–1.12 s；a 位置 4，0.62–0.78 s
10	And you know I really do like to see fluffy chick flicks sometimes so I’m not against that but this one was pretty terrible	−1.708	文本	terrible 位置 30，8.56–9.00 s；pretty 位置 29，7.78–8.56 s；was 位置 28，7.38–7.78 s
17	Applying these four design concepts to your presentations is simple, easy and will make people think you turned into a design guru.	1.419	文本	simple 位置 10，4.44–5.08 s；easy 位置 12，5.54–5.82 s；guru 位置 23，8.62–8.96 s

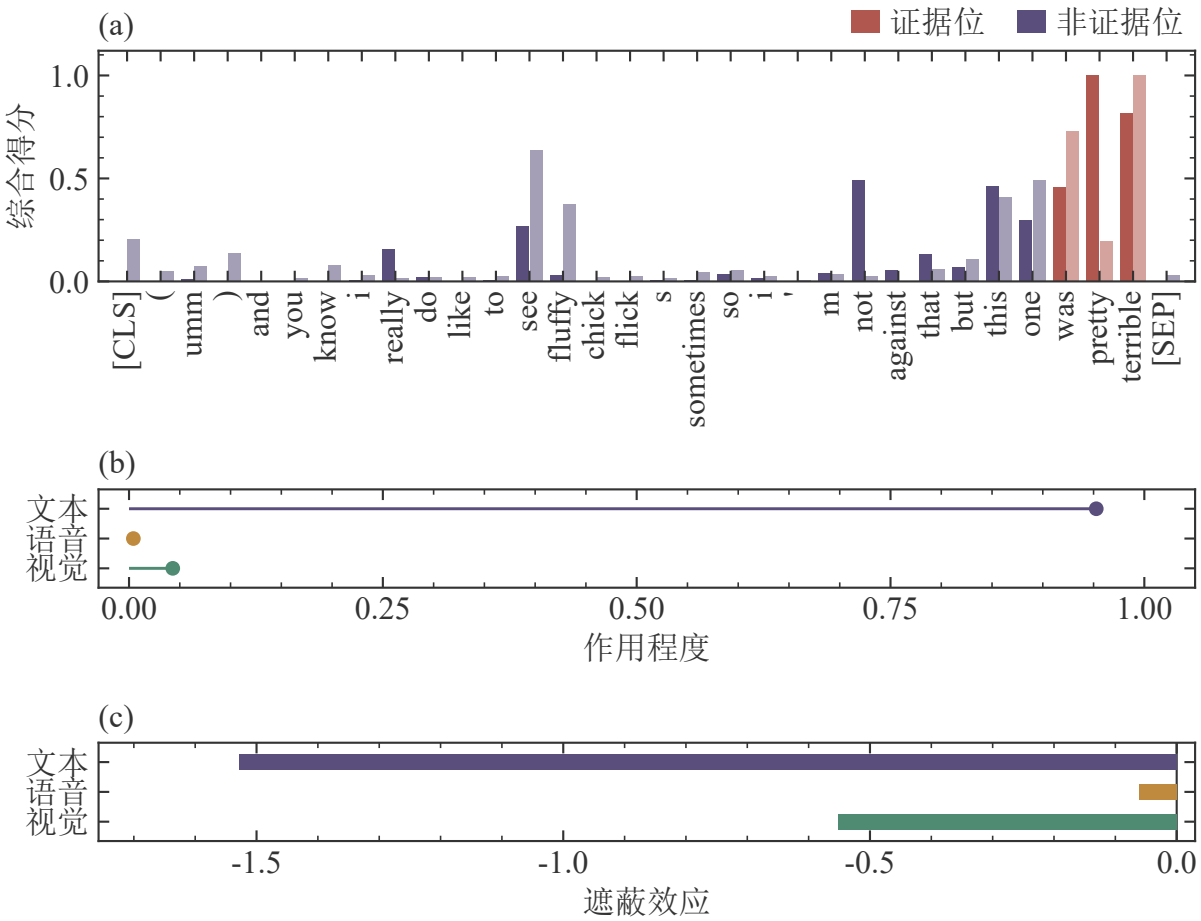


图 6-5　样本 10 的解释卡

句子前半段说自己爱看这类片子，后半段以 but 转折为对本片的否定。图 6-5(a) 按式 (6-7) 画出各词元的综合得分，被选中的三位用深色棒标出，位置 28、29、30 连成一

段，紧跟在 but 之后，集中在 7.38 到 9.00 秒；整段音频长过 9 秒，模型未被前半段的正向说法带偏。图 6-5(b) 给出三条通道各自分到的权重，文本 0.956 明显领先，语音 0.004、视觉 0.040 都贴近底线。图 6-5(c) 换成遮蔽效应，文本 −1.535 最长，视觉 −0.555 次之，语音 −0.061 最短。视觉分到的权重虽小，遮蔽它强度仍有明显变化，这条样本的负向判断视觉也有贡献。

样本 17 的三处依据落在 simple、easy 与 guru 上，时刻为 4.44、5.54 与 8.62 秒，彼此间隔较大，说明这句的正向情感由多处线索汇聚而成，与前面两例靠一处转折定调的形态不同。文本一路单独给出的预测为 1.405，融合后为 1.419，遮蔽文本带来的变化为 1.404，三个数字接近，判断来源单一，换哪条通道作参照都稳定。

6.4.5 依据回看与对齐质量

三条样本的依据时段都能回原视频逐一定位核对。20 条样本排名前三的文本依据连同时间落点列在表 6-7 中，样本 16 的逐时刻回看另见图 6-6。

回看能否成立，取决于附件 4 上的对齐水平，本文为此核对两项。第一项按问题一的流程，把附件 4 的 20 条视频切出时间窗，再将官方转写与识别结果的词逐位比对：匹配率的中位数为 0.932，均值 0.905，只有 1 条低于 0.5，最低一条为 0.412，人脸检出率均值 0.947。第二项核对词元编号，把问题一切出的编号和附件 4 给的编号逐位对照，20 条完全相同。模型给出的位置下标因此可以直接用问题一的时间窗解读，依据回看这一步才成立。

与问题一的全量结果相比，附件 4 的匹配率更高：问题一在全量数据上匹配率均值 0.763、人脸检出率均值 0.898，附件 4 这两项都高出一截。原因在于这 20 条是逐条挑出的演示样本，音画质量优于全量平均水平，切窗与识别都更顺利。依据回看在这 20 条上因此更为稳定，换到全量数据上会略松，读者核对其他视频时应计入这一差别。回看一旦落空，前面三层解释给出的位置下标便无从核对，这一层虽排在最后，分量并不轻。

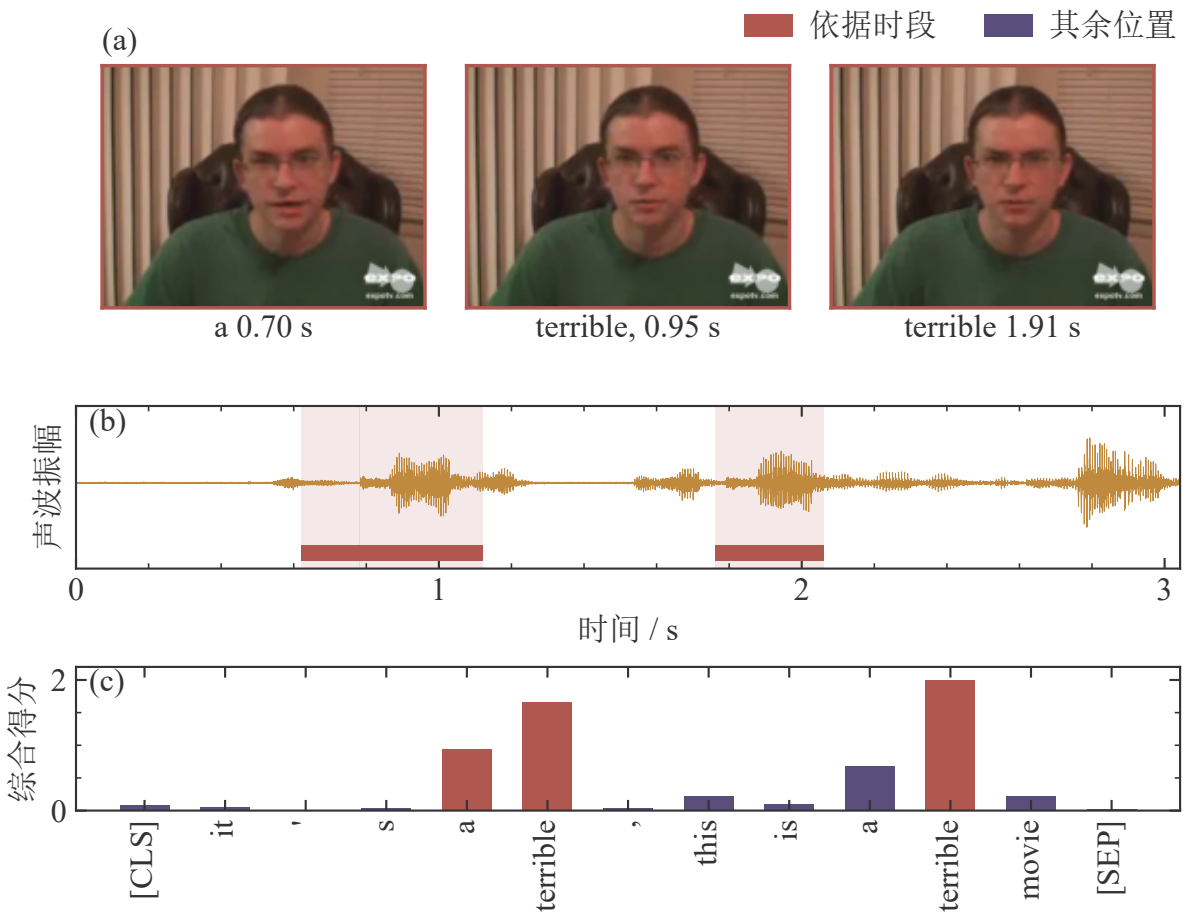


图 6-6　样本 16 的依据回看

图 6-6 把模型内部的一个权重回溯到原始素材，三块子图共用一组时间窗，自下而上阅读。样本 16 的整句为 It's a terrible, this is a terrible movie，预测强度 −2.392。最下一格 (c) 是各词元的综合得分，两个 terrible 以及它前面的冠词 a 得分居前；中间一格 (b) 画声波振幅随时间的起伏，红色带子标出这三位对应的语音时段，依次为 0.62 至 0.78 秒、0.78 至 1.12 秒与 1.76 至 2.06 秒，都落在片段的前两秒内；最上一格 (a) 取三段中点的真实画面，每帧下方标出词与时刻，可回原视频逐帧核对。这一路能够成立，依靠的是问题一给出的位置到时刻映射，即式 (6-9)。

表 6-7 两列的取法不同：首个时段是文本一路得分最高的依据所在的时间窗；关键帧取视觉一路得分最高的依据，按式 (6-9) 算出其中点，因此与文本那一位不一定重合。语音一路的依据时段与另外两个视觉关键帧另存一份 csv，收在支撑材料中。

表 6-7　附件 4 的预测与依据位置

样本	强度	极性	文本	语音	视觉	前三个证据	首个时段/s	关键帧/s
1	0.123	中性	0.595	0.129	0.276	essential，ensuring，to	3.68–4.08	7.83
2	-0.573	负向	0.940	0.006	0.055	misery，happiness，other's	2.46–2.60	0.76
3	-0.061	中性	0.624	0.110	0.266	one，lender，take	0.76–0.96	4.89
4	-0.192	负向	0.707	0.076	0.217	not，should，goodbye	5.72–6.22	1.35
5	0.582	正向	0.469	0.198	0.333	name，is，Chloe	2.10–2.24	1.16
6	0.408	正向	0.684	0.081	0.236	impressive，then，fan	3.88–4.34	5.87

样本	强度	极性	文本	语音	视觉	前三个证据	首个时段/s	关键帧/s
7	0.968	正向	0.758	0.055	0.187	enthusiastically，reports，leading	5.42–6.68	12.55
8	0.150	中性	0.479	0.131	0.389	Grand，Universal，brings	3.04–3.62	3.89
9	-1.946	负向	0.960	0.009	0.030	not，like，not	1.30–1.44	0.34
10	-1.708	负向	0.956	0.004	0.040	terrible，pretty，was	8.56–9.00	6.77
11	-0.908	负向	0.990	0.001	0.010	be，ashamed，would	0.76–0.88	4.79
12	-0.854	负向	0.920	0.023	0.057	low，good，usually	11.90–12.30	0.32
13	0.082	中性	0.729	0.062	0.209	a，more，example	1.20–1.38	5.03
14	0.307	中性	0.724	0.056	0.220	and，co-founder，Director	2.64–3.28	9.26
15	0.684	正向	0.474	0.216	0.311	poverty，believed，transform	6.98–7.20	7.31
16	-2.392	负向	0.994	0.001	0.005	terrible，terrible，a	1.76–2.06	1.12
17	1.419	正向	0.744	0.072	0.184	simple，easy，guru	4.44–5.08	3.35
18	-0.506	负向	0.716	0.047	0.237	denied，failed，Meanwhile	8.96–9.36	8.40
19	1.082	正向	0.787	0.047	0.165	surprisingly，imperfections，forgiving	0.88–1.52	8.25
20	0.784	正向	0.587	0.057	0.355	this，end，at	2.74–2.88	4.75

表 6-7 中两列不重合的例子不少：样本 10 的首个文本时段落在 8.56 到 9.00 秒，视觉一路得分最高的关键帧取在 6.77 秒，相差近两秒；样本 17 的文本时段从 4.44 秒起算，视觉关键帧落在 3.35 秒。两条通道各自认定的关键时刻本不必相同，文本对应词，视觉对应画面，读者按各自的列去原视频核对即可。

表 6-7 中，20 条里判为负向的 8 条，文本权重无一低于 0.68，9、10、11、16 四条最高；其余 12 条判为正向或中性，格局相反，5、8、15、20 四条视觉权重领先。指出的词一半是 terrible、ashamed、failed、simple 这类评价词，另一半混有虚词，20 条中有 7 条的前三依据至少含一个功能词，样本 1 的 to、样本 5 的 is 与样本 20 的 at 即为例。一种可能是跨模态交互把上下文融入每个位置的表示，虚词位置也带有语义，归因因此落到其上。得分高的位置未必都是情感词，核对时需连同左右几个词一并阅读。

6.4.6 验证集上的错误分布

表 6-8　验证集上的错误分布

标注强度绝对值	0	1	2	3
平均绝对误差	0.351	0.620	0.974	1.584
文本门控权重四分位	最低	次低	次高	最高
平均绝对误差	0.470	0.562	0.525	0.739
标注强度绝对值均值	0.644	0.693	0.746	0.993
负向样本占比	12.6%	19.8%	23.1%	57.7%
三分类，真实 \ 预测	负向	中性	正向	合计
负向	**144**	28	34	206
中性	39	**91**	54	184
正向	42	56	**240**	338

表 6-8 上半段按标注强度的绝对值把误差分成四档，四档依次为 0.351、0.620、0.974

与 1.584，逐档升高，强度越大越难判准。预测值始终位于 −2.368 到 2.171 之间，而标注的极值到 3.0，向均值收缩的迹象明显。这一表现与问题二同向，说明收缩并非解释性约束引入，凡以回归为目标的网络都有此现象。

表 6-8 中段按文本门控权重把样本分成四份，误差依次为 0.470、0.562、0.525 与 0.739，最高的一份误差确实最大。该份的标注强度绝对值均值为 0.993，高于最低一份的 0.644，负向样本占 57.7%，其余三份分别只有 12.6%、19.8% 与 23.1%，文本权重高与标注强度大在这份样本中相互交织。误差偏高是模型过于依赖文本，还是这批样本本身难以判定，本文未在同一强度内再分层，无法区分。

表 6-8 下半段是 728 条样本的三分类混淆矩阵，三条对角线为 144、91 与 240，各类正确率 0.699、0.495 与 0.710。中性一类最弱，184 条中有 54 条被误判为正向、39 条被误判为负向；负向一类 206 条中有 34 条被误判为正向；正向一类 338 条中有 56 条被误判为中性。问题二在同一划分上的三分类准确率为 0.639，本问略高，说明加入熵正则、使注意力变尖之后，中间一类并未变得更模糊。

单看正负两种极性，判反的样本有 106 条，在非零样本中占 19.5%。这 106 条里有 48 条的标注绝对值不超过 0.5，紧贴正负分界，与强度回归收缩是同一现象的两面。模型在标注接近零的样本上本就没有稳定线索可用，判反集中在这一带属于数据边界模糊，并非解释层引入的新错误。

按方向归并三类错误，偏斜走向便清楚了。负向误判为正向的 34 条少于正向误判为负向的 42 条；数量较多的是两侧都落入中间，负向进中性的 28 条与正向进中性的 56 条，两项之和超过两个方向对调的总数。中间一类因此既是漏出的源头，也接收两端，这与强度回归收缩的机制一致：模型无法确定时把预测置于中间，代价最小。

综合本节几项检验，问题三的模型在精度上保持了问题二的水平，在解释上给出了可逐条核对的四层结果：通道权重说明模型把注意力分给了谁，遮蔽效应说明缺少哪一条会判错，依据位置说明判据落在哪几个词上，时间窗说明这几个词在原始素材的第几秒。四层之间并不总能互相印证，样本 5 那样的分歧本章如实列出，不作平滑处理。

7 模型的评价

7.1 模型的优点

三问串成一条完整链路，从特征对齐到缺失预测再到解释输出，成立之处有四处。

其一，对齐结果既有明确的语义边界，又能逐个位置核对。词元时间窗作为公共刻度后，序列上任一位置都对应一个词、该词的起止时刻以及覆盖到的抽帧画面；式 (4-8) 给出的映射单调不减，各窗并起来覆盖整段，归并时每个窗至少落进一个帧时刻。位置带有字面内容，问题三的证据回看才有落点。把自提特征与附件 2 逐元素比对，文本一侧的平均绝对差为 0.000，两边处于同一套表示；100 条样本共得到 2447 个有效词元，词匹配率均值为 0.763，平均 0.898 的抽帧能检到人脸，其中 68 条自始至终未丢失人脸。

其二，每一种缺失都有对应的失效环节被单独处理，而非笼统地增加一层鲁棒性。文本一侧真正的漏洞在于冻结特征会借句首记号把整句语义泄露出去，对策是把处理粒度降到词元一级并重新编码。缺失位置若留零值会带来语义歧义，于是改为可学习的缺失词元；汇聚只在可用位置范围内归一化，缺失位置不计入。两级掩蔽增广也各有分工：区段掩蔽使模型学会从上下文补足某一小段，整模态丢弃使其学会在一条通道完全缺失时仍能给出判断。消融结果与这几条对策逐条呼应，见表 5-8：撤掉掩蔽增广后，仅文本缺失这一列的均值由 0.698 升到 0.781；撤掉缺失词元，同一列升到 0.723；撤掉重建损失，升到 0.744。

其三，解释输出分四层，彼此之间可以对照。四层分别给出通道的事前权重、事后

必要性、位置上的关注分布与局部灵敏度，并排列入解释卡；遇到四层冲突的样本，附件 4 的样本 05 即为一例，卡片上把分歧原样保留，不替模型弥合分歧。这四层还能经交叉核对：把验证样本按极性分开看，门控给出的文本占比在 0.679 到 0.815 之间变化，方向与情绪强弱一致；文本在 0.978 的验证样本中被门控选为主模态。换到测试集上，门控均值与验证集几乎重合，文本一路仍占七成上下，说明这层权重并非拟合所得。忠实性也有硬凭据，见表 6-3：删去被指认的三个文本依据位置带来的预测偏移为 0.242，是删随机位置所得 0.053 的 4.53 倍。

其四，比较公平，版本选择不使用测试集。缺模态场景下的对照方法共用同一份缺失掩码，输入条件完全一致；网络结构只在验证集上按事先写定的综合得分挑选，两个候选各跑三个种子，得分 1.232 与 1.229 十分接近，测试集在版本确定后才报一次，见表 5-3 与表 5-5。种子波动也得到控制，单模型三个种子的完整输入标准差为 0.006，集成后测试误差 0.602，低于单模型均值 0.625 与 Self-MM 的 0.610。文本为主这一判断有三路证据支持，即门控权重、单模态误差与缺失网格；语音与视觉的强弱，换一组证据或换一个数据划分就换一种结论，本文因此不给它们排名次。

7.2 模型的缺点

最突出的一处是强度回归把数值拉向中间。问题二的版本在验证集上的预测只覆盖 −2.214 到 2.177，而标注覆盖 −3 到 3，两端各缺一截；误差随标注强度绝对值的上升而单调变大，问题三的分档统计见表 6-8，问题二这一份的走向与之一致。原因是绝对误差损失遇到长尾标注总把预测拉向中段，而两端样本占比又低。收窄预测范围可换取总体损失下降，代价是模型面对强烈情绪时偏保守。这不是样本量不足，而是损失函数与目标分布不匹配。

第二处短板是语音与视觉两条通道未被充分利用。这两条通道单独训练的测试误差为 0.873 与 0.860，远高于文本的 0.653，相关系数更低，只有 0.217 与 0.241，而文本可达 0.650；缺失网格中把语音与视觉从完全可用逐步压到完全缺失，误差也只从 0.612 变到 0.624 与 0.621，折成相对幅度为 1.9% 与 1.4%，见表 5-7。三条通道齐全时，单模型仍高于 Self-MM，优势主要体现在缺模态的场合；换成三种子集成，三条通道的贡献差异依然存在，问题不出在集成上。原因可能有两个方向，一是这份数据的情感线索本就集中在语义上，二是附件 2 给的 74 维语音与 35 维视觉对情绪的区分力有限。究竟偏向哪一边，本文未再区分。

第三处短板在特征口径上。问题一自提的语音为 45 维、视觉为 56 维，附件 2 给的是 74 维语音与 35 维视觉，两边维数与语义都不同；问题二、问题三的网络都没有用这套自提特征做过训练或验证，两边相同的只是把序列排成位置的方式，数据本身并不衔接。要接通这一段，只能回到附件 1 的 100 条上重训一个输入维数匹配的模型，而这 100 条规模有限，训练结果也不足以支撑结论。

第四处短板在对齐的可靠性上。问题一的 100 条样本当中，20 条的词匹配率不到 0.5，文本与音轨本就不能配对；这 20 条中只有 1 条属于片段编号排错，换成同一视频中别的片段的语音即可对上，余下 19 条在任何片段上都对不上。全量样本中靠插值补出的词有 373 个，其中 283 个落在这 20 条上，占 0.759。对齐质量目前只能从覆盖率、匹配率与帧命中数这类侧面指标推断，缺少逐词标注的时间真值。原始转写按赛题要求未作改动，逐条匹配率也都留有记录，这 20 条已单独标出；但这批样本的模态对齐在语义上不可靠，其产出的特征文件只可用于演示流程，不能作为对齐质量的证据。

7.3　模型的改进与推广

应对收缩有两条路径。一条是把强度回归换成有序分类：把 $[-3,3]$ 划成若干个有序档，用累积链接模型给出落在各档的概率，最后加权求期望作为预测值。这一写法对长尾标注的适应性优于直接回归，输出仍是连续值，平均绝对误差这一口径也不需改动。5.4.5 节已经把这条路径走了一遍：三种子对照下来，文本在场时各档误差一律更低，最多低 0.041；文本整条缺失时反过来高出 0.038 到 0.064，原因是门控权重被压到文本一侧，另两条通道几乎不再参与。所以这条路要用，得配一道按可用通道数切换解码方式的机制，只在文本充足时启用，这一层本文没有做。另一条是加权损失，使权重随标注强度绝对值的增大而增大，让数量很少的极端样本在梯度中得到足够权重。两条路径可以合用，先分档再解码，权重只加在分类头上；改动之后仍要经一遍验证集选型，把有序分类版本与现行的回归版本放在同一份缺失掩码下比较。

窗内取均值等于把窗内发生的变化压平，而语调的升降、表情的起落正是情绪的所在。改进办法是每个词元位置上保存一小段有先后次序的帧序列，交给小型循环单元或一维卷积压缩，输出仍是一个向量，但带有次序信息。代价是序列变长、显存占用增加，可只在上游两层保留窗内序列，下游仍按位置汇聚，把开销控制住。

本文原本假设缺失机制随机发生。若放松这一假设，认为缺失与内容并不独立，例如情绪激动时说话人动作幅度变大、人脸检测随之失败，则需要做选择性偏差校正，按缺失概率的倒数为损失加权，使训练所见分布更接近真实分布。校正是否有效，可以用附件 3 逐条记录的缺失区段与位置数回头核对，看加权后这些样本上的预测是否更稳定。

解释的输出格式还可以再进一步。可以取综合得分靠前的词元，按原序连成一句话，与预测一并给出。使用者先读到一句自然语言，需要深究时再展开到逐词与逐帧，解释的门槛随之降低。拼接只用已有词元，不引入额外的生成模型，句中每个成分都能回溯到具体位置，可回溯性不因摘要而丢失。

这套做法可迁移之处有三处。其一，对齐这一层与任务无关。只要主干是文本，又需要把节奏不同的信号对应到语义单位上，即可照搬。会议录音提取要点、教学视频定位知识点、医患对话识别症状都属于这一类；换成其他语种同样成立，只要文本主干能切出词元、音频能给出逐词时刻。迁移时更换的只是文本主干与信号通道，词元时间窗的构造方式与归并规则原样保留。

其二，传感器时好时坏的工业与医疗监测，其困难与这里的模态局部缺失同源。三条通道若换成温度、振动、电流，缺失词元、按可用位置归一化的池化、随缺失比例调整的门控，三者都能直接移植。另有一条结论可以借用：同样比例的缺失，切成多段的破坏力小于连成一整段，见图 5-9，若需节省带宽，可据此把丢弃分散。

其三，只要系统输出最终要由人复核，四层归因即可接入。通道一级的依据、必要性与可回看的证据都已备齐。风控、质检、辅助诊断等场合，把输出格式换成这四层，即可直接对应人工复核的流程；解释卡字段不必改动，更换的只是模型与业务的对应关系。需要留意两点：依据必须带上时间戳与原文，层与层对不上时应如实呈现，不为系统掩饰。

参考文献

[1] Lian Z, Chen L, Sun L, et al. GCNet: Graph completion network for incomplete multimodal learning in conversation, IEEE Transactions on Pattern Analysis and Machine Intelligence, 45(7): 8419–8432, 2023.

[2] Wang Y, Cui Z, Li Y. Incomplete multimodality-diffused emotion recognition, Advances in Neural Information Processing Systems, 36: 17117–17128, 2023.

[3] Zhu A, Hu M, Wang X, et al. Proxy-driven robust multimodal sentiment analysis with incomplete data, Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics, 2025.

[4] Fang Y, Huang W, Wan G, et al. EMOE: Modality-specific enhanced dynamic emotion experts, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2025.

[5] Wan J, Gong C, Fu G. Locate and explain: Joint multimodal emotion cause extraction and summarization in conversation, Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics, 2026.

[6] Zhang S, Yang Y, Chen C, et al. Deep learning-based multimodal emotion recognition from audio, visual, and text modalities: A systematic review of recent advancements and future prospects, Expert Systems with Applications, 237: 121692, 2024.

[7] Zadeh A, Liang P P, Poria S, et al. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph, Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 1: 2236–2246, 2018.

[8] Eyben F, Scherer K R, Schuller B W, et al. The Geneva minimalistic acoustic parameter set for voice research and affective computing, IEEE Transactions on Affective Computing, 7(2): 190–202, 2016.

[9] Lugaresi C, Tang J, Nash H, et al. MediaPipe: A framework for building perception pipelines, https://arxiv.org/abs/1906.08172, 2026 年 9 月 25 日.

[10] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks, IEEE Signal Processing Letters, 23(10): 1499–1503, 2016.

[11] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding, Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics, 1: 4171–4186, 2019.

[12] Radford A, Kim J W, Xu T, et al. Robust speech recognition via large-scale weak supervision, Proceedings of the 40th International Conference on Machine Learning, 202: 28492–28518, 2023.

[13] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models, Proceedings of the 10th International Conference on Learning Representations, 2022.

[14] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need, Advances in Neural Information Processing Systems, 30: 5998–6008, 2017.

[15] Loshchilov I, Hutter F. Decoupled weight decay regularization, Proceedings of the 7th International Conference on Learning Representations, 2019.

[16] Sun L, Lian Z, Liu B, et al. Efficient multimodal transformer with dual-level feature restoration for robust multimodal sentiment analysis, IEEE Transactions on Affective Computing, 15(1): 309–325, 2024.

[17] Mao H, Yuan Z, Xu H, et al. M-SENA: An integrated platform for multimodal sentiment analysis, Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics: System Demonstrations, 204–213, 2022.

[18] Yu W, Xu H, Yuan Z, et al. Learning modality-specific representations with self-supervised multitask learning for multimodal sentiment analysis, Proceedings of the AAAI Conference on Artificial Intelligence, 35(12): 10790–10797, 2021.

[19] Zadeh A, Chen M, Poria S, et al. Tensor fusion network for multimodal sentiment analysis, Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, 1103–1114, 2017.

[20] Williams J, Kleinegesse S, Comanescu R, et al. Recognizing emotions in video using multimodal DNN feature fusion, Proceedings of Grand Challenge and Workshop on Human Multimodal Language, 11–19, 2018.

[21] Hazarika D, Zimmermann R, Poria S. MISA: Modality-invariant and -specific representations for multimodal sentiment analysis, Proceedings of the 28th ACM International Conference on Multimedia, 1122–1131, 2020.

[22] Sundararajan M, Taly A, Yan Q. Axiomatic attribution for deep networks, Proceedings of the 34th International Conference on Machine Learning, 70: 3319–3328, 2017.

附录

附录 **A**　人工智能工具使用情况说明

本队答题时借助了人工智能工具，型号为 DeepSeek V4.1-flash，由深度求索开发，版本发布日期_____。它参与的环节有三个：一是辅助编程，三问的程序从特征提取、训练到评测，编写与排错都借助了它，每个程序开头按规定加了注释；二是辅助数据处理，结果的汇总与图表的绘制由它协助完成；三是论文写作，句子的打磨与版式编排由它协助。

工具只作辅助手段，不代替队员判断。从网络搭建、实验实施到结果解读，连同正文中的每一个结论，都由队员自己完成并逐条核对；文中出现的模型与公式都给出了推导过程或文献出处。支撑材料保留了原始输出与处理日志，复核痕迹可逐项追溯。

附录 **B**　运行环境与复现步骤

整套材料分布在两套环境中，配置都记在 env_versions.json 中。问题一的一套运行在 Ubuntu 20.04 上，Python 3.10，显卡为 NVIDIA RTX 3080 Ti，深度学习框架是 PyTorch 2.7.0 配 CUDA 12.6；其余依赖依次为 transformers 4.51.3、openai-whisper 20250625、openSMILE 2.6.0、librosa 0.11.0、MediaPipe 1.0.1、facenet-pytorch 2.6.0 与 FFmpeg 4.2.7。问题二、问题三连同几项开源对比方法共用另一套：Python 3.12，NVIDIA RTX 4090 D，PyTorch 与 CUDA 版本不变，另装 transformers 4.53.2、peft 0.21.0 与 captum 0.9.0。对比方法的程序取自 MMSA 与 EMT-DLFR 的官方仓库，仅改动数据路径与个别版本兼容之处，方法本身未作改动。

复现步骤在 run_all.sh 中排成三步。第一步运行 extract_q1.py 做特征准备，产出三条通道的特征与逐条词元时间窗；第二步先由 q2_train.py 训练两个候选融合方式、每个各跑三个种子，评测在验证集上完成，再由 final_q2.py 选型、集成并对附件 3 推理；第三步运行 q3_explain.py 训练模型，再对附件 4 推理。每一步的日志与版本记录都随做随留。

环境上有两处问题需要提前规避。一是特征文件的读法，附件 3 与附件 4 的两份文件由较新的数值库写出，直接反序列化会因模块不存在而失败，读取之前要先把 common.py 导入做一次模块名映射。二是导入次序，openSMILE 要排在 PyTorch 之前，次序一旦颠倒，内存分配就会冲突。

附录 **C**　问题一逐条样本的提取结果

表 7-1 把附件 1 的 100 条样本逐一列出。文本一路 768 维，以语言模型分出的词元作对齐单位；语音 45 维，每 10 毫秒一帧；视觉 56 维，每 100 毫秒一帧；三条通道并到同样的 50 个位置，只在有效词元处留值，其余位置补零。表中词数是官方转写切出的词数，有效词元是其中落进对齐位置的部分，语音帧与视觉帧记两条通道各自的帧数；人脸检出率是检到人脸的抽帧占比，词匹配率衡量转写与识别的对应程度。时间轴按音轨长度确定，容器时长只是 mp4 文件中记录的数，100 条中普遍更长，两者相差大的样本说明容器中仍留有片头或片尾。

表 7-1　附件 1 的特征提取与对齐结果

序号	样本编号	音轨长度/s	容器时长/s	词数	有效词元	语音帧	视觉帧	人脸检出率	词匹配率
1	-3g5yACwYnA$_$13	5.399	8.767	15	20	535	55	1.000	0.933
2	-3g5yACwYnA$_$3	14.328	19.273	29	42	1428	144	1.000	0.966
3	-3g5yACwYnA$_$2	9.231	14.234	14	19	919	94	1.000	0.929

序号	样本编号	音轨长度/s	容器时长/s	词数	有效词元	语音帧	视觉帧	人脸检出率	词匹配率
4	-3g5yACwYnA$_$9	8.696	16.234	21	30	865	88	1.000	0.905
5	-3nNcZdcdvU$_$5	7.789	10.937	18	24	774	79	0.987	0.889
6	-HwX2H8Z4hY$_$2	3.916	8.151	8	14	387	40	0.300	0.500
7	-HwX2H8Z4hY$_$5	5.544	11.467	10	12	550	57	0.351	0.900
8	-HwX2H8Z4hY$_$6	3.256	6.767	7	11	321	34	0.618	0.857
9	-HwX2H8Z4hY$_$9	7.636	11.434	22	26	759	78	0.308	0.955
10	-NFrJFQijFE$_$1	5.659	9.120	16	18	561	57	0.000	0.000
11	-NFrJFQijFE$_$2	6.698	9.760	18	20	665	68	0.000	0.000
12	-THoVjtIkeU$_$12	14.806	18.800	39	44	1476	149	1.000	0.949
13	-THoVjtIkeU$_$2	4.231	4.644	10	13	419	43	1.000	1.000
14	-THoVjtIkeU$_$6	7.983	11.067	30	34	794	81	0.988	0.900
15	-UuX1xuaiiE$_$1	10.268	13.434	27	35	1022	104	0.942	1.000
16	-UuX1xuaiiE$_$0	3.576	3.700	9	14	353	37	1.000	1.000
17	-UuX1xuaiiE$_$3	4.038	10.634	9	11	399	41	1.000	1.000
18	-UuX1xuaiiE$_$6	7.944	15.234	22	25	790	81	0.926	0.955
19	-a55Q6RWvTA$_$3	22.083	22.617	65	50	2204	222	1.000	1.000
20	-aNfi7CP8vM$_$7	8.538	11.334	18	25	849	87	1.000	1.000
21	-aqamKhZ1Ec$_$0	10.890	11.000	14	18	1085	110	1.000	1.000
22	-dxfTGcXJoc$_$1	16.018	19.700	36	44	1597	162	1.000	0.944
23	-dxfTGcXJoc$_$0	20.410	20.534	41	50	2037	206	0.777	0.927
24	-dxfTGcXJoc$_$2	16.633	19.552	34	42	1659	167	1.000	0.971
25	-dxfTGcXJoc$_$6	12.628	12.967	27	34	1258	128	1.000	0.926
26	-egA8-b7-3M$_$26	5.921	11.500	15	21	588	60	1.000	1.000
27	-egA8-b7-3M$_$17	7.095	14.000	16	21	705	73	1.000	1.000
28	-egA8-b7-3M$_$18	8.266	13.367	22	29	822	84	1.000	1.000
29	-egA8-b7-3M$_$16	5.483	7.129	11	15	544	56	1.000	1.000
30	-egA8-b7-3M$_$13	4.024	6.967	11	18	398	42	1.000	1.000
31	-egA8-b7-3M$_$1	10.156	11.534	20	24	1011	103	1.000	1.000
32	-egA8-b7-3M$_$6	6.183	8.035	12	15	614	63	1.000	1.000
33	-egA8-b7-3M$_$9	4.936	10.134	10	14	489	51	1.000	1.000
34	-egA8-b7-3M$_$20	6.474	14.767	20	26	643	66	1.000	1.000
35	-iRBcNs9oI8$_$3	5.538	5.840	8	11	549	56	1.000	0.125
36	-iRBcNs9oI8$_$7	4.006	5.806	9	17	396	41	0.976	0.000
37	-iRBcNs9oI8$_$6	2.820	7.475	5	7	278	29	1.000	0.000
38	-iRBcNs9oI8$_$9	3.374	7.152	5	7	333	34	0.735	0.200
39	-iRBcNs9oI8$_$8	8.026	8.642	21	28	798	81	1.000	0.048
40	-lzEya4AM_4$_$5	7.570	7.800	19	23	752	77	1.000	0.947
41	-lzEya4AM_4$_$6	14.740	22.733	43	50	1470	148	1.000	0.953
42	-mJ2ud6oKI8$_$1	6.054	6.574	13	15	601	61	0.000	0.000
43	-mJ2ud6oKI8$_$2	5.702	6.781	11	19	566	57	0.404	0.000
44	-mJ2ud6oKI8$_$6	2.228	2.648	5	7	218	23	1.000	0.200
45	-mJ2ud6oKI8$_$9	6.909	10.010	22	31	686	70	0.943	0.091
46	-mJ2ud6oKI8$_$8	4.171	8.662	11	13	413	42	1.000	0.182
47	-mqbVkbCndg$_$0	6.386	6.500	12	19	634	65	1.000	0.833
48	-t217m2on-s$_$2	5.630	8.011	12	18	559	57	1.000	1.000
49	-t217m2on-s$_$7	17.026	18.700	45	50	1698	172	1.000	1.000
50	-tANM6ETl_M$_$3	6.604	9.100	22	31	656	68	1.000	0.955
51	-tPCytz4rww$_$11	5.379	8.000	17	22	533	55	0.982	0.706
52	-tPCytz4rww$_$10	4.679	11.734	12	17	463	48	1.000	0.917
53	-tPCytz4rww$_$12	11.736	18.767	26	30	1169	119	1.000	0.769

序号	样本编号	音轨长度/s	容器时长/s	词数	有效词元	语音帧	视觉帧	人脸检出率	词匹配率
54	-tPCytz4rww$_$16	7.139	13.236	16	19	709	72	1.000	0.875
55	-tPCytz4rww$_$18	6.569	14.281	16	24	652	67	1.000	1.000
56	-vxjVxOeScU$_$4	9.037	11.734	21	29	899	91	0.945	1.000
57	-wMB_hJL-3o$_$7	5.976	7.315	22	25	593	61	0.967	1.000
58	-wny0OAz3g8$_$1	6.777	9.100	23	30	673	69	1.000	0.870
59	-wny0OAz3g8$_$0	3.274	3.334	9	13	323	34	1.000	0.889
60	-wny0OAz3g8$_$3	6.100	11.169	20	22	605	62	1.000	1.000
61	-wny0OAz3g8$_$2	6.523	11.934	23	30	648	67	1.000	0.957
62	-wny0OAz3g8$_$5	6.741	9.967	20	29	670	69	1.000	0.950
63	-wny0OAz3g8$_$7	7.910	9.500	29	33	787	81	1.000	1.000
64	-wny0OAz3g8$_$9	6.043	9.867	20	24	600	62	1.000	1.000
65	-571d8cVauQ$_$0	4.992	5.167	12	18	495	52	0.962	0.917
66	-571d8cVauQ$_$5	15.115	18.500	43	50	1507	153	1.000	0.977
67	-I_e4mIh0yE$_$1	7.444	10.767	18	23	740	76	1.000	1.000
68	-I_e4mIh0yE$_$3	8.994	9.300	22	32	895	91	1.000	0.864
69	-UacrmKiTn4$_$10	7.242	12.634	18	24	720	74	1.000	1.000
70	-UacrmKiTn4$_$4	4.682	6.223	14	17	464	48	1.000	1.000
71	-hnBHBN8p5A$_$7	7.309	9.176	13	19	726	73	0.699	0.000
72	-hnBHBN8p5A$_$6	6.333	11.429	13	16	629	64	0.641	0.154
73	-qDkUB0GgYY$_$6	4.615	9.683	16	20	457	47	1.000	1.000
74	-uywlfIYOS8$_$4	5.881	14.334	18	24	584	61	1.000	0.944
75	-6rXp3zJ3kc$_$8	12.738	16.580	34	40	1269	128	1.000	0.971
76	-9y-fZ3swSY$_$0	6.757	6.900	22	30	671	69	1.000	0.727
77	-9y-fZ3swSY$_$4	2.665	9.334	9	13	262	28	1.000	0.556
78	-9y-fZ3swSY$_$8	4.917	10.775	12	16	487	50	0.880	0.917
79	-AUZQgSxyPQ$_$2	22.405	27.300	41	50	2236	225	1.000	0.854
80	-HeZS2-Prhc$_$2	8.151	15.834	16	19	811	83	1.000	0.938
81	-MeTTeMJBNc$_$0	9.218	9.334	21	28	917	94	0.979	1.000
82	-MeTTeMJBNc$_$13	5.255	7.467	14	18	521	54	1.000	1.000
83	-MeTTeMJBNc$_$7	10.411	17.367	31	35	1037	105	0.981	1.000
84	-RfYyzHpjk4$_$11	5.075	11.700	17	21	503	52	1.000	1.000
85	-RfYyzHpjk4$_$8	4.532	11.657	17	23	449	46	1.000	0.941
86	-RfYyzHpjk4$_$2	5.392	6.234	25	31	535	55	0.964	0.960
87	-UUCSKoHeMA$_$0	7.732	7.867	18	25	769	79	0.987	0.944
88	-ri04Z7vwnc$_$0	2.763	3.295	8	10	272	28	0.000	0.000
89	-ri04Z7vwnc$_$2	5.913	6.966	16	28	587	60	0.367	0.000
90	-ri04Z7vwnc$_$5	3.440	5.965	9	13	339	35	1.000	0.111
91	-s9qJ7ATP7w$_$1	4.644	10.900	11	14	460	48	1.000	0.909
92	-s9qJ7ATP7w$_$0	6.711	6.867	24	30	667	69	1.000	0.750
93	-s9qJ7ATP7w$_$5	8.398	13.567	19	22	835	85	1.000	1.000
94	-s9qJ7ATP7w$_$4	4.247	6.200	9	12	420	44	0.682	1.000
95	-s9qJ7ATP7w$_$7	6.839	12.767	28	40	679	70	0.729	1.000
96	-s9qJ7ATP7w$_$6	2.315	6.600	5	7	227	25	0.800	1.000
97	-s9qJ7ATP7w$_$8	3.184	6.600	13	19	314	33	1.000	0.923
98	-yRb-Jum7EQ$_$1	29.110	34.567	49	50	2906	293	1.000	0.000
99	-yRb-Jum7EQ$_$5	13.045	13.634	25	33	1300	132	1.000	0.080
100	-yRb-Jum7EQ$_$6	11.243	15.488	19	26	1120	112	1.000	0.000

附录 D　核心代码

三问各取一段最关键的程序列于下方，全部程序见支撑材料。

D.1　问题一：逐词时间戳的转移与窗内归并

这段程序处理官方转写与音轨不匹配的问题，用最长公共子序列在识别词与转录词之间寻找锚点。配上对的词直接继承识别给出的起止时刻，未配上的词由前后两个锚点按词数分摊；两端没有锚点时铺到片段两端，所有时刻都限制在音轨长度以内。后半段把帧级特征按词元时间窗归并，窗内取均值；某个窗内没有帧时刻落入时，取离时间中点最近的一帧替代，同时记下每个窗用掉的帧数作为命中数。

```
# 本程序及代码是在人工智能工具辅助下完成的：DeepSeek V4.1-flash，深度求索
def anchor_words(official_text, asr_words, dur=None):
    """官方转写的词继承识别词的时间戳。用 difflib 求最长公共子序列当锚点，
    未配对的词在相邻锚点之间按词数线性插值；首尾没有锚点时铺到片段两端，
    所有时刻都钳进 [0, dur]。返回逐词时间段与词匹配率。"""
    off = official_text.split()
    o_norm = [norm_word(w) for w in off]
    a_norm = [norm_word(w['word']) for w in asr_words]
    sm = difflib.SequenceMatcher(a=o_norm, b=a_norm, autojunk=False)
    start = [None] * len(off); end = [None] * len(off); matched = 0
    for tag, i1, i2, j1, j2 in sm.get_opcodes():
        if tag == 'equal':
            for k in range(i2 - i1):
                start[i1 + k] = asr_words[j1 + k]['start']
                end[i1 + k] = asr_words[j1 + k]['end']; matched += 1
    tail = dur if dur else (asr_words[-1]['end'] if asr_words else 0.0)
    if all(s is None for s in start): # 全句无锚点，按词数等分
        for i in range(len(off)):
            start[i] = tail * i / max(1, len(off))
            end[i] = tail * (i + 1) / max(1, len(off))
    else:
        i = 0
        while i < len(off):
            if start[i] is not None:
                i += 1; continue
            j = i
            while j < len(off) and start[j] is None:
                j += 1
            left = end[i - 1] if i > 0 else 0.0
            right = start[j] if j < len(off) else max(tail, left)
            n = j - i
            for k in range(n): # 相邻锚点之间按词数线性插值
                start[i + k] = left + (right - left) * k / n
                end[i + k] = left + (right - left) * (k + 1) / n
            i = j
    clip = lambda x: float(min(max(x, 0.0), tail)) if tail > 0 else float(max(x, 0.0))
    return [{'word': off[i], 'start': clip(start[i]), 'end': clip(end[i])}
            for i in range(len(off))], matched / max(1, len(off))


def merge_by_span(frames, times, spans, step):
    """帧级特征按词元时间窗取均值，窗内无帧时取时间中点最近的那一帧。"""
    D = frames.shape[1]
    out = np.zeros((MAXLEN, D), np.float32); hit = np.zeros(MAXLEN, np.int32)
    if len(frames) == 0:
        return out, hit
    for k, (s, e) in enumerate(spans):
        m = (times >= s) & (times < max(e, s + step))
        if m.sum() == 0:
            j = int(np.argmin(np.abs(times - (s + e) / 2)))
            out[k] = frames[j]; hit[k] = 1
        else:
            out[k] = frames[m].mean(0); hit[k] = int(m.sum())
    return out, hit
```

D.2 问题二：文本的词元级重编码与分层融合

这段程序是问题二的主干。文本一侧在预训练语言模型上附加低秩增量，只训练注意力中 query 与 value 两处的增量；三条通道各自映射到同一宽度，加上位置标记与模态标记后先做模态内编码，再拼到一起做跨模态交互。空缺位置改用可学习的缺失词元填补；汇聚只在可用位置归一化，某条通道整条不可用时退回有效位置。缺失比例算出一并送入门控，最后按权重求和，给出强度与极性两个头。

```
# 本程序及代码是在人工智能工具辅助下完成的：DeepSeek V4.1-flash，深度求索
class LoraText(torch.nn.Module):
    """bert-base-uncased 加低秩增量，只训练注意力里 query 与 value 上的增量。"""
    def __init__(self, r, alpha):
        super().__init__()
        base = BertModel.from_pretrained(MODELS + '/bert-base-uncased')
        self.m = get_peft_model(base, LoraConfig(r=r, lora_alpha=alpha,
                lora_dropout=0.1, target_modules=['query', 'value'], bias='none'))

    def forward(self, tb):
        return self.m(input_ids=tb[:, 0], attention_mask=tb[:, 1],
                      token_type_ids=tb[:, 2]).last_hidden_state


class MSHF(nn.Module):
    """缺失感知融合：缺失词元替换、模态内编码、跨模态交互、
    按可用位置池化、平均融合与双头输出。"""
    def forward(self, b):
        valid = b['valid']; B, T = valid.shape
        seqs, keeps, miss_ratio = [], [], []
        for i, m in enumerate(MODS):
            miss = b['miss_' + m]
            h = self.proj[m](b[m])
            if self.use_miss_token: # 缺失位置换成可学习的缺失词元
                h = torch.where(miss.unsqueeze(-1), self.miss_tok[m].expand(B, T, -1), h)
            h = self.drop(h + self.pos_emb[:T] + self.mod_emb[i])
            h = self.intra[m](h, src_key_padding_mask=~valid)
            seqs.append(h); keeps.append(valid & ~miss)
            miss_ratio.append((miss & valid).float().sum(1) / valid.float().sum(1).clamp_min(1))
        x = self.cross(torch.cat(seqs, 1), src_key_padding_mask=~torch.cat([valid] * 3, 1))
        hs = x.split(T, 1)
        pooled = []
        for i, m in enumerate(MODS):
            keep = torch.where(keeps[i].any(1, keepdim=True), keeps[i], valid)
            p, _ = self.pool[m](hs[i], keep) # 只在可用位置上归一化
            pooled.append(p)
        if self.gate_mode == 'learned': # 缺失比例一并送进门控
            g = torch.softmax(self.gate(torch.cat(pooled + [torch.stack(miss_ratio, 1)], 1)), -1)
        else: # 平均融合，验证集选定的版本
            g = torch.full((B, 3), 1 / 3, device=x.device)
        fused = sum(g[:, i:i + 1] * pooled[i] for i in range(3))
        return {'reg': self.reg_head(fused).squeeze(-1), 'cls': self.cls_head(fused),
                'gate': g, 'fused': fused,
                'recon': {m: self.recon[m](hs[i]) for i, m in enumerate(MODS)}}
```

D.3 问题三：解释量的计算与删除对照

这段程序给出依据所在的位置。先做整段遮蔽，用遮蔽前后的预测之差衡量每条通道的必要性；再对输入求积分梯度，以零向量为基线，缺失标志保持不变。注意力与积分梯度各自归一化后相加，取分数最高的若干位置，首尾两个特殊记号排除在外。最后做删除对照，删掉得分最高的若干位置，再随机删掉同样多个，比较两次预测的偏移，两者之比即忠实性比值。

```
# 本程序及代码是在人工智能工具辅助下完成的：DeepSeek V4.1-flash，深度求索
def explain(T, d, ig_steps=32):
    o = run(T)
    occl = {} # 模态必要性：整段遮蔽前后的预测之差
    for m in MODS:
```

```
        Tm, _ = D.apply_missing(T, (m,), 1.0, 'start')
        occl[m] = run(Tm)['reg']
    ig = IntegratedGradients(fwd) # 零向量基线，缺失标志保持不变
    for i in range(0, N, 32):
        b = D.index(T, slice(i, i + 32))
        at = ig.attribute((b['text'], b['audio'], b['vision']),
                          baselines=tuple(torch.zeros_like(b[m]) for m in MODS),
                          additional_forward_args=(b['valid'], b['miss_text'],
                                                   b['miss_audio'], b['miss_vision']),
                          n_steps=ig_steps, internal_batch_size=32)
        ...


def top_positions(alpha, ig, k, exclude_special=True):
    """注意力与积分梯度各自归一化后相加，取前 k 个位置，排除首尾特殊记号。"""
    a = np.asarray(alpha); g = np.abs(np.asarray(ig))
    s = a / (a.max() + 1e-9) + g / (g.max() + 1e-9)
    if exclude_special and len(s) > 2:
        s[0] = -1; s[-1] = -1
    return [int(i) for i in np.argsort(-s)[:k]]


def faithfulness(T, k=3):
    """删去得分最高的 k 个位置与随机 k 个位置，比较预测偏移的绝对均值。"""
    evi, rnd = [], []
    for t in D.iter(T):
        c = card(t)
        for m in MODS:
            evi.append(abs(run(D.drop(t, m, top_positions(c['alpha'][m], c['ig'][m], k)))
                       - run(t)['reg']))
            rnd.append(abs(run(D.drop(t, m, D.random_positions(t, m, k))) - run(t)['reg']))
    return np.mean(evi) / np.mean(rnd)
```

D.4 问题一：三通道特征的提取

语音一路用 openSMILE 取 eGeMAPS 的 25 维低层描述子，再按 10 毫秒窗移补 20 维梅尔倒谱系数，拼成 45 维；视觉一路每 100 毫秒取一帧，先用 MTCNN 框出人脸并按边长外扩，长边不足 192 像素的放大到该尺寸，再送入面部网格模型，取 52 个表情系数，并由变换矩阵解出俯仰、偏航、翻滚三个姿态角，检出人脸时另置一位标志，合计 56 维。视觉帧的时刻取自解码器上报的呈现时间戳，不按帧号与标称帧率换算，少数容器元数据与内容不一致的样本因此不受影响。

```
# 本程序及代码是在人工智能工具辅助下完成的：DeepSeek V4.1-flash，深度求索
def audio_frames(wav):
    """10 ms 一帧：eGeMAPS 低层描述子 25 维 + MFCC 20 维 = 45 维。"""
    df = smile.process_file(wav)
    ege = df.values.astype(np.float32) # 10 ms 步长，窗长 20/60 ms
    t = np.asarray([x.total_seconds() for x in df.index.get_level_values('start')])
    y, sr = librosa.load(wav, sr=16000)
    mf = librosa.feature.mfcc(y=y, sr=sr, n_mfcc=20, n_fft=400, hop_length=160).T
    L = min(len(ege), len(mf))
    return np.nan_to_num(np.concatenate([ege[:L], mf[:L]], 1)), t[:L]


def vision_frames(mp4):
    """每 100 ms 取一帧：52 个表情系数 + 3 个姿态角 + 1 个人脸检出标志 = 56 维。

    时刻读解码器给出的呈现时间戳，不用帧号除以标称帧率。"""
    cap = cv2.VideoCapture(mp4); feats, times = [], []
    n = 0; next_t = 0.0; last_t = 0.0
    while True:
        if not cap.grab(): break
        t = cap.get(cv2.CAP_PROP_POS_MSEC) / 1000.0
        n += 1; last_t = max(last_t, t)
        if t + 1e-9 < next_t: continue
        ok, fr = cap.retrieve()
        if not ok: break
        rgb = cv2.cvtColor(fr, cv2.COLOR_BGR2RGB)
```

```
        res = None
        try:
            boxes, _ = mtcnn.detect(rgb)
            if boxes is not None: # 外扩一圈再放大到 192 像素长边
                x1, y1, x2, y2 = boxes[0]; bw, bh = x2 - x1, y2 - y1
                X1, Y1 = int(max(0, x1 - FACE_MARGIN * bw)), int(max(0, y1 - FACE_MARGIN * bh))
                X2, Y2 = int(min(rgb.shape[1], x2 + FACE_MARGIN * bw)), int(min(rgb.shape[0], y2 + FACE_MARGIN *
                     bh))
                crop = rgb[Y1:Y2, X1:X2]
                if crop.size and crop.shape[0] < FACE_MIN_SIDE:
                    f = FACE_MIN_SIDE / crop.shape[0]
                    crop = cv2.resize(crop, None, fx=f, fy=f, interpolation=cv2.INTER_CUBIC)
                if crop.size:
                    res = landmarker.detect(mp.Image(image_format=mp.ImageFormat.SRGB,
                                                     data=np.ascontiguousarray(crop)))
        except Exception:
            res = None
        row = np.zeros(56, np.float32)
        if res is not None and res.face_blendshapes:
            row[:52] = [c.score for c in res.face_blendshapes[0]]
            M = np.asarray(res.facial_transformation_matrixes[0])[:3, :3]
            sy = np.sqrt(M[0, 0] ** 2 + M[1, 0] ** 2) # 三个姿态角由旋转矩阵解出
            row[52] = np.arctan2(M[2, 1], M[2, 2])
            row[53] = np.arctan2(-M[2, 0], sy)
            row[54] = np.arctan2(M[1, 0], M[0, 0])
            row[55] = 1.0 # 人脸检出标志
        feats.append(row); times.append(t)
        next_t += VIS_STEP
    cap.release()
    fps_real = (n - 1) / last_t if last_t > 0 else 0.0
    return np.stack(feats) if feats else np.zeros((0, 56), np.float32), np.asarray(times), fps_real, n
```

D.5 问题二：四项损失与一轮训练

一批数据前向两次：完整视图给主任务与辅助任务两条损失，掩蔽视图在四项损失之外，另与完整视图的融合表示作一致性约束；两次前向的损失相加后一次反传。辅助任务只计入该通道还留有可用位置的那一份样本，整条被丢弃的通道不计入；重建只作用在人工制造缺失的位置上，目标是恢复这些位置的原始特征。

```
# 本程序及代码是在人工智能工具辅助下完成的：DeepSeek V4.1-flash，深度求索
def losses(out, b, art=None, ref=None):
    """四项损失：主任务、单模态辅助、重建、一致性。art 是人工掩蔽的位置。"""
    y = b['reg']; l = {}
    l['reg'] = F.l1_loss(out['reg'], y)
    l['cls'] = args.w_cls * F.cross_entropy(out['cls'], b['cls'])
    uni = 0 # 辅助损失只算还留着可用位置的样本
    for m in MODS:
        keep = (~b['miss_' + m] & b['valid']).any(1).float()
        uni = uni + (F.l1_loss(out['uni'][m], y, reduction='none') * keep).sum() / keep.sum().clamp_min(1)
    l['uni'] = args.w_uni * uni / 3
    if art is not None and ab != 'no_recon': # 重建只作用在人工掩蔽的位置上
        rec = 0; n = 0
        for m in MODS:
            a = art[m] & b['valid']
            if a.any():
                rec = rec + F.mse_loss(out['recon'][m][a], ref['orig_' + m][a]); n += 1
        l['rec'] = args.w_rec * (rec / max(n, 1))
    if ref is not None and ab != 'no_consist':
        l['con'] = args.w_con * F.mse_loss(out['fused'], ref['fused'].detach())
    return l


for b in loader: # 一轮训练里的一个批次
    bm = D.apply_missing(dict(b), ...) # 掩蔽视图：连续区段加整模态丢弃
    D._unk_text(bm, art) # 被掩蔽的词元改成未登录记号后重编
    out_full = model(encode(b, train=True)) # 完整视图
    out_m = model(encode(bm, train=True)) # 掩蔽视图
    ref = {'fused': out_full['fused']}
    ref.update({'orig_' + m: b[m].detach() for m in MODS})
```

```
    loss = sum(losses(out_full, b).values()) + sum(losses(out_m, bm, art, ref).values())
    opt.zero_grad(); loss.backward()
    torch.nn.utils.clip_grad_norm_(list(model.parameters()) + enc.trainable(), 1.0)
    opt.step()
```