






中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生数学建模竞赛

学　　校	
参赛队号	
队员姓名	1.
	2.
	3.

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生
数学建模竞赛

题　目： 基于质量增强广义标度律的大模型算力资源配置研究

摘　要：

大语言模型的能力取决于参数量 N、数据量 D、数据质量 Q 和领域配比 p 四种资源在有限算力下的分配。本文以交叉熵损失为共同度量，从质量与配比出发建立广义标度律，在算力约束下求解资源配置并识别结构性转移，最后用评测数据分离规模与技术进步的贡献并预测能力前沿。

基于题目给出的附件，先完成质量指标标量化与可信度分层，把数据分成真实观测、半合成、插值与估算四层，各层用途不同。

针对问题一，首先把 22 个质量指标中 8 个列表型指标压成标量并统一为越高越好，以熵权与 CRITIC 权的几何平均建立**组合权质量评价模型**，在 272,505 条全量记录上得到域级质量分，arxiv 最高为 0.666，github 最低为 0.442，抽样集与扩展集同域 KS 检验 p 值 0.717 与 0.174。然后把指标分为语义组与统计负面组，以两组同时落入极端分位定义冲突，抽样集 I 型冲突率 2.48%，扩展集 2.18%，建立**语义主裁的分层消解模型**，消解后排序 Spearman 0.983。最后以 **LightGBM 集成配比模型**刻画 17 域配比与 loss 的关系，1M 检验集 R^2 为 0.936，排序可传递到 60M 与 1B，Spearman 0.933 与 0.728，并发现附件外推表把配比排序翻转，得到最优配比 p^*。

针对问题二，首先用 Chinchilla 第三种方法在对数空间以 Huber 损失拟合经典标度律，得 E=1.690，A=406.2，α=0.340，B=410.9，β=0.280，跨族验证 Spearman 0.983。然后比较三种引入质量的形式，选定质量同时提高有效参数与有效数据的**双作用广义标度律**，γ_N=0.698，γ_D=0.606，配比项按 $(N/10^6)^{-0.171}$ 衰减，Q=1 时严格退化为经典形式。最后解析给出三个弹性，质量提升 0.1 等价于参数增加 1.20 到 1.36 倍，并识别出数学与问答文本互补、代码与长文本替代。

针对问题三，以 N、D、Q 为决策变量建立**算力约束资源配置模型**，用多起点 **SLSQP** 求解。10^{22} FLOPs 下最优为 N^*=5.58B，D^*=234B，Q^*=1，loss 2.157，比不投质量低 0.058。以活跃约束集变化定义结构性转移，幂函数成本下预算 4.0×10^{18} 与 6.3×10^{20} 处出现两次转移。解析得临界上下文长度 $L_{\mathrm{ctx}}^{\mathrm{crit}}=6/\eta$=30000，131072 时有效预算只剩 18.6%。

针对问题四，建立**规模与时间两因素分解模型**，前沿模型能力提升中技术进步贡献 115%，规模贡献 -54\%。以上限固定的 logistic 建立 **Loss 到 Benchmark 桥接模型**，误差 8 分。以累计前沿的 logit 趋势预测，算力放缓情景下对话模型 12 个月后前沿为 66 分，24 个月 78 分，90% 区间 72 到 83。

本文把四问串在交叉熵损失这一条线上：质量分与最优配比供问题二使用，广义标度律成为问题三的目标函数，问题三的最优损失经问题四的桥接译成榜单得分。质量同时作用在有效参数与有效数据上，取 1 时严格退化为经典形式；结构性转移有可计算的定义与两个连续指标。

关键词： 质量评价　广义标度律　算力约束　结构性转移　能力前沿预测

目录

一. 问题重述 3
1.1 问题背景 3
1.2 问题重述 3
二. 总体技术路线图 3
三. 基本假设与符号说明 4
3.1 模型假设 4
3.2 符号说明 4
四. 数据处理与分析 5
4.1 附件的读取与预处理 5
4.2 数据口径与质量信号机理 5
4.3 附件 B 的数据结构与可信度 6
五. 问题一：数据质量评价、冲突消解与领域配比模型 7
5.1 问题分析 7
5.2 质量评价与冲突消解模型 8
5.3 领域配比模型与最优配比 9
5.4 模型的求解与结果 10
5.5 本章小结 14
六. 问题二：质量与配比同时进入的广义标度律 14
6.1 问题分析 15
6.2 标度律机理与经典形式 15
6.3 广义标度律的建立 16
6.4 模型的求解与检验 18
6.5 本章小结 20
七. 问题三：算力约束下的资源配置与结构性转移 21
7.1 问题分析 21
7.2 算力开销结构的机理分析 22
7.3 算力约束资源配置模型 22
7.4 模型的求解与结果 23
7.5 参数灵敏度分析 27
7.6 本章小结 28
八. 问题四：规模与技术进步的分离及能力前沿预测 28
8.1 问题分析 28
8.2 前沿抬升的机理分析 29
8.3 口径、分解、桥接与预测模型 29
8.4 模型的求解与检验 31
8.5 本章小结 34
九. 模型评价 34
9.1 模型的优点 34
9.2 模型的缺点 34
9.3 模型的推广 34

一. 问题重述

1.1 问题背景

大语言模型的训练可以类比成培养学生：参数量是脑容量，数据量是阅读量，算力是教育经费，数据质量是教材质量，领域配比是课时分配。标度律给出损失随参数量与数据量按幂律下降的经验关系，但没有显式纳入数据质量与领域配比。随着干净语料日益稀缺，小模型靠高质量数据在若干任务上超过大模型的案例 [1] 说明质量与配比不可忽视。扩大规模、提升质量、延长上下文都要付出算力，四者之间存在取舍。如图 1 所示，本题把这四种资源与算力预算、损失和下游评测放在同一个框架里，附件 A 给出质量信号与配方实验，附件 B 给出训练轨迹与半合成质量实验，附件 C 给出评测榜单、桥接数据与架构元数据。

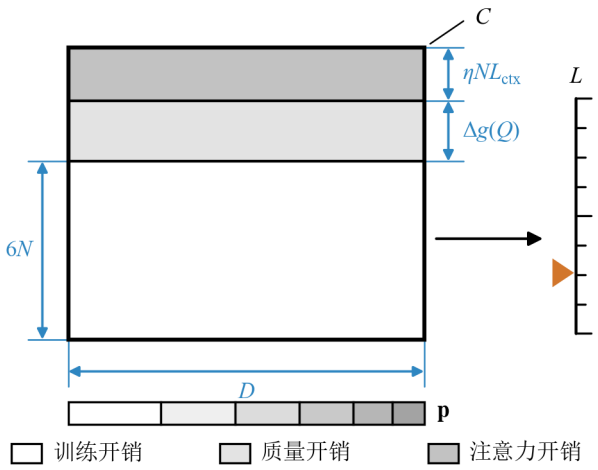


图 1 算力预算下四种资源的取舍关系

1.2 问题重述

在附件数据的基础上建立数学模型，完成四个递进的问题。

1. 用抽样集 A1 与扩展集 A2、A3 的全部记录建立质量评价模型，指标方向统一为越高越好，给出样本级与域级质量分 Q 并对照抽样集与全量结果；定义指标间的冲突并给出消解规则，在扩展集上检验；用 A4 到 A15 建立 17 域配比 $\boldsymbol{p}$ 与交叉熵损失的关系，在检验集上验证并讨论外推表的稳健性。
2. 以 B1 为主拟合经典标度律，用 B2 或 B3、B4、B5 验证；用 B6 到 B8 引入质量 Q，结合 B9、B10 讨论百亿参数以上的外推，建立同时含 N、D、Q、$\boldsymbol{p}$ 的广义标度律；分析边际效用、弹性、领域间替代与互补，推导质量与规模可相互替代的条件。
3. 总算力 C 由训练开销 $6ND$、质量提升开销 $D[g(Q)-g(Q_0)]_+$ 与注意力开销 ηNDL_{ctx} 三部分组成，$\eta = 2\times10^{-4}$，L_{ctx} 按 C7 外生给定。在 C 不超过预算的条件下求解资源配置，考察 10^{19}、10^{22}、10^{24} 三档预算，比较三种成本函数，给出结构性转移的数学定义与识别方法，解析给出 $L_{\mathrm{ctx}}^{\mathrm{crit}} = 6/\eta$ 并做敏感性分析。
4. 用附件 C 分离并量化规模扩张与非规模技术进步的贡献，在算力增长放缓情景下预测未来 12 与 24 个月开源模型的能力前沿并给出不确定性；说明综合能力度量、开源筛选口径、模型类型与时间轴口径；用桥接数据建立 Loss 与 Benchmark 的映射并讨论映射误差；对 C8 做至少一项逐任务聚合分析。

二. 总体技术路线图

四问的输入输出关系如图 2 所示，附件 A 经问题一得到 Q 与 $\boldsymbol{p}^*$，与附件 B 一起进入问题二的广义律，问题三在广义律上加算力约束，问题四用附件 C 把 loss 翻译成得分并预测前沿。

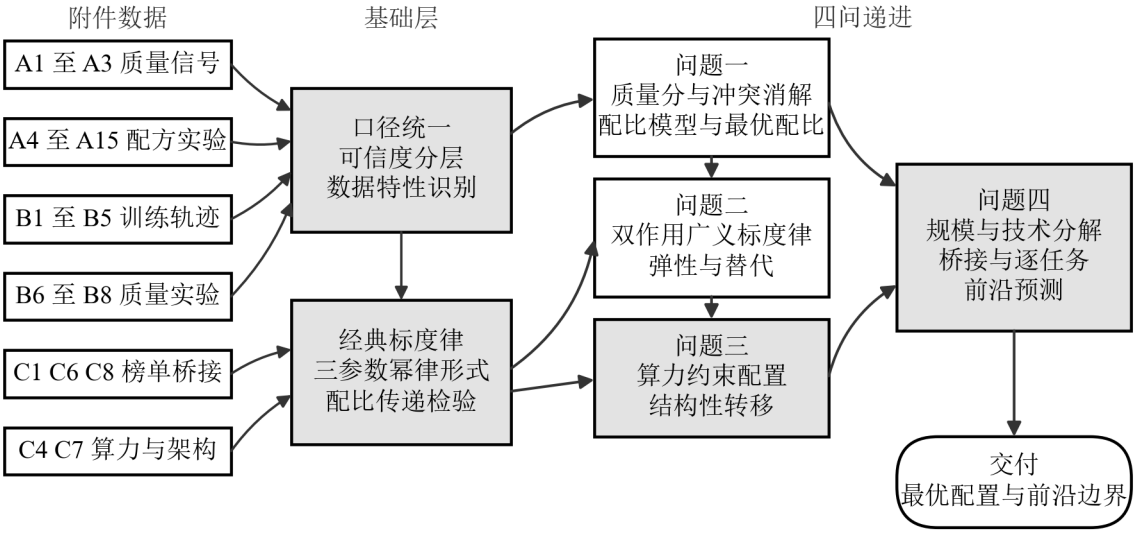


图 2　全文求解思路框架图

三.　基本假设与符号说明

3.1　模型假设

1. 附件 A 的质量信号抽样集能代表各域的质量分布，扩展集与抽样集同一口径。
2. 配比对 loss 的影响与模型规模可分离，配比效应随规模按幂律衰减。
3. 半合成数据 B6、B7 在 $Q = 1$ 处与真实训练轨迹口径一致，可与 B1 拼接；B8 因质量方向与 B6、B7 相反，只用于核对 N、D 方向。
4. 训练、质量处理与注意力计算使用同一批 token，L_{ctx} 外生给定，不作为寻优变量。
5. 榜单的六维平均分能代表综合能力，提交日期可作为模型出现的时间。
6. 未来两年技术进步速率与观测窗口内一致，算力放缓只影响规模项。

3.2　符号说明

符号	说明	单位
N	模型参数量	个
D	训练 token 数	个
Q	数据质量分	–
$\boldsymbol{p}$	17 域配比向量	–
L	验证集交叉熵损失	nat
E, A, α, B, β	经典标度律参数	–
γ_N, γ_D	质量的作用指数	–
ρ	配比效应衰减指数	–
C	总算力预算	FLOPs
$g(Q)$	质量提升成本函数	FLOPs
Q_0	基线质量	–
L_{ctx}	上下文窗口长度	token
η	注意力开销系数	–
ε_x	L 对 x 的弹性	–
S	榜单六维平均分	分
b_N, b_t	规模与时间系数	分

其它符号在文中具体说明。

四. 数据处理与分析

本章把三套附件读进来并统一口径，再按可信度给数据分层：真实观测用于拟合与检验，半合成只用来补真实数据里缺失的维度，插值与估算只用于核对自洽。后面各问只使用与其性质相称的那一层。

4.1 附件的读取与预处理

附件 A 的质量信号是 xz 压缩的 JSONL，抽样集 A1 共 51,230 条，按域分布为 c4、github、stackexchange、wikipedia 各 10,000 条，commoncrawl 9,640 条，arxiv 1,419 条，book 171 条；扩展集 A2 为 arxiv 域 17,523 条，A3 为 github 域 203,752 条，三者合计 272,505 条。读取用流式逐行解析，不把文件整体载入内存；content 字段只在核查评分可靠性时抽查原文，不参与统计。27 个字段里 22 个是质量指标，其中 8 个是分类器输出的 logit 列表，需要先压成标量，压缩规则见 5.2.1 节。扩展集没有 content 与来源域字段，来源域由文件名推断。

配方实验数据为成对的 CSV：A4 与 A5 是 512 组训练配比与对应 loss，A6 到 A11 是 1M、60M、1B 三个尺度的检验配比与 loss，其中 1M 与 60M 各 256 组，1B 为 64 组，A12 到 A15 是 10B 与 70B 的外推表，各 63 组。配比表有 17 个训练域列，每行之和为 1 并带千分位的舍入误差，本文按行重新归一化；loss 表有 13 个验证域列，nih_exporter、enron_emails、europarl 与 philpapers 只出现在配比侧，没有对应的验证 loss。这四个域仍作为输入特征保留，它们对 loss 的影响通过配比模型间接体现，不单独建目标。两张表按 index 列配对。

标量化与归一化的顺序是先压标量、再缩尾、再归一化。缩尾取抽样集的 1% 与 99% 分位数，目的是防止个别极端样本把归一化区间拉得过宽而让其余样本挤在一起；扩展集沿用抽样集的分位数边界，两套数据才在同一把尺子上。方向按指标的定义判定而不按统计相关判定：教育价值、流畅度、清洁度、可读性、推理性、专业性、qurater 与三个 DSIR 相似度越高越好，词数、句数、一元词熵、唯一词占比、句末标点行占比越高越好，广告概率、非字母词占比、2-gram 与 3-gram 重复占比、大写字母行占比、数字字符占比越低越好，平均词长以 5.5 为参考值取距离的相反数，离参考值越近越好。

4.2 数据口径与质量信号机理

三套附件相互独立，都以交叉熵损失或榜单得分为可观测量。按性质分成四层：真实观测有 A1 到 A11、B1、B4、B5、C1 到 C4、C7、C8；插值有 B3；半合成有 B2、B6 到 B8；估算有 A12 到 A15、B10。建模时真实观测用于拟合与检验，半合成只用于引入真实数据里缺失的维度，估算数据只用于讨论外推是否自洽，不作为观测。

三处数据特性影响后面的建模。B1 的 loss 列用经典标度律拟合 R^2 为 1.000，参数与 Hoffmann 等人 [2] 报告的 $E = 1.69$、$A = 406.4$、$\alpha = 0.34$、$B = 410.7$、$\beta = 0.28$ 一致，说明它是按该公式生成的，B10 同样如此。B8 中 Q 与 loss 的组内 Spearman 为 +0.992，与 B6、B7 的 −0.925 相反，且 loss 被截在 0.5，不能与 B6、B7 混用。A12 到 A15 的外推 loss 与同批配比在 1M 的实测 loss 呈负相关，说明附件的幂律外推翻转了配比排序。

质量信号来自 SlimPajama-Meta-rater[3]，22 个指标分三类：7 个语义打分器，包括教育价值 fineweb_edu[4]、流畅度、清洁度、可读性、推理性、专业性与 qurater 四维评分；3 个 DSIR 相似度，衡量文本与书籍、维基、数学语料的接近程度；12 个统计特征，来自 RedPajama 沿用的 Gopher 过滤规则 [5]，包括词数、句数、一元词熵、唯一词占比、非字母词占比、2-gram 与 3-gram 重复字符占比、大写字母行占比、句末标点行占比、数字字符占比、平均词长与广告概率。

同一篇文本上，语义打分器与统计特征可能给出相反的判断，如图 3 所示。图 3(a) 是学术文本，语义得分高，但公式与符号推高了数字字符和非字母词占比，统计组判为低质；图 3(b) 是两组一致的普通网页；图 3(c) 是目录页或问答页，结构干净但语义空洞。冲突不是指标出错，而是统计特征测的是形式，语义打分器测的是内容，两者在特定文体上分离。消解规则因此以语义组为主裁。

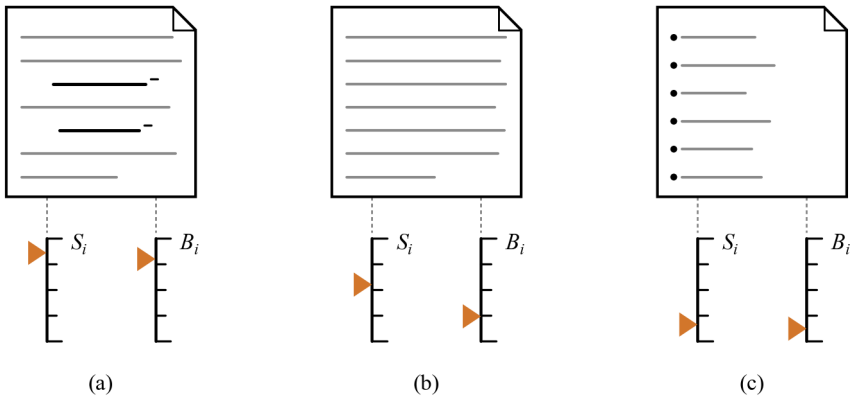


图 3　语义组与统计组的三种关系：(a) I 型冲突；(b) 一致；(c) II 型冲突

配方实验来自 RegMix[6]，如图 4 所示，512 个随机配比在 1M 参数的小模型上训练，得到 13 个验证域的 loss；同一批检验配比又在 1M、60M 与 1B 三个尺度训练。小尺度上学到的配比排序能否传到大尺度，是配比模型能否用于问题三的关键。

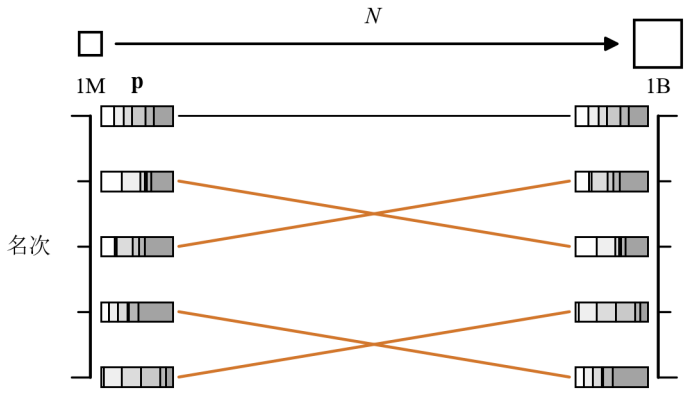


图 4　配方实验的跨尺度传递

4.3　附件 B 的数据结构与可信度

附件 B 共 12 个文件，按性质分三层。真实观测层是 B1、B4、B5 与三份元数据。B1 是 Pythia 套件 [12]8 个模型的训练日志，参数量为 70M、160M、410M、1.0B、1.4B、2.8B、6.9B 与 12B，每个模型 147 个检查点，训练 token 数从 0.13B 到 300B，验证 loss 从 4.74 降到 2.09，共 1176 行，每行还带累计算力、步数、学习率与梯度范数；数据说明给出累计算力与 $6ND$ 的中位比值约为 1，与本文采用的算力近似一致。B4 是 12 个模型族的 57 个收敛点，Pythia 8 个，Qwen2、Cerebras-GPT 与 OPT 各 7 个，Phi 与 LLaMA 各 6 个，BLOOM 与 GPT2 各 4 个，Gemma 3 个，Falcon 与 Yi 各 2 个，Mistral 1 个，参数量从 70M 到 72B。B5 是文献里整理的 44 个标度律基准点，参数量到 280B。B9 是 132 个百亿参数以上开源模型的缩放参数，B11 是 18 个模型族的仓库元数据，B12 是 1386 条 Pythia 检查点索引。

半合成层是 B2 与 B6 到 B8。B2 是按 Pythia 标度律和 Cerebras-GPT 的公开训练设定校准并叠加噪声生成的 7 条轨迹，共 1029 行。B6 是 N、D、Q 三维的半合成实验，9 个参数量从 70M 到 11.97B，5 个数据量 10B、50B、150B、300B 与 600B，8 个质量档从 0.1 到 1.0，合计 360 点；B7 在同一网格上扩展到 450 点；B8 是 1704 点的大规模矩阵，参数量外推到 700B。插值层是 B3，由 B1 的检查点插值出 8 条各 500 点的轨迹；估算层是 B10，用已拟合的标度律参数对 B9 里的 128 个大模型估算 loss。

这三层的用途不同。经典律的五个参数只用真实观测层拟合，半合成层只用来引入真实数据里没有的质量维度，插值层与估算层只用来检查自洽，不参与拟合，也不作为观测证据。用之前先核对三件事：B1 的 loss 精确等于 Chinchilla 公式的取值，说明它是公式生成的，这不影响用它估计经典参数，但意味着参数的不确定性不能从残差估计；B6 与 B7 在 $Q = 1$ 处与 B1 的经典律吻合，均值偏差 0.004，两套数据可以拼接；B8 里 Q 与 loss 的组内 Spearman 为 +0.992，与 B6、B7 的 −0.925 方向相反，且 loss 被截断在 0.5，它只能用 $Q = 1$ 的子集核对 N、D 的方向，不能与 B6、B7 混用。

五. 问题一：数据质量评价、冲突消解与领域配比模型

本章针对问题一展开，先把 22 个质量指标压成一把可比的尺子，再处理内容与形式两类指标的冲突，最后把 17 个训练域的配比与交叉熵损失的关系定量化，输出质量分 Q 与最优配比 $\boldsymbol{p}^*$，供后面两问使用。

5.1 问题分析

问题一：数据质量评价、冲突消解与领域配比模型

问题一要求用质量信号的抽样集 A1 与扩展集 A2、A3 建立质量评价模型，给出样本级与领域级质量分，并对照抽样集与全量的结论；定义指标之间的冲突并给出消解规则，在扩展集上检验；再用配方实验 A4 到 A15 建立 17 个训练域的配比与交叉熵损失之间的关系，在检验集上验证，并讨论外推表是否可信。

这一问含有三个子问题，先对它们做步骤拆分。

子问题一：把 22 个指标压成一把可比的尺子——立尺子

1）8 个 logit 列表型指标按各自含义压成标量，方向按指标定义统一为越高越好；2）缩尾与归一化的分位数边界只从抽样集求，扩展集沿用同一把尺子；3）熵权与 CRITIC 权取几何平均得到组合权，样本级质量分取加权和，域级质量分取域内中位数。

子问题二：处理内容与形式两类指标的冲突——定主裁

1）按看内容的语义组与看形式的统计负面组划分指标；2）两组同时落入极端分位记为冲突，分 I 型与 II 型两类；3）冲突样本上把负面组的权重减半，按比例转给语义组；4）在扩展集上复核冲突率，并比较消解前后排序是否稳定。

子问题三：把配比与损失的关系定量化——建回归

1）17 域配比做中心对数比变换，消掉单纯形约束；2）比较线性与树集成两类回归，选定树集成的 LightGBM；3）在 1M、60M、1B 三套检验集上看绝对精度与排序能否传递；4）用 Dirichlet 采样求最优配比 $\boldsymbol{p}^*$，并核对附件外推表能否作为大尺度的依据。

问题一的求解路线如图 5 所示，从质量信号的标量化开始，经权重合成、冲突消解得到域级 Q，再用配方实验建立配比模型并求最优配比。

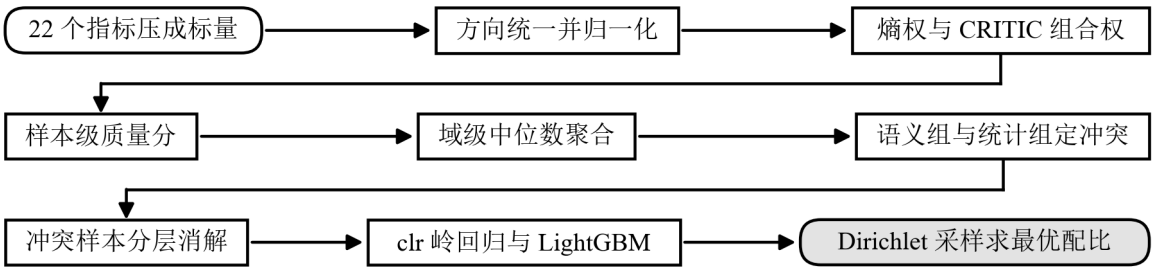


图 5 问题一思路框架图

组合权质量评价模型：把 22 个指标压成标量并统一方向后，用熵权刻画每个指标把样本拉开的能力，用 CRITIC 权刻画它与其它指标之间的独立性，两者取几何平均得到组合权，样本级质量分是指标的加权和，域级质量分取域内中位数。这样做的理由是单一权重

会被个别指标带偏：广告概率这一项在熵权下独占四成权重，在 CRITIC 权下只占百分之四，几何平均把它压回到 0.162，既保留了它的区分度，也不让一项指标决定评分。

语义主裁的分层消解模型：把指标分成看内容的语义组和看形式的统计负面组，两组同时落入极端分位记为冲突，冲突样本上把负面组的权重减半并转给语义组，其余样本不动。语义组由七个打分器构成，测的是文本讲了什么；统计组来自 Gopher 过滤规则，测的是文本长什么样。公式多、符号多的学术文本在两组上必然分离，以语义组为主裁符合训练语料筛选的实际做法。

LightGBM 集成配比模型：以 17 域配比为输入、13 个验证域 loss 的均值为输出建立回归，单纯形约束用中心对数比变换化解，三个随机种子的 LightGBM 取平均以压低单个树模型的方差。模型在 1M 检验集上看绝对精度，在 60M 与 1B 上看排序传递，再以训练配比均值为中心做 Dirichlet 采样搜最优配比，取预测最小的 128 个配比的平均作为 $\boldsymbol{p}^{*}$，不把代理模型平台上的某一个点当成最优。

5.2 质量评价与冲突消解模型

5.2.1 质量指标的标量化与方向统一

记第 i 条记录第 j 个指标的原始值为 v_{ij}。列表型指标压成标量：fineweb_edu 取唯一分量；fluency_en 与 ad_en 是二分类 logit，取正类 softmax 概率；qurater 四维取均值；四个 modernbert 指标是六级分类 logit，取期望等级 $\sum_{k=0}^{5} k\,\mathrm{softmax}_k$。词数与句数取 $\log(1+v)$，平均词长取与参考值 5.5 的距离的相反数。每个指标以抽样集 1% 与 99% 分位数 a_j、b_j 缩尾后 Min-Max 归一化，负向指标取补：

$$x_{ij}=\begin{cases}\dfrac{\min(\max(v_{ij},a_j),b_j)-a_j}{b_j-a_j}, & \text{正向指标,}\\[2ex] 1-\dfrac{\min(\max(v_{ij},a_j),b_j)-a_j}{b_j-a_j}, & \text{负向指标.}\end{cases}\tag{1}$$

负向指标是广告概率、2-gram 与 3-gram 重复占比、非字母词占比、数字字符占比、大写字母行占比，其余为正向。扩展集沿用抽样集的 a_j、b_j。缩尾、归一化与取补的做法如图 6 所示，落在分位数边界之外的值先被拉回边界，再映射到 0 到 1 之间，负向指标的映射方向反过来，映射线交叉。

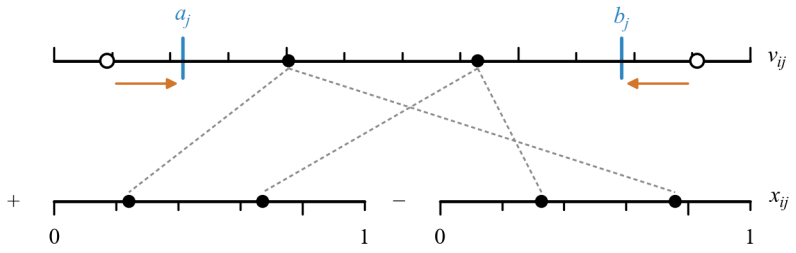


图 6 质量指标的缩尾、归一化与方向统一

5.2.2 组合权质量评价模型

熵权 w_j^{E} 反映指标的区分度，CRITIC 权 w_j^{C}[7] 同时看标准差与指标间的冲突性。记 $p_{ij}=x_{ij}/\sum_i x_{ij}$，$e_j=-\frac{1}{\ln n}\sum_i p_{ij}\ln p_{ij}$，$r_{jk}$ 为指标 j 与 k 的相关系数，σ_j 为标准差，则

$$w_j^{E}=\frac{1-e_j}{\sum_k(1-e_k)},\qquad w_j^{C}=\frac{\sigma_j\sum_k(1-r_{jk})}{\sum_l\sigma_l\sum_k(1-r_{lk})}.\tag{2}$$

综上所述，最终得到组合权质量评价模型为

$$\begin{cases} w_j = \dfrac{\sqrt{w_j^{E} w_j^{C}}}{\sum_{k} \sqrt{w_k^{E} w_k^{C}}}, \\ Q_i = \sum_{j=1}^{22} w_j x_{ij}, \\ Q_d = \operatorname{median}\{Q_i : i \in d\}, \end{cases} \tag{3}$$

Q_d 为域级质量分，取域内中位数，抗离群。

三种权重各有偏向。熵权只看一个指标能不能把样本拉开，广告概率的取值接近两端，区分度最大，熵权给了它 0.424，其余指标都在 0.1 以下；CRITIC 权把标准差与指标间的独立性相乘，广告概率与别的指标相关性弱但标准差不大，权重降到 0.044，三个 DSIR 相似度因为彼此高度相关而被压到 0.032。几何平均取两者的折中，广告概率 0.162，专业性 0.107，推理性 0.067，DSIR 三项 0.015，既不让一项指标独大，也不把区分度最强的指标抹平。主成分评分作对照，前三个主成分的方差贡献率为 27.5%、21.8% 与 9.7%，第一主成分的载荷集中在清洁度、可读性、推理性与流畅度上，与语义组的构成一致。

5.2.3 冲突定义与分层消解模型

把指标分成语义组 S 与统计负面组 B，S 含教育价值、qurater、清洁度、可读性、推理性、专业性、流畅度，B 含广告概率、2-gram 与 3-gram 重复占比、非字母词占比、数字字符占比、大写占比。记 $S_i = \frac{1}{|S|}\sum_{j\in S} x_{ij}$ 为语义得分，$B_i = 1 - \frac{1}{|B|}\sum_{j\in B} x_{ij}$ 为负面强度，S_q、B_q 为 q 分位数，则冲突定义为

$$\text{I 型：}\ S_i \ge S_{0.8} \wedge B_i \ge B_{0.8}; \qquad \text{II 型：}\ S_i \le S_{0.2} \wedge B_i \le B_{0.2}. \tag{4}$$

消解规则以语义组为主裁，冲突样本上把负面组权重减半，减掉的权重按比例转给语义组，综上所述得到分层消解模型

$$Q_i^{r} = \begin{cases} \displaystyle\sum_{j\in B} \tfrac{1}{2} w_j x_{ij} + \sum_{j\in S} \Big(w_j + \frac{w_j}{\sum_{k\in S} w_k} \cdot \frac{1}{2} \sum_{k\in B} w_k \Big) x_{ij} + \sum_{j\notin S\cup B} w_j x_{ij}, & i \text{ 为冲突样本}, \\ Q_i, & \text{否则}. \end{cases} \tag{5}$$

5.3 领域配比模型与最优配比

以 17 域配比 $\boldsymbol{p}$ 为自变量，13 个验证域 loss 的均值 $\bar{L}$ 为因变量。配比是成分数据，17 个分量之和恒为 1，直接把分量当自变量会带来完全共线，某一个域增加必然意味着别的域减少，回归系数没有单独的含义。单纯形约束用中心对数比变换 [8] 处理，$\operatorname{clr}(\boldsymbol{p})_i = \ln(p_i + \epsilon) - \frac{1}{17}\sum_k \ln(p_k + \epsilon)$，$\epsilon = 10^{-4}$ 用来处理为零的分量。变换后的 17 个坐标之和为零，落在一个 16 维的超平面上，线性模型与树模型都能直接使用。如图 7 所示，配比落在单纯形上，中心对数比把它映到与全 1 向量正交的超平面上，图中以三个域为例，到三条边的距离就是三个分量。

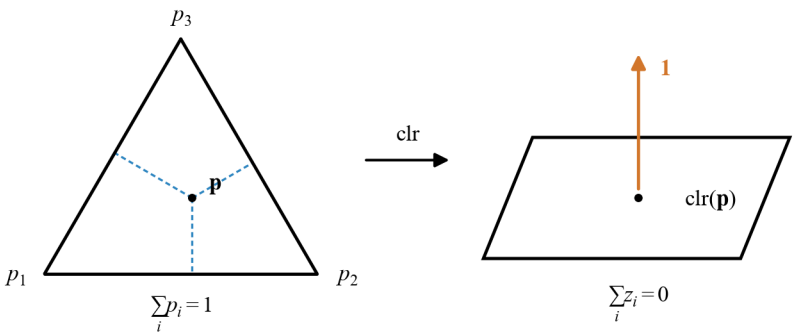


图 7 单纯形上的配比与中心对数比变换

对照 clr 岭回归与 LightGBM[9] 三种子集成，主用后者。LightGBM 的设置为学习率 0.02，1500 棵树，每棵树最多 8 个叶子，叶子最少 5 个样本，行采样与列采样各 0.8，L2 正则 1，三个随机种子的模型取平均；13 个验证域各建一个模型，再建一个均值模型，共 14 个目标，超参数用 5 折交叉验证选定，领域重要性用 20 次置换估计。最优配比按 RegMix 的做法，以训练配比均值 $\bar{\boldsymbol{p}}$ 为 Dirichlet 中心采样 3×10^5 个候选，取预测最小的 128 个求平均。综上所述，配比模型与最优配比为

$$\begin{cases} \hat{\bar{L}}(\boldsymbol{p}) = \dfrac{1}{3}\sum_{s=1}^{3} f_{\mathrm{LGB}}^{(s)}(\boldsymbol{p}), \\ \boldsymbol{p}^{*} = \dfrac{1}{128}\sum_{\boldsymbol{p}\in\mathcal{T}_{128}} \boldsymbol{p}, \quad \mathcal{T}_{128} = \arg\min_{|\mathcal{T}|=128} \sum_{\boldsymbol{p}\in\mathcal{T}} \hat{\bar{L}}(\boldsymbol{p}), \\ \boldsymbol{p} \sim \mathrm{Dirichlet}(s\bar{\boldsymbol{p}}),\ s\in\{0.5,1,2\}, \quad p_i \ge 0,\ \sum_i p_i = 1. \end{cases} \tag{6}$$

5.4 模型的求解与结果

5.4.1 质量评价结果

22 个指标的类别、方向与三种权重见表 1。组合权前五位是广告概率 0.162、专业性 0.107、推理性 0.067、句末标点行占比 0.064、清洁度 0.053，三个 DSIR 指标最低，约 0.015。组合权评分与熵权、CRITIC、PCA 第一主成分评分的 Spearman 分别为 0.940、0.962、0.889，四种方案给出的域级排序完全一致，权重方案稳健。

表 1　22 个质量指标的类别、方向与权重

指标	类别	方向	熵权	CRITIC 权	组合权
教育价值 fineweb_edu	语义	+	0.036	0.040	0.045
流畅度 fluency_en	语义	+	0.032	0.060	0.052
清洁度 cleanliness	语义	+	0.037	0.055	0.053
可读性 readability	语义	+	0.030	0.052	0.047
推理性 reasoning	语义	+	0.065	0.050	0.067
专业性 professionalism	语义	+	0.096	0.086	0.107
四维评分 qurater	语义	+	0.032	0.038	0.041
书籍相似度 dsir_books	相似度	+	0.005	0.032	0.015
维基相似度 dsir_wiki	相似度	+	0.005	0.032	0.014
数学相似度 dsir_math	相似度	+	0.005	0.033	0.015
广告概率 ad_en	统计	−	0.424	0.044	0.162
词数	统计	+	0.027	0.038	0.038
句数	统计	+	0.037	0.044	0.048
一元词熵	统计	+	0.020	0.038	0.033
唯一词占比	统计	+	0.027	0.052	0.044
非字母词占比	统计	−	0.008	0.034	0.020
2-gram 重复占比	统计	−	0.009	0.037	0.022
3-gram 重复占比	统计	−	0.008	0.037	0.021
大写字母行占比	统计	−	0.033	0.059	0.052
句末标点行占比	统计	+	0.047	0.062	0.064
数字字符占比	统计	−	0.008	0.039	0.021
平均词长	统计	距参考值	0.008	0.036	0.021

全量 272,505 条记录的域级质量分见表 2。arxiv 的中位数 0.666 最高且分布最集中，四分位距只有 0.03；github 与 wikipedia 最低，中位数 0.442 与 0.433。github 低是因为代码文本的非字母词、数字字符与重复片段多，统计组整体判低；wikipedia 低则来自抽样里大量的短条目与非英文残片，语义组与统计组都不高。抽样集与扩展集在 arxiv 与 github 两域

的 KS 检验 p 值为 0.717 与 0.174，均值只差 0.001 以内，分布无显著差异，抽样集能代表全量。全量样本级质量分的均值为 0.503，标准差 0.095，5% 与 95% 分位为 0.349 与 0.668，这个均值就是问题三基线质量 Q_0 的取值。原文抽查显示低分文本是 LaTeX 宏定义、商品标题堆砌、非英文维基残片与单行 HTML，高分文本是论文引言、教程与百科正文，评分与 qurater 的 Spearman 为 0.719，与教育价值为 0.501，评分可靠。

表 2　域级质量评分

质量域	记录数	全量 Q 中位数	抽样集中位数	扩展集中位数
arxiv	18,942	0.666	0.666	0.666
c4	10,000	0.551	0.551	–
commoncrawl	9,640	0.536	0.536	–
book	171	0.525	0.525	–
stackexchange	10,000	0.525	0.525	–
github	213,752	0.442	0.443	0.442
wikipedia	10,000	0.433	0.433	–

5.4.2　冲突消解结果

各域的冲突率见表 3。抽样集 I 型冲突率 2.48%，II 型 3.54%，教育价值高且广告概率高的样本占 5.97%，语义与负面 z 分数之差超过 1.5 的宽口径占 31.3%；扩展集对应为 2.18%、5.11%、5.68%、24.9%，主要结论在扩展集上成立。冲突在域之间的分布很不均匀。arxiv 的宽口径冲突率达 91%，扩展集上更到 96%，几乎每一篇论文都被统计组判低，来源是公式与符号推高了非字母词与数字字符占比；stackexchange 与 book 的 I 型冲突率约 10%，来自问答帖与目录页；c4 的 II 型冲突率 13.6% 是各域最高，网页里大量格式干净但内容空洞的商品列表与导航页被语义组判低。语义组与负面组的 Spearman 为 −0.13，两组近乎独立，说明冲突不是随机噪声，而是统计指标对特定文体的系统性误判。消解后评分与原评分的 Spearman 为 0.983，冲突样本平均变动 0.066，arxiv 的域级中位数从 0.666 微升到 0.669，其余域变动都在 0.01 以内，消解只修正冲突样本，不扰动整体排序。

表 3　各域的冲突率（%）

数据集	域	I 型冲突	II 型冲突	教育价值高且广告高	宽口径
抽样集	arxiv	5.1	0.0	28.5	91.5
抽样集	book	10.5	0.0	4.1	9.9
抽样集	c4	0.1	13.6	3.1	38.8
抽样集	commoncrawl	0.3	3.0	3.0	32.1
抽样集	github	0.3	1.4	0.9	24.5
抽样集	stackexchange	9.8	0.0	10.5	13.3
抽样集	wikipedia	1.4	0.3	9.2	39.9
抽样集	全部	2.48	3.54	5.97	31.3
扩展集	arxiv	5.9	0.0	40.4	95.7
扩展集	github	1.9	5.6	2.7	18.8
扩展集	全部	2.18	5.11	5.68	24.9

5.4.3　配比模型的求解与多算法对比

六种回归器在训练集 5 折交叉验证与三套检验集上的表现见表 4。线性类的 clr 岭回归交叉验证 R^2 只有 0.195，支持向量回归 0.536，多层感知机在 512 个样本上过拟合，R^2 为负；三种树集成都在 0.79 以上，说明配比与 loss 的关系强非线性，各域之间存在交互。

LightGBM[9] 的交叉验证 R^2 0.929 与 1M 检验 R^2 0.936 都是最高，60M 上的排序传递与梯度提升树持平，1B 上略低 0.002，差别在千分位；它的训练用时最长，70 秒对梯度提升树的 2.3 秒，因为用了 1500 棵树与三个种子的集成，这个开销在可接受范围内。综合精度取 LightGBM，随机森林 [10] 与梯度提升树作为对照保留。

表 4　配比回归器的多算法对比（目标为 13 域平均 loss）

指标	岭回归	随机森林	梯度提升树	SVR	MLP	**LightGBM**
5 折 CV R^2	0.195	0.787	0.914	0.536	−1.270	0.929
1M 检验 R^2	0.192	0.784	0.925	0.657	−1.407	0.936
60M 检验 Spearman	0.424	0.836	0.933	0.742	0.467	0.933
1B 检验 Spearman	0.667	0.692	0.726	0.652	0.396	0.724
训练用时 / s	0.04	1.6	2.3	0.08	11.0	70.4

最优配比的搜索比较了 Dirichlet 采样、SLSQP 多起点、差分进化 [11] 与模拟退火四种方法，各跑 10 次，见表 5。差分进化与模拟退火找到的代理值更低，为 4.683 与 4.699，Dirichlet 采样为 4.777，但三者之差不到 0.1，与配比模型在检验集上 1.06% 的 MAPE 相当，在代理模型的分辨率之内。看解落在哪里才能分出好坏：Dirichlet 采样取预测最小的 128 个候选的平均，到训练配比分布的马氏距离为 2.04，低于训练集自身的中位数 3.86，是训练分布内部的一个平滑解；差分进化与模拟退火各自停在一个点上，马氏距离 4.13 与 4.00，靠近训练集的 95% 分位 5.63，处在代理模型外推的边缘，模拟退火的解还把两个域压到了零。SLSQP 多起点在分段常值的预测面上几乎不动，停在 5.03 到 5.21 的平台上。树模型在训练分布之外的预测不可信，本文因此取 Dirichlet 采样的均值解作为 $\boldsymbol{p}^*$；表中一列是与其它方法同等评估次数下的重复试验，正文求 $\boldsymbol{p}^*$ 用 3×10^5 次采样，预测 loss 为 4.748。

表 5　最优配比搜索的多算法对比（10 次运行）

指标	**Dirichlet 采样**	SLSQP 多起点	差分进化	模拟退火
最小 $\hat{\bar{L}}$	4.777	5.028	4.683	4.699
10 次均值	4.796	5.137	4.694	4.702
10 次极差	0.034	0.180	0.015	0.007
单次用时 / s	2.3	0.5	2.1	2.5
解到训练分布的马氏距离	2.04	–	4.13	4.00
解中最大单域占比	0.151	–	0.144	0.157
解中为零的域数	1	–	0	2

5.4.4　配比模型的检验与结果

配比模型的检验结果如图 8 所示。图 8(a) 是七个质量域的分位数，arxiv 集中且最高，github 与 wikipedia 最低；图 8(b) 是 1M 检验集上预测与实测的对照，256 组配比贴在对角线附近，R^2 为 0.936，MAPE 1.06%；图 8(c) 是六个重要域的边际效应曲线，以训练均值配比为基准把某一域的占比提到横轴的值，stackexchange 与 dm_mathematics 提高到 0.3 以内 loss 单调下降，github 与 pile_cc 过了 0.15 后反而上升。

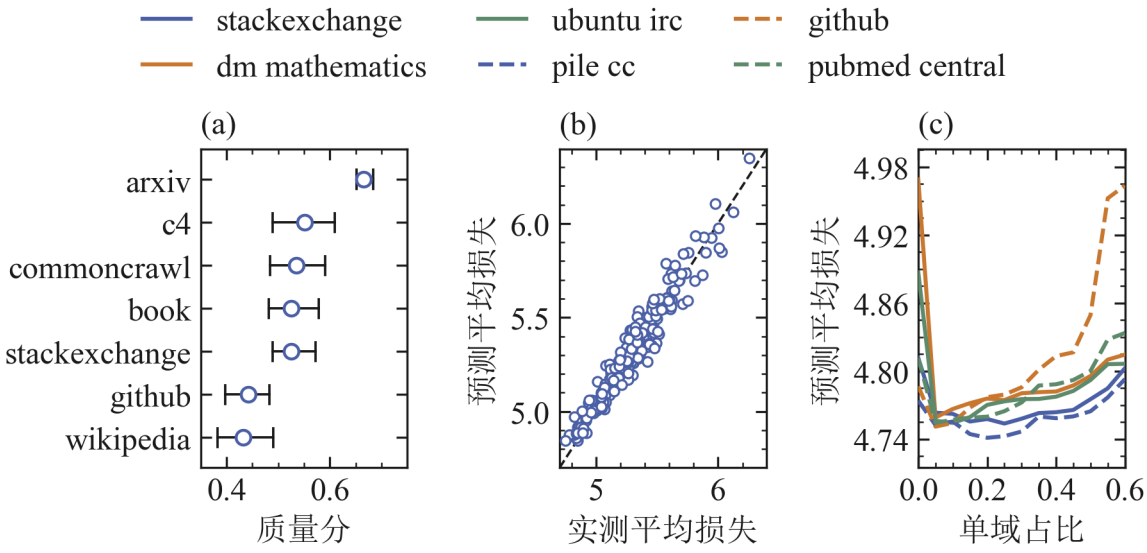


图 8　问题一结果：(a) 域级质量分位数；(b) 1M 检验集预测对照；(c) 领域边际效应

60M 与 1B 是更大的模型，loss 绝对值不同，看排序传递：Spearman 为 0.933 与 0.728，逐域 Spearman 在 1B 仍为 0.86 到 0.99，配比优劣可跨尺度传递，与 RegMix 论文的结论一致。逐个验证域的表现见表 6，各验证域最偏好的训练域见表 7。13 个域在 1M 检验集上的 R^2 都在 0.97 以上，MAPE 在 0.6% 到 3.0% 之间，dm_mathematics 的 MAPE 最大，因为数学文本的 loss 对配比最敏感，取值范围也最宽。到 1B 时排序传递最好的是 stackexchange、uspto_backgrounds、arxiv 与 github，Spearman 都在 0.98 以上，最差的是 hackernews 与 ubuntu_irc，为 0.86 与 0.87，这两个域的验证 loss 在 1B 上的离散度小，排序本身就不稳。平均 loss 的传递 0.728 低于逐域的值，因为 13 个域的平均把各域相反方向的变化互相抵消了一部分。每个验证域最偏好的训练域是同名域，其次是同类域，例如 pubmed_central 的验证 loss 最受 pubmed_central、pubmed_abstracts 与 arxiv 三个训练域影响，github 最受 github、stackexchange 与 ubuntu_irc 影响，代码与技术问答互相支撑。外推表 A12 到 A15 的 $\bar{L}$ 与同

表 6　配比模型在 13 个验证域上的检验

验证域	1M R^2	1M MAPE / %	60M Spearman	1B Spearman
arxiv	0.971	1.38	0.990	0.985
freelaw	0.995	0.74	0.996	0.982
pubmed_central	0.985	1.52	0.985	0.959
wikipedia_en	0.987	0.77	0.993	0.981
dm_mathematics	0.978	2.99	0.956	0.928
github	0.987	1.41	0.989	0.983
stackexchange	0.991	0.89	0.995	0.989
gutenberg_pg_19	0.980	0.79	0.990	0.939
pile_cc	0.981	0.56	0.988	0.956
ubuntu_irc	0.980	1.47	0.958	0.872
hackernews	0.976	0.71	0.983	0.861
pubmed_abstracts	0.989	0.81	0.994	0.941
uspto_backgrounds	0.992	0.64	0.989	0.989
13 域平均	0.936	1.06	0.933	0.728

批配比在 1M 的实测 loss 呈负相关，10B 为 −0.739，70B 为 −0.814，模型预测与外推表的

表 7　各验证域最偏好的三个训练域

验证域	最偏好的训练域
arxiv	arxiv，stackexchange，pubmed_central
freelaw	freelaw，pile_cc，wikipedia_en
pubmed_central	pubmed_central，pubmed_abstracts，arxiv
wikipedia_en	wikipedia_en，pile_cc，gutenberg_pg_19
dm_mathematics	dm_mathematics，ubuntu_irc，stackexchange
github	github，stackexchange，ubuntu_irc
stackexchange	stackexchange，github，ubuntu_irc
gutenberg_pg_19	gutenberg_pg_19，pile_cc，freelaw
pile_cc	pile_cc，wikipedia_en，ubuntu_irc
ubuntu_irc	ubuntu_irc，europarl，stackexchange
hackernews	hackernews，pile_cc，stackexchange
pubmed_abstracts	pubmed_abstracts，pubmed_central，uspto_backgrounds
uspto_backgrounds	uspto_backgrounds，pubmed_abstracts，pile_cc

Spearman 同样为负。附件的幂律外推把配比排序翻转了，与 1B 实测 0.73 的正向传递矛盾，外推表不能作为大尺度配比的依据，本文以 1B 实测作为传递的证据。

领域效应上，置换重要性前五为 stackexchange 0.251、dm_mathematics 0.221、ubuntu_irc 0.108、pile_cc 0.105、github 0.103；岭回归系数为负即多配降 loss 的是 ubuntu_irc、dm_mathematics、stackexchange，为正的是 enron_emails、philpapers、nih_exporter。每个验证域最偏好的训练域是同名域，其次是同类域。最优配比 $\boldsymbol{p}^*$ 为 stackexchange 0.151、pile_cc 0.125、pubmed_central 0.116、wikipedia_en 0.085、ubuntu_irc 0.085、freelaw 0.078、dm_mathematics 0.071、arxiv 0.062、pubmed_abstracts 0.059、github 0.054、uspto_backgrounds 0.052、gutenberg_pg_19 0.032、hackernews 0.016、europarl 0.007、nih_exporter 0.003、philpapers 0.002、enron_emails 0，预测 $\bar{L}(\boldsymbol{p}^*) = 4.748$，训练均值配比 4.762，均匀配比 4.762，训练集实测最优 4.753。

质量评分不引入配比模型。按 A16 把 17 域映射到质量域后，配比加权质量 $Q_{\text{mix}}(\boldsymbol{p}) = \sum_i p_i Q_{d(i)}$ 与 $\bar{L}$ 的 Spearman 在训练集、1M、60M、1B 上分别为 −0.02、−0.12、−0.10、+0.29，方向不稳；加入 Q_{mix} 特征后交叉验证 R^2 由 0.9289 变为 0.9288。原因是 RegMix 实验固定各域语料只改配比，域级 Q 是常数，与 $\boldsymbol{p}$ 线性相关，不含新信息。质量的作用在问题二用附件 B 引入，$\boldsymbol{p}^*$ 对应 $Q_{\text{mix}} = 0.558$，作为参考。

5.5　本章小结

本章把 22 个质量指标压成标量并统一方向，用熵权与 CRITIC 的组合权得到样本级与域级质量分，全量 272,505 条记录上 arxiv 最高为 0.666，github 最低为 0.442，抽样集与扩展集在同域上分布无显著差异。把指标分成语义组与统计负面组后定义了两类冲突，抽样集 I 型冲突率 2.48%、II 型 3.54%，扩展集上结论同样成立，分层消解只修正冲突样本，整体排序的 Spearman 为 0.983。配比模型在 1M 检验集上 R^2 为 0.936，优劣排序可传递到 60M 与 1B，由此得到最优配比 $\boldsymbol{p}^*$，预测平均损失 4.748。本章还查出附件外推表把配比排序翻转，这一发现决定了后面不采用外推表的结论。本章输出的质量分 Q 与最优配比 $\boldsymbol{p}^*$ 是问题二与问题三的输入。

六．问题二：质量与配比同时进入的广义标度律

本章针对问题二展开，在问题一给出的质量分与最优配比之上建立广义标度律：先只用真实训练点把经典律的参数估准，再用半合成数据把质量这一个维度引进幂律项，最后回答质量与规模能否相互替代。

6.1 问题分析

问题二：质量与配比同时进入的广义标度律

问题二要求以 B1 为主拟合经典标度律，用 B2 至 B5 验证；用 B6 至 B8 把质量 Q 引入标度律，结合 B9、B10 讨论百亿参数以上的外推；分析边际效用、弹性与领域间的替代互补，并推导质量与规模可以相互替代的条件。

这一问含有三个子问题，先对它们做步骤拆分。

子问题一：把经典标度律的参数估准——定基准

1）以 B1 中 1144 个真实检查点为样本，在对数空间最小化 Huber 损失；2）用 B3 插值轨迹、B4 跨族收敛点、B5 文献点三套独立数据验证；3）用差分进化的全局搜索确认解是全局最优，并做留出 12B 模型的外推检验。

子问题二：选一种质量进入标度律的形式——比形式

1）核对半合成数据 B6、B7 在 $Q = 1$ 处与经典律是否吻合，确认能否与 B1 拼接；2）比较三种形式，只放大有效数据、加一个与规模无关的惩罚、同时放大有效参数与有效数据；3）按规模分组做交叉验证，选能表达质量收益随规模收缩的那一种，并检查 B8 的方向与 B10 的外推是否自洽。

子问题三：把资源之间的关系讲清楚——提结论

1）对广义律求对数导数，给出参数、数据与质量三个弹性的闭式；2）解等损失方程，给出质量提升等价的参数倍数与两者可替代的条件；3）用问题一配比模型的二阶交互判断领域之间的替代与互补。

问题二的求解路线如图 9 所示，在问题一的 Q 与 $\boldsymbol{p}^*$ 基础上，先拟合并验证经典律，再引入质量项与配比项，最后做弹性与替代分析。

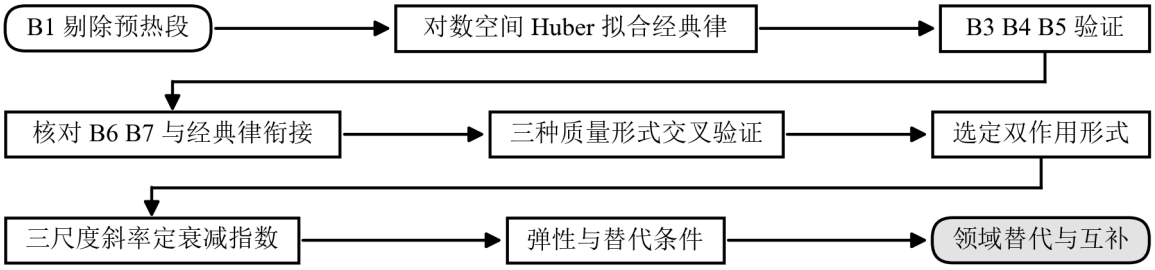


图 9　问题二思路框架图

经典标度律拟合模型：以 B1 的 1144 个真实检查点为样本，按 Chinchilla 的第三种方法在对数空间拟合 $L = E + AN^{-\alpha} + BD^{-\beta}$ 的五个参数。对数空间的 Huber 损失对个别偏离点不敏感；拟合后在 B3、B4、B5 三套独立数据上验证，用留出一个模型的方式检查外推。

双作用广义标度律：把质量分 Q 同时乘进参数项与数据项，Q^{γ_N} 放大有效参数量，Q^{γ_D} 放大有效数据量，$Q = 1$ 时严格退化为经典形式。三种候选形式在同一批半合成数据上按 (N, D) 分组交叉验证，选型的依据不只看误差，还看能不能表达质量收益随规模收缩这一在数据里看得见的现象。配比通过问题一的配比模型进入，其效应随规模按幂律衰减，衰减指数由同一批配比在三个尺度的实测 loss 估计。

弹性与替代分析：对广义律求偏导得到 loss 对 N、D、Q 三个弹性的解析式，由等 loss 方程解出质量提升 0.1 等价的参数倍数，由等 loss 线存在的条件推出质量与规模可替代的条件；领域间的替代与互补用配比模型的二阶交互判断。

6.2 标度律机理与经典形式

Hoffmann 等人 [2] 给出的经典形式为

$$L(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \tag{7}$$

E 是不可约损失，两个幂律项分别是有限参数与有限数据带来的损失，幂律形式的来源可以从数据流形的维度与模型的分辨率得到解释 [13]。训练算力按 $C \approx 6ND$ 近似 [14]。本文所有 loss 均指验证集交叉熵，N 与 D 的单位统一为个，附件里以十亿计的列乘以 10^9。

经典律的两个幂律项分别对应有限参数与有限数据。数据质量提高后，同样多的 token 里有效信息更多，相当于放大了有效数据量；同时噪声更少，同样多的参数能更充分地拟合有效模式，相当于放大了有效参数量。质量进入标度律有三种自然的方式，如图 10 所示。图 10(a) 只放大数据项，图 10(b) 在损失上加一个与规模无关的惩罚，图 10(c) 同时放大参数项与数据项。三者在 $Q = 1$ 时都退化为经典律，区别在质量带来的收益是否随规模变化。B6 与 B7 里 Q 从 0.1 到 1 的 loss 差在 70M 参数与 10B token 处为 0.61，在 12B 参数与 600B token 处为 0.27，收益随规模收缩，这一点只有作用在幂律项上的形式能表达。

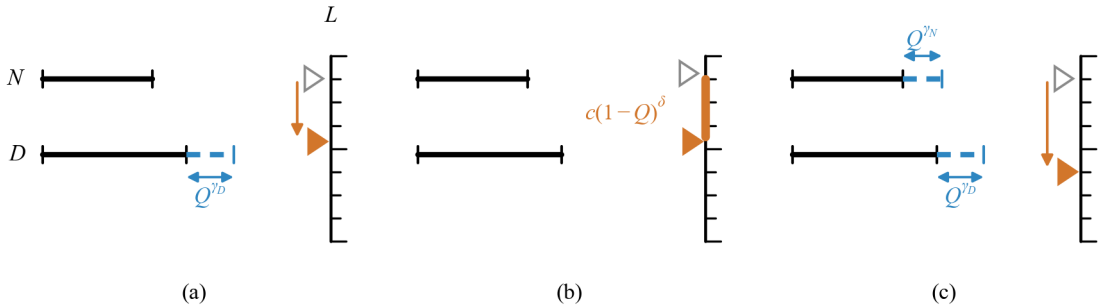


图 10　质量进入标度律的三种形式：(a) 有效数据；(b) 加性惩罚；(c) 双作用

配比的作用来自问题一：同一批配比在 1M、60M、1B 三个尺度的实测 loss 对 1M 预测差的回归斜率分别为 1.00、0.76、0.29，配比效应随模型增大按幂律衰减。

6.3　广义标度律的建立

6.3.1　经典律的拟合

按 Hoffmann 等人 [2] 的第三种方法，即直接对参数化形式做拟合，而不是先固定数据量扫描参数量，也不是先固定算力扫描两者的比例。原因有二：一是 B1 的 8 个模型不是等算力设计的，前两种方法要求的等算力切片在这里凑不齐；二是参数化拟合能把 1144 个检查点全部用上，而不只用每条轨迹的终点。在对数空间最小化 Huber 损失 [15]：

$$\hat{\theta} = \arg\min_{E,A,\alpha,B,\beta} \sum_i \mathrm{Huber}_\delta\Big(\mathrm{LSE}(\ln E,\ \ln A - \alpha \ln N_i,\ \ln B - \beta \ln D_i) - \ln L_i\Big), \quad \delta = 10^{-3}, \tag{8}$$

LSE 为 log-sum-exp，把三项之和写成对数空间的形式后数值上更稳，五个参数的搜索范围为 $\ln E \in [-2, 2]$，$\ln A$ 与 $\ln B \in [-5, 20]$，α 与 $\beta \in [0.01, 2]$。Huber 损失在残差小于 δ 时是平方损失，大于 δ 时转为线性，个别偏离点不会把整条曲线拉歪；取 $\delta = 10^{-3}$ 是因为对数空间的残差本身就在千分位。拟合用 B1 里 $D \geq 2 \times 10^9$ 的 1144 个点，剔除的 32 个点是学习率预热段的检查点，此时 loss 还没有进入幂律区。初值取 Hoffmann 等人报告的 $E = 1.69$、$A = 406.4$、$\alpha = 0.34$、$B = 410.7$、$\beta = 0.28$，用 L-BFGS-B 求解。外推能力用留出检验：去掉 12B 模型的全部检查点重新拟合，再预测它，看误差是否与训练点同量级。

6.3.2　双作用广义标度律

三种候选形式为

$$\mathrm{I}:\ L = E + AN^{-\alpha} + B(DQ^{\gamma})^{-\beta}, \tag{9}$$

$$\mathrm{II}:\ L = E + AN^{-\alpha} + BD^{-\beta} + c(1-Q)^{\delta}, \tag{10}$$

$$\mathrm{III}:\ L = E + A(NQ^{\gamma_N})^{-\alpha} + B(DQ^{\gamma_D})^{-\beta}. \tag{11}$$

经典部分固定为 B1 的估计，只用 B6、B7 拟合质量参数。配比项定义为 1M 配比模型的预测差 $\Delta L_{\text{mix}}(\boldsymbol{p}) = \hat{\tilde{L}}(\boldsymbol{p}) - \hat{\tilde{L}}(\boldsymbol{p}^*) \geq 0$，随规模按 $s(N) = (N/10^6)^{-\rho}$ 衰减。综上所述，最终得到双作用广义标度律为

$$\begin{cases} L(N, D, Q, \boldsymbol{p}) = E + A\,(NQ^{\gamma_N})^{-\alpha} + B\,(DQ^{\gamma_D})^{-\beta} + \left(\dfrac{N}{10^6}\right)^{-\rho} \Delta L_{\text{mix}}(\boldsymbol{p}), \\ \Delta L_{\text{mix}}(\boldsymbol{p}) = \hat{\tilde{L}}(\boldsymbol{p}) - \hat{\tilde{L}}(\boldsymbol{p}^*), \\ Q = 1,\ \boldsymbol{p} = \boldsymbol{p}^* \ \Rightarrow\ L = E + AN^{-\alpha} + BD^{-\beta}. \end{cases} \tag{12}$$

6.3.3 弹性与替代的解析式

记 $T_N = A(NQ^{\gamma_N})^{-\alpha}$，$T_D = B(DQ^{\gamma_D})^{-\beta}$，弹性 $\varepsilon_x = \partial \ln L / \partial \ln x$ 为

$$\varepsilon_N = -\frac{\alpha T_N}{L}, \qquad \varepsilon_D = -\frac{\beta T_D}{L}, \qquad \varepsilon_Q = -\frac{\gamma_N \alpha T_N + \gamma_D \beta T_D}{L}. \tag{13}$$

三个弹性的推导只用到幂律项的齐次性，

$$\frac{\partial T_N}{\partial \ln N} = -\alpha T_N, \quad \frac{\partial T_D}{\partial \ln D} = -\beta T_D, \quad \frac{\partial T_N}{\partial \ln Q} = -\gamma_N \alpha T_N, \quad \frac{\partial T_D}{\partial \ln Q} = -\gamma_D \beta T_D,$$

再除以 L 即得式 (13)。三个弹性都是负数，绝对值越大说明该资源对 loss 的杠杆越大；$|\varepsilon_Q|$ 是另两项的加权和，只要 γ_N、γ_D 不为零它就同时吃到两侧的收益。质量与规模的边际替代率为 $\text{MRS} = \varepsilon_Q / \varepsilon_N$，沿等 loss 线 $\mathrm{d}\ln N / \mathrm{d}\ln Q = -\varepsilon_Q / \varepsilon_N$。质量提升 ΔQ 等价的参数倍数 N'/N 由 $L(N', D, Q) = L(N, D, Q + \Delta Q)$ 解出，因为 T_N 对 N 是幂函数，解有闭式

$$\frac{N'}{N} = \left[\frac{T_N(N, Q + \Delta Q) + T_D(D, Q + \Delta Q) - T_D(D, Q)}{T_N(N, Q)}\right]^{-1/\alpha}, \tag{14}$$

分子是质量提升后参数项与数据项之和减去原数据项，即要由参数项单独承担的那部分 loss。两者的几何关系如图 11 所示，A 与 B 在同一条等 loss 线上，A 比 B 质量高 ΔQ，B 比 A 参数多 $\ln(N'/N)$，A 处切线的斜率对应边际替代率，等 loss 线越靠右上 loss 越低。两者可替代的条件是等 loss 线在可行域内存在，即

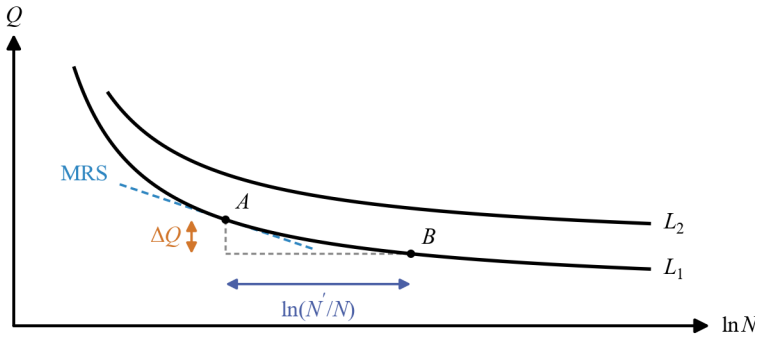


图 11　质量与参数量的等 loss 线与替代关系

$$L(N, D, Q + \Delta Q) > E \quad \Longleftrightarrow \quad T_D(Q) - T_D(Q + \Delta Q) + T_N(Q) - T_N(Q + \Delta Q) < T_N(Q), \tag{15}$$

质量提升带来的 loss 下降不能超过参数项当前的贡献。

6.4 模型的求解与检验

6.4.1 经典律的结果与多算法对比

拟合得 $E = 1.690$，$A = 406.2$，$\alpha = 0.340$，$B = 410.9$，$\beta = 0.280$，训练点 R^2 为 1.000，MAPE 0.004%，留出 12B 模型外推的 MAPE 0.003%。四种拟合器从 10 个随机起点出发的对比见表 8。基于梯度的两种方法对初值敏感，Huber 加 L-BFGS-B 从随机起点出发 10 次都没有收敛到全局解，最小二乘加 L-BFGS-B 命中 5 次；不用梯度的 Nelder-Mead 命中 9 次，差分进化 [11]10 次全部收敛到同一个解，MAPE 0.0039%，与本文以文献报告值为初值的 Huber 拟合结果一致到小数点后三位。这说明五参数目标函数有多个局部极小，全局解就是文献值附近的那一个。本文主拟合取文献值为初值的 Huber 拟合，用时最短，并用差分进化的全局搜索确认它是全局最优。

表 8 经典标度律拟合器的多算法对比（10 个随机起点）

指标	Huber+L-BFGS-B	最小二乘 L-BFGS-B	Nelder-Mead	**差分进化**
最小 MAPE / %	0.065	0.004	0.004	0.004
10 次平均 MAPE / %	3.38	4.33	0.024	0.004
命中次数（MAPE<0.05%）	0	5	9	10
单次用时 / s	0.12	0.04	0.28	4.8

验证结果见表 9。B3 插值轨迹 MAPE 0.07%；B4 跨族收敛点 Spearman 0.983，MAPE 8.6%，允许一个族级截距后 R^2 由 0.605 升到 0.830，各族偏差在 0.03 到 0.44 之间；B5 文献点 Spearman 0.959，MAPE 8.1%。B2 半合成 Cerebras 轨迹 MAPE 33.6%，只有排序可用，Spearman 0.788，它的校准口径与 B1 不同，只作族外排序验证。

表 9 经典标度律的验证

数据集	性质	点数	R^2	MAPE / %	Spearman
B1 训练点	真实	1144	1.000	0.004	1.000
B3 插值轨迹	插值	2600	1.000	0.07	1.000
B2 Cerebras	半合成	1029	0.385*	33.6	0.788
B4 跨族收敛点	真实	57	0.830*	8.6	0.983
B5 文献点	真实	44	0.733*	8.1	0.959

* 允许一个整体截距后的 R^2。

族级偏差见表 10。12 个族里 Yi 与 LLaMA 的偏差最小，为 0.03 与 0.07，OPT 与 BLOOM 在 0.28 到 0.29，B4 里 Pythia 的收敛点偏差 0.44，说明 B4 的 loss 口径与 B1 不同。偏差的来源是验证集与分词器：经典律的 loss 是在 Pile 验证集上的交叉熵，其它族的 loss 来自各自的验证集，词表越大每个 token 的信息量越多，交叉熵的绝对值就越低，所以偏差本身不说明模型好坏。族内的排序全部保持，除 Gemma 三个点为 0.5 以外，各族的族内 Spearman 都为 1 或 0.96，说明经典律抓住的是规模效应的形状，形状在族间是通用的，差的只是一个族级的平移。

6.4.2 广义律的选型与检验

B6 与 B7 合并去重后 450 点，在 $Q = 1$ 处与经典律的均值偏差 0.004，MAPE 1.7%，可以拼接。三种形式按 (N, D) 组做 5 折交叉验证，每一折留出若干个 (N, D) 组合的全部质量档，考察的是模型对没见过的规模的外推，结果见表 11。形式 II 交叉验证误差最小，但它的惩罚项 $0.34(1 - Q)^{0.95}$ 与规模无关，Q 从 0.1 提到 1 在任何规模下都只降同样多的 loss，与数据里 70M 模型降 0.61、12B 模型降 0.27 的事实矛盾；形式 I 只放大数据项，能表达收缩但误差最大，$\gamma = 1.26$ 把全部质量效应压在数据一侧；形式 III 能表达收缩，误差只比形

表 10　跨族收敛点 B4 的族级偏差

模型族	点数	偏差	族内 Spearman	模型族	点数	偏差	族内 Spearman
Yi	2	0.029	–	Phi	6	0.184	1.00
LLaMA	6	0.072	1.00	Cerebras-GPT	7	0.186	1.00
Mistral	1	0.127	–	GPT2	4	0.211	1.00
Falcon	2	0.158	–	OPT	7	0.281	1.00
Gemma	3	0.165	0.50	BLOOM	4	0.294	1.00
Qwen2	7	0.176	0.96	Pythia	8	0.443	1.00

式 II 差 0.3 个百分点，取为主形式，$\gamma_N = 0.698$，$\gamma_D = 0.606$，两个指数都在 0 到 1 之间，说明质量对参数与数据两侧的放大都是次线性的，且对参数一侧略强。若放开经典部分的五个参数与质量参数一起拟合，三种形式的交叉验证 MAPE 会降到 1.04%、0.62% 与 0.71%，但经典参数会被半合成数据带偏，α 从 0.340 移到 0.336，E 从 1.690 移到 1.687，本文不采用，坚持经典部分只由真实数据决定。配比衰减指数 $\rho = 0.171$。B8 的 $Q = 1$ 子集 138 点与主形式的 MAPE 1.26%，Spearman 0.990，N 与 D 的方向自洽；B10 的 128 个百亿以上估算值与主形式 MAPE 0.03%，偏差 −0.0007，说明外推形式自洽，但它是公式生成值，不能当作观测。

表 11　广义标度律三种形式的比较（经典部分固定）

形式	CV-MAPE / %	B6/B7 R^2	B6/B7 MAPE / %	质量参数
I 有效数据	3.30	0.872	3.28	$\gamma = 1.260$
II 加性惩罚	2.14	0.953	2.13	$c = 0.339$, $\delta = 0.954$
III 双作用	2.45	0.937	2.43	$\gamma_N = 0.698$, $\gamma_D = 0.606$

拟合与验证如图 12 所示。图 12(a) 是八个 Pythia 模型的 loss 随 token 数的轨迹与经典律曲线，曲线穿过全部点；图 12(b) 是四个 (N, D) 组合下 loss 随 Q 的变化与主形式的预测，小模型的曲线更陡，收益随规模收缩；图 12(c) 是 B4 与 B5 共 101 个真实点的预测对照，点沿对角线分布，族间的平移来自验证集差异。

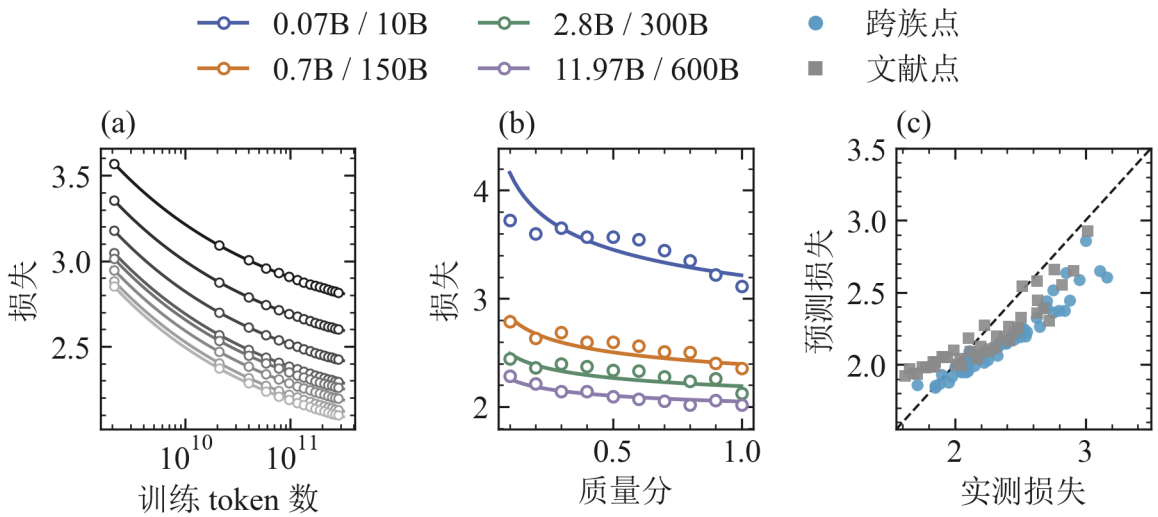


图 12　问题二结果：(a) 经典律拟合，灰阶由深到浅为参数量由小到大；(b) 质量项拟合；(c) 跨族与文献验证

6.4.3 弹性、替代与领域交互

典型配置的弹性见表 12。三个弹性都为负且绝对值随规模减小；$|\varepsilon_Q|$ 在各点都最大，因为 Q 同时进入两项；$|\varepsilon_D| > |\varepsilon_N|$ 说明在 Chinchilla 比例附近数据仍比参数更有效。质量提升 0.1 等价的参数倍数在 $Q = 0.5$ 处为 1.28 到 1.36，在 $Q = 0.8$ 到 0.9 处为 1.20，规模越大同样的质量提升折算的参数越多。

表 12 典型配置的弹性与质量提升 0.1 的等价参数倍数

N	D	Q	L	ε_N	ε_D	ε_Q	N'/N
10^8	2×10^9	0.5	3.752	−0.083	−0.086	−0.110	1.28
10^9	2×10^{10}	0.5	2.710	−0.052	−0.062	−0.074	1.30
7×10^9	1.4×10^{11}	0.5	2.255	−0.033	−0.043	−0.049	1.33
7×10^9	1.4×10^{11}	0.8	2.205	−0.030	−0.041	−0.046	1.20
7×10^{10}	1.4×10^{12}	0.5	1.972	−0.017	−0.026	−0.028	1.36
7×10^{10}	1.4×10^{12}	0.9	1.942	−0.015	−0.024	−0.025	1.20

领域间的替代与互补用问题一的配比模型判断：以训练均值配比为基准，两个域各加 0.05 后的 loss 变化减去各自单独加的变化，负值为互补，正值为替代，绝对值小于 10^{-4} 记为独立，结果见表 13。dm_mathematics 与 ubuntu_irc、stackexchange、arxiv、pubmed_central 互补，交互项在 −0.0014 到 −0.0030，数学与问答、学术文本一起增加比单独增加更有效；github 与 pubmed_central、freelaw、arxiv、pile_cc 替代，交互项 0.0028 到 0.0036，代码与长文本争夺配额；stackexchange 与 pubmed_central 独立。有意思的是单独增加 dm_mathematics 只降 loss 0.0009，单独增加 arxiv 反而升 0.0029，两者同时增加却几乎不变，交互项 −0.0020 把 arxiv 的负效应抵消了，数学文本需要学术文本作上下文才起作用。

表 13 领域对的二阶交互（各加 0.05，loss 变化 $\times10^{-3}$）

域对	单独增加前者	单独增加后者	同时增加	交互项	关系
dm_mathematics 与 ubuntu_irc	−0.9	−5.5	−9.3	−3.0	互补
stackexchange 与 dm_mathematics	−7.4	−0.9	−11.0	−2.7	互补
dm_mathematics 与 arxiv	−0.9	2.9	0.0	−2.0	互补
dm_mathematics 与 pile_cc	−0.9	−20.0	−22.6	−1.8	互补
stackexchange 与 ubuntu_irc	−7.4	−5.5	−14.4	−1.6	互补
dm_mathematics 与 pubmed_central	−0.9	−3.6	−5.9	−1.4	互补
ubuntu_irc 与 pile_cc	−5.5	−20.0	−26.7	−1.3	互补
stackexchange 与 pubmed_central	−7.4	−3.6	−10.9	0.0	独立
stackexchange 与 github	−7.4	5.4	0.3	2.3	替代
pile_cc 与 github	−20.0	5.4	−11.7	2.8	替代
github 与 arxiv	5.4	2.9	11.4	3.1	替代
github 与 pubmed_central	5.4	−3.6	5.4	3.6	替代
github 与 freelaw	5.4	−1.1	7.9	3.6	替代

6.5 本章小结

本章以 1144 个真实训练点拟合出经典标度律，参数与文献报告值一致，跨族收敛点与文献点上的 Spearman 都在 0.95 以上。比较三种引入质量的形式后选定双作用形式，$\gamma_N = 0.698$，$\gamma_D = 0.606$，$Q = 1$ 时严格退化为经典律；配比项按 $(N/10^6)^{-0.171}$ 随规模衰减。弹性分析给出 $|\varepsilon_Q| > |\varepsilon_D| > |\varepsilon_N|$，质量提升 0.1 等价于参数增加 1.20 到 1.36 倍，并解析给出两者可相互替代的条件。领域之间，数学与问答、学术文本互补，代码与长文本相互替代。本章建立的广义标度律是问题三优化模型的目标函数。

七. 问题三：算力约束下的资源配置与结构性转移

本章针对问题三展开，在广义标度律上加一条算力预算约束，求最优的参数量、数据量与数据质量，并给出预算变化时资源配置发生结构性转移的位置。

7.1 问题分析

问题三：算力约束下的资源配置与结构性转移

问题三要求在总算力不超过预算的条件下求最优的参数量、数据量与数据质量，考察三档预算与三种质量成本函数，给出结构性转移的数学定义与识别方法，解析给出临界上下文长度并做敏感性分析。

这一问含有三个子问题，先对它们做步骤拆分。

子问题一：把三项开销写清楚——搭约束

1）训练开销 $6ND$、质量提升开销 $D[g(Q)-g(Q_0)]_+$ 与注意力开销 ηNDL_{ctx} 三项之和不超过预算；2）由 KKT 条件推出等边际率，并分质量在下界、内点与上界三种情形讨论；3）由平衡条件说明质量开销会把最优解推向多参数、少数据。

子问题二：把最优解求出来——给结果

1）配比固定为问题一的最优配比，决策变量取 N、D、Q；2）用多起点序列二次规划求解，与差分进化、网格搜索、罚函数法对比，并核对最优性条件；3）在三档预算与三种质量成本函数下给出最优配置，再在 C7 的五个上下文长度上看影响。

子问题三：识别预算上的结构性转移——定制度

1）以最优解的活跃约束集变化定义结构性转移；2）用参数与数据的预算弹性断点、三项开销份额向量的转角两个连续指标佐证；3）给出三种成本函数下的切换点，并对配置参数做灵敏度分析。

问题三的求解路线如图 13 所示，在问题二的广义律上加三项开销约束，求解三档预算与连续扫描，识别结构性转移并做上下文长度敏感性。

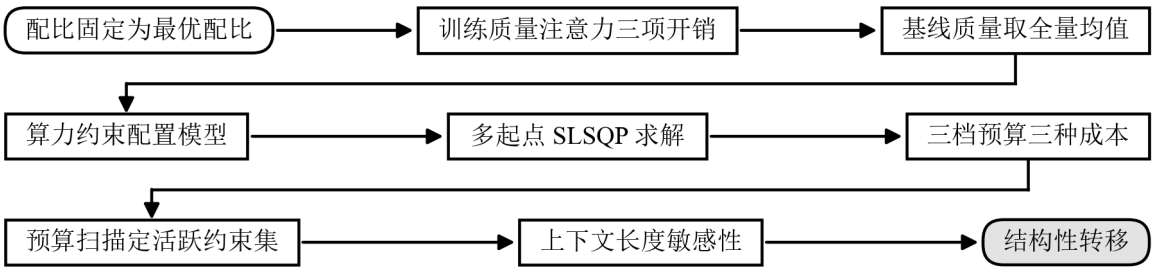


图 13 问题三思路框架图

算力约束资源配置模型：以广义标度律为目标函数，以训练、质量、注意力三项开销之和不超过预算为主约束，质量限定在基线与 1 之间，决策变量是参数量、数据量与质量三个连续量。配比不进入决策，因为它不占算力，且配比项对任何预算都在问题一的最优配比处取最小。

结构性转移的识别：把结构性转移定义为最优解的活跃约束集发生变化，即质量从不投到投、从内点到饱和的切换；再用两个连续指标佐证，一个是最优参数量与数据量对预算的弹性出现断点，另一个是三项开销的份额向量在相邻预算点之间转过的角度。三者互相印证，切换点才算可信。

多起点序列二次规划求解：在对数空间求解，以 Chinchilla 比例生成 15 个起点逐个求解并保留可行的最优解，在最优点上核对 KKT 条件；与差分进化、网格搜索、罚函数法对比后确认解是全局的；在 10^{18} 到 10^{26} 的 41 个预算点上扫描，三种成本函数各扫一遍，再在 C7 给出的五个上下文长度上做敏感性分析。

7.2 算力开销结构的机理分析

总预算被三项开销分走。训练开销 $6ND$ 与 N、D 同时成正比；质量开销 $D[g(Q)-g(Q_0)]_+$ 只与 D 和质量提升幅度有关，不随 N 增长；注意力开销 ηNDL_{ctx} 与训练开销同结构，比例固定为 $\eta L_{\text{ctx}}/6$。按 token 计价之后，训练与质量两项的轻重随预算翻转，如图 14 所示。图 14(a) 是低预算，模型小，每个 token 的训练成本 $6N$ 低于质量成本 $g(1)-g(Q_0)$ 约 5×10^9，质量开销占大头，值得投的质量有限；图 14(b) 是中预算，N 长到数十亿，训练成本反超质量成本，质量可以拉满；图 14(c) 是高预算，质量开销份额趋近于零，分配退回参数与数据两者之间。这就是结构性转移的来源：质量成本是 token 计价的固定项，训练成本随 N 增长，两者的比值随预算单调变化。

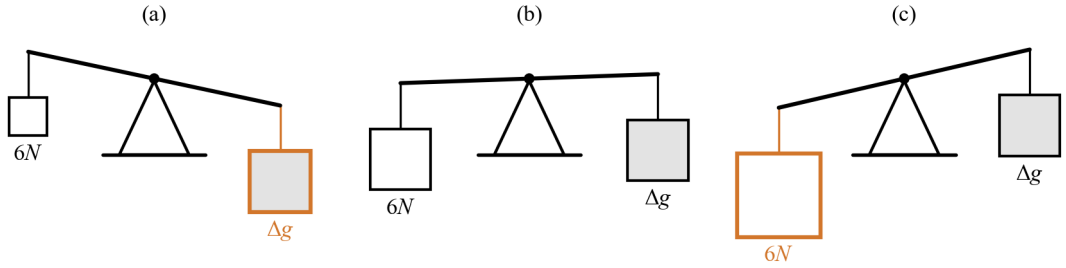


图 14 三档预算下每 token 训练成本与质量成本的轻重：(a) 10^{19}；(b) 10^{22}；(c) 10^{24} FLOPs

注意力开销与训练开销相当的条件由 $\eta NDL_{\text{ctx}} = 6ND$ 解出，$L_{\text{ctx}}^{\text{crit}} = 6/\eta = 30000$。注意力项与 ND 成正比，等价于把训练预算缩为 $C/(1+\eta L_{\text{ctx}}/6)$，上下文长度只压缩有效预算，不改变最优解的结构。注意力开销与 L_{ctx} 成正比的原因如图 15 所示，每个 token 要与窗口内前面的全部位置各做一次注意力，窗口拉长几倍，每个 token 的注意力计算就多几倍。

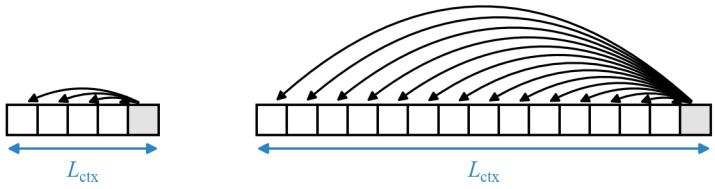


图 15 注意力开销随上下文窗口增长

7.3 算力约束资源配置模型

决策变量为 N、D、Q。配比固定为 $\boldsymbol{p}^*$，因为配比不占算力，且配比项 $s(N)\Delta L_{\text{mix}}(\boldsymbol{p}) \geq 0$ 对任意预算都在 $\boldsymbol{p}^*$ 取最小，联立求解与先定 $\boldsymbol{p}^*$ 等价。目标函数是式 (12) 的 loss。约束有三条：总开销不超过预算；质量不低于基线，低于基线不省算力却抬高 loss，不会最优；质量不超过 1。综上所述，最终得到算力约束资源配置模型为

$$\begin{cases} \min\limits_{N,D,Q} \; L(N,D,Q,\boldsymbol{p}^*) = E + A(NQ^{\gamma_N})^{-\alpha} + B(DQ^{\gamma_D})^{-\beta}, \\ \text{s.t.} \begin{cases} 6ND + D\,[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}} \leq C, \\ Q_0 \leq Q \leq 1, \\ N \geq N_{\min},\; D \geq D_{\min}, \end{cases} \end{cases} \tag{16}$$

g 取指数型 $\gamma e^{\lambda Q}$、幂函数型 γQ^{λ}、对数渐进型 $\gamma \ln(1+\lambda Q)$ 三种，参数按题目附录 B，分别为 $g_{\text{exp}}(Q) = 10^7 e^{6Q}$、$g_{\text{pow}}(Q) = 5\times10^9 Q^4$ 与 $g_{\log}(Q) = 2\times10^9 \ln(1+10Q)$，单位是每

个 token 的 FLOPs。三种成本的形状决定了质量决策的性质：指数型与幂函数型的边际成本 $g'(Q)$ 随 Q 递增，质量越高再提一点越贵，最优质量可以停在内点；对数型的边际成本随 Q 递减，越提越便宜，一旦值得投就会一直投到 1，最优质量只会在 Q_0 与 1 两个端点之间跳，不会停在中间。从 $Q_0 = 0.503$ 提到 1 的每 token 增量成本，三种形式分别为 3.8×10^9、4.7×10^9 与 1.2×10^9 FLOPs，与一个 10^9 参数模型每 token 的训练成本 6×10^9 同量级，这正是质量与参数会互相争预算的原因。

结构性转移定义为最优解的活跃约束集 $\mathcal{A}(C) = \{i：\text{约束}i\text{在}C\text{处取等号}\}$ 发生变化，即 Q^* 从内点跳到边界 Q_0 或 1，或从边界回到内点。配合两个连续指标识别：一是 $\ln N^*$、$\ln D^*$ 对 $\ln C$ 的弹性 $\partial \ln N^*/\partial \ln C$ 出现断点，取二阶差分最大处；二是开销份额向量 $\boldsymbol{s} = (s_{\text{train}}, s_Q, s_{\text{attn}})$ 在相邻预算点间的夹角 $\theta_k = \arccos\left(\boldsymbol{s}_k \cdot \boldsymbol{s}_{k-1}/\|\boldsymbol{s}_k\|\|\boldsymbol{s}_{k-1}\|\right)$，转角最大处即份额结构变化最剧烈处。

7.3.1 最优性条件

记总开销 $c(N,D,Q) = 6ND + D[g(Q) - g(Q_0)]_+ + \eta NDL_{\text{ctx}}$，对预算约束与质量上下界分别引入乘子 $\mu \geq 0$、$\nu_0 \geq 0$、$\nu_1 \geq 0$，拉格朗日函数为 $\mathcal{L} = L + \mu(c - C) + \nu_0(Q_0 - Q) + \nu_1(Q - 1)$。预算约束在最优点必然取等号，否则还能增加 N 或 D 降低 loss，故 $\mu > 0$。对 N、D 的驻点条件给出

$$\frac{-\partial L/\partial N}{\partial c/\partial N} = \frac{-\partial L/\partial D}{\partial c/\partial D} = \mu, \qquad \frac{\partial c}{\partial N} = D(6 + \eta L_{\text{ctx}}), \quad \frac{\partial c}{\partial D} = N(6 + \eta L_{\text{ctx}}) + [g(Q) - g(Q_0)]_+, \tag{17}$$

即在最优点上，参数与数据每多花一个 FLOP 带来的 loss 下降率相等，都等于预算的影子价格 μ。对 Q 的条件分三种情形：Q 在内点时 $(-\partial L/\partial Q)/(Dg'(Q)) = \mu$，质量的每 FLOP 边际下降率也等于影子价格；$Q$ 到上界 1 时 $\nu_1 > 0$，质量的边际率大于 μ，说明质量还想再投但已经没有余地；Q 停在下界 Q_0 时边际率小于 μ，说明质量不值得投。把式 (17) 展开，得到 $\alpha T_N\,[N(6 + \eta L_{\text{ctx}}) + \Delta g] = \beta T_D\, D(6 + \eta L_{\text{ctx}})$，$\Delta g = [g(Q) - g(Q_0)]_+$。没有质量开销时它退化为 $\alpha T_N = \beta T_D$，正是 Chinchilla 算力最优解的条件；质量开销 Δg 附在数据一侧，每个 token 都变贵，同样的预算下最优解会用略多的参数换略少的数据，投质量的解比不投质量的解 D/N 小，10^{22} 处为 42 对 53，这一点在后面的结果里得到印证。如图 16 所示，在 $(\ln N, \ln D)$ 平面上预算约束 $6ND = C$ 是一条斜率为 -1 的直线，等 loss 线是凸向原点的曲线，最优点 A 是两者的切点；加上质量开销后预算线弯成曲线并向内收，低参数量一侧收得更多，切点移到 B，B 落在射线 $D/N = 20$ 的下方，即最优的 D/N 变小。

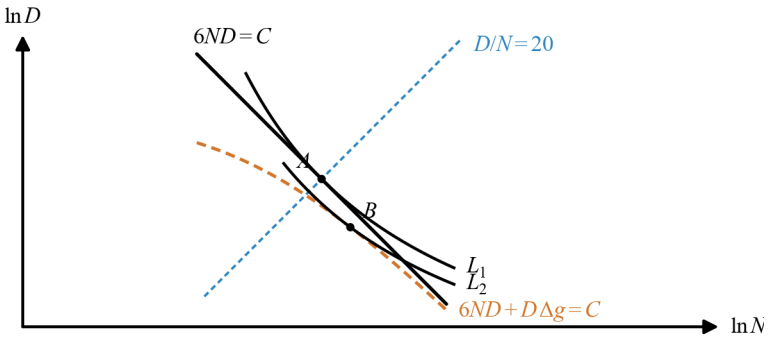


图 16 预算线与等 loss 线的切点：无质量开销的 A 与有质量开销的 B

7.4 模型的求解与结果

7.4.1 求解算法与多算法对比

在 $(\ln N, \ln D, Q)$ 空间用 SLSQP 求解，流程如图 17 所示：以 Chinchilla 比例 $N \approx D/20$ 生成 15 个起点，逐个求解并保留可行且最优的解，最优点处检查 N、D 的每 FLOP 边际

loss 下降率是否相等，Q 到边界时其边际率应更大，这是 KKT 条件；再沿预算扫描判定活跃约束集与断点。

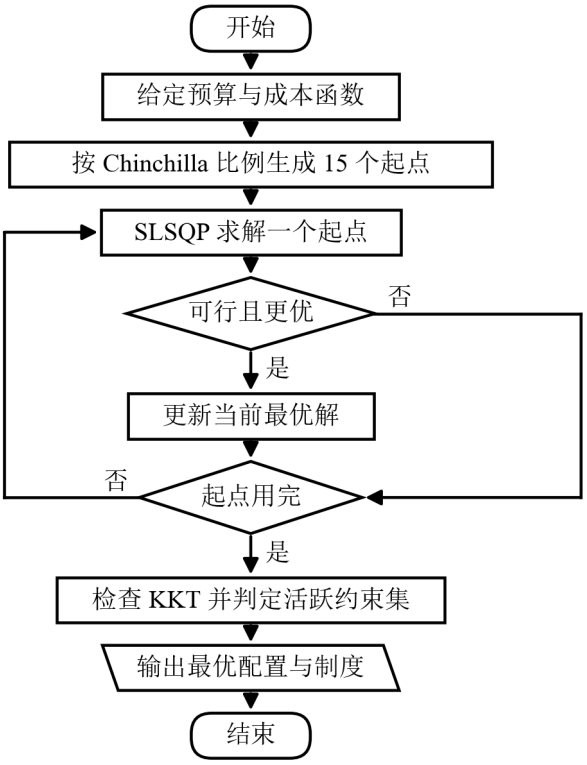


图 17　算力约束资源配置模型的求解与制度识别流程

四种优化器在 $C = 10^{22}$、幂函数成本下各跑 10 次的对比见表 14。SLSQP[16] 多起点与差分进化 10 次都收敛到 $L^* = 2.1565$，前者用时 0.02 秒，后者 0.32 秒；网格搜索把 D 由预算等式消去后只搜两维，最好一次与最优只差 3×10^{-7}，但 10 次里只有 3 次落进容差，因为最优点落在网格点之间；罚函数配 Nelder-Mead 只有 1 次到达最优，均值 4.22，多数起点停在不可行域附近的罚函数平台上。目标函数在对数空间是光滑的，可行域由一条不等式界定，这类问题正是序列二次规划的长项，故选定 SLSQP。

表 14　优化器的多算法对比（$C = 10^{22}$，幂函数成本，10 次运行）

指标	**SLSQP 多起点**	差分进化	网格搜索	罚函数 Nelder-Mead
最小 L^*	2.1565	2.1565	2.1565	2.1580
10 次均值	2.1565	2.1565	2.1569	4.2244
命中最优次数	10	10	3	1
单次用时 / s	0.02	0.32	0.005	0.08

7.4.2　三档预算的结果

基线质量 $Q_0 = 0.503$。上下文长度由 C7 的 45 个模型给出，可行取值为 2048、4096、8192、32768、131072，出现次数为 18、8、7、11、1，默认取 4096。三档预算与三种成本函数的最优解见表 16。低预算 10^{19} 处质量是否值得投取决于成本函数，指数型给 $Q^* = 0.70$，幂函数型给 0.61，对数型直接饱和到 1；预算到 10^{22} 及以上，三种成本下 Q^* 都为 1，成本函数只影响质量在总开销里的份额，分别为 9%、11%、3%。质量投入的 loss 收益在 10^{19} 为 0.01 到 0.08，在 10^{22} 为 0.06，在 10^{24} 为 0.033，与不投质量的 Chinchilla 解相比参数略

小、数据略多。最优 D/N 随预算从 14 升到 92，来源是 $\beta < \alpha$ 使数据项的衰减慢于参数项，预算越大越值得多买数据，加上注意力开销按 ND 计价；质量开销反而压低 D/N，同一预算下投质量的解比不投质量的解 D/N 小，10^{22} 处为 42 对 53。最优点处 N 与 D 的每 FLOP 边际 loss 下降率相等，10^{22} 处为 7.5×10^{-24}，Q 到边界 1 时其边际率为 2.0×10^{-23}，KKT 条件成立。九个组合的核对见表 15：三档预算下参数与数据的边际率在小数点后三位以内相等；10^{19} 处指数型与幂函数型的质量是内点解，质量的边际率与另两者相等，对数型的质量已经饱和，边际率是另两者的两倍；10^{22} 与 10^{24} 处三种成本的质量都饱和，质量的边际率比参数与数据高 2 到 190 倍，说明质量若能超过 1 还会继续投。影子价格随预算按幂律下降，从 10^{19} 的 2.5×10^{-20} 到 10^{24} 的 3.5×10^{-26}，每增加一个数量级的预算，一个 FLOP 能换到的 loss 下降少一个数量级还多。

表 15　最优点处的每 FLOP 边际 loss 下降率（KKT 核对）

成本	C	参数量	数据量	质量	质量所处位置
指数	10^{19}	2.48×10^{-20}	2.48×10^{-20}	2.48×10^{-20}	内点
指数	10^{22}	7.45×10^{-24}	7.45×10^{-24}	1.57×10^{-23}	上界
指数	10^{24}	3.49×10^{-26}	3.49×10^{-26}	5.12×10^{-25}	上界
幂	10^{19}	2.49×10^{-20}	2.49×10^{-20}	2.49×10^{-20}	内点
幂	10^{22}	7.54×10^{-24}	7.54×10^{-24}	1.98×10^{-23}	上界
幂	10^{24}	3.50×10^{-26}	3.50×10^{-26}	6.24×10^{-25}	上界
对数	10^{19}	2.60×10^{-20}	2.60×10^{-20}	5.46×10^{-20}	上界
对数	10^{22}	7.17×10^{-24}	7.17×10^{-24}	1.81×10^{-22}	上界
对数	10^{24}	3.47×10^{-26}	3.47×10^{-26}	6.67×10^{-24}	上界

表 16　三档预算下的最优配置（$L_{\text{ctx}} = 4096$）

成本	C	N^*/B	D^*/B	Q^*	L^*	L(不投质量)	训练份额	质量份额	注意力份额
指数	10^{19}	0.287	4.1	0.702	3.165	3.206	0.71	0.19	0.10
指数	10^{22}	5.46	244	1.000	2.155	2.215	0.80	0.09	0.11
指数	10^{24}	39.6	3648	1.000	1.916	1.949	0.87	0.01	0.12
幂	10^{19}	0.277	4.5	0.605	3.195	3.206	0.74	0.16	0.10
幂	10^{22}	5.58	234	1.000	2.157	2.215	0.78	0.11	0.11
幂	10^{24}	39.8	3624	1.000	1.916	1.949	0.86	0.02	0.12
对数	10^{19}	0.347	2.8	1.000	3.127	3.206	0.58	0.34	0.08
对数	10^{22}	5.07	280	1.000	2.150	2.215	0.85	0.03	0.12
对数	10^{24}	39.2	3725	1.000	1.916	1.949	0.88	0.00	0.12

7.4.3　结构性转移的识别

在 10^{18} 到 10^{26} 共 41 个预算点上扫描，结果如图 18 所示。图 18(a) 是三种成本下 Q^* 随预算的变化，幂函数成本下出现三个制度：$C < 4.0\times10^{18}$ 不投质量，4.0×10^{18} 到 6.3×10^{20} 为内点解，Q^* 从 0.50 升到 1，$C \geq 6.3\times10^{20}$ 质量饱和；指数成本下内点到饱和的切换点在 1.6×10^{21}；对数成本因边际成本随 Q 递减，在 2.5×10^{18} 处从不投质量直接跳到饱和，份额向量转角达 41°，是最强的结构性转移。图 18(b) 是幂函数成本下三项开销的份额，质量份额在内点制度内先升后降，峰值 24% 出现在 10^{20} 附近，之后被训练份额挤掉；图 18(c) 是 N^*、D^* 对预算的弹性，饱和制度内稳定在 0.45 与 0.55，是 Chinchilla 的 0.5 与 0.5 受注意力开销和质量成本残余影响的结果，内点制度内 N 的弹性在 0.36 到 0.55 之间波动，因为质量在与参数争预算。

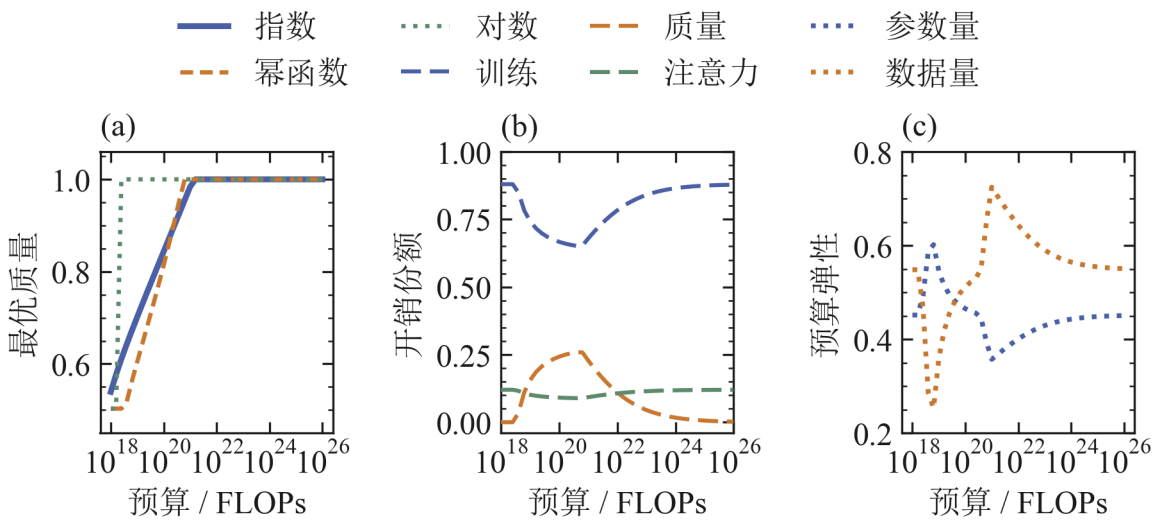


图 18　问题三结果：(a) 最优质量随预算；(b) 开销份额；(c) 参数与数据的预算弹性

三种识别方法的结果汇总见表 17。活跃约束集的切换点与两个连续指标互相印证：幂函数成本下弹性断点 4.0×10^{18} 与第一次切换点重合；对数成本下份额向量的最大转角 41.4° 正好落在唯一的切换点 2.5×10^{18} 上，是三种成本里最剧烈的一次转移，因为质量从不投一步跳到饱和，质量份额从 0 跳到三成以上；指数成本下内点制度横跨三个数量级，份额变化平缓，最大转角只有 3.9°，弹性断点 2.5×10^{21} 比切换点 1.6×10^{21} 晚一个扫描步长，预算网格每步 0.2 个数量级，差别在分辨率之内。转移的方向在三种成本下一致：预算越大，质量在总开销里的份额越小，资源分配越接近只有参数与数据两项的经典问题。

表 17　结构性转移的三种识别结果（预算单位为 FLOPs）

成本	切换点	切换类型	弹性断点	最大转角	转角位置
指数	1.6×10^{21}	内点到饱和	2.5×10^{21}	3.9°	1.6×10^{18}
幂	4.0×10^{18}	不投到内点	4.0×10^{18}	5.7°	6.3×10^{18}
幂	6.3×10^{20}	内点到饱和	–	–	–
对数	2.5×10^{18}	不投到饱和	4.0×10^{18}	41.4°	2.5×10^{18}

7.4.4　上下文长度敏感性

L_{ctx} 在五个可行取值上的结果见表 18。从 2048 增到 131072，注意力份额从 6% 升到 77%，最优参数量从 5.76B 缩到 2.58B，loss 从 2.152 升到 2.276；超过临界值 30000 后注意力成为主要开销，131072 的有效预算只剩 18.6%。质量决策在中高预算下不受上下文长度影响，各取值下 Q^{*} 都为 1；在 10^{19} 处 Q^{*} 随 L_{ctx} 从 2048 增到 131072 由 0.598 升到 0.774，因为注意力开销把训练预算压缩之后，质量成本按 token 计价不受 L_{ctx} 影响，相对性价比上升。另两档预算的走势与 10^{22} 一致：10^{19} 处 loss 从 3.182 升到 3.545，10^{24} 处最优参数量从 40.9B 缩到 19.5B，loss 从 1.914 升到 1.977。注意力与训练开销之比 $\eta L_{\text{ctx}}/6$ 在五个取值下为 0.07、0.14、0.27、1.09 与 4.37，跨过 1 的位置就是临界值 30000，C7 里 11 个 32768 上下文的模型恰好落在临界值附近，1 个 131072 的模型远在其上。

7.4.5　模型的检验

把质量固定在 Q_0，模型退化为 Chinchilla 的算力最优问题，10^{22} 处得 N = 5.25B、D = 279B，D/N = 53，与不含注意力项时的 Chinchilla 解 $D/N\approx20$ 相比偏大，差别来自 $\eta L_{\text{ctx}}/6$ = 0.14 的注意力开销与 $\beta<\alpha$ 的参数取值，方向与 Hoffmann 等人的结论一致。放开质量后

表 18　上下文长度对最优配置的影响（幂函数成本，$C = 10^{22}$）

L_{ctx}	注意力/训练	有效预算比例	N^*/B	D^*/B	L^*	注意力份额
2048	0.07	0.936	5.76	241	2.152	0.06
4096	0.14	0.880	5.58	234	2.157	0.11
8192	0.27	0.786	5.26	223	2.164	0.19
32768	1.09	0.478	4.09	178	2.200	0.48
131072	4.37	0.186	2.58	114	2.276	0.77

loss 下降 0.058，与问题二弹性 $|\varepsilon_Q| > |\varepsilon_N|$ 的判断一致，即问题三的解回代印证了问题二的模型。

7.5　参数灵敏度分析

对问题三的最优解做参数灵敏度分析，取幂函数成本，五个配置参数各取 0.6 到 1.4 倍共七档，相对灵敏度定义为 $|\partial \ln L^* / \partial \ln p|$，用 $\pm 20\%$ 的中心差分估计。结果如图 19 所示。

图 19(a) 是低预算 10^{19} 处最优 loss 随各参数倍数的曲线族，此时 $Q^* = 0.605$ 为内点解，五个参数都起作用。基线质量 Q_0 的影响最大也最特别，它上调 40% 时最优 loss 从 3.195 降到 3.108，因为基线越高，达到同样质量要买的算力越少，省下的预算全部转给参数和数据。质量指数 γ_D 与 γ_N 上调会抬高 loss，看似反直觉，其实是模型重新配平的结果：质量的边际收益变大后最优质量从 0.605 升到 0.647，挤占了训练预算，净效果是 loss 略升，说明在低预算下质量已经投到了边际平衡点附近。成本函数指数 λ 上调使质量变贵，最优质量反而从 0.605 升到 0.658，因为幂函数在 $Q < 1$ 区间内 λ 越大增量成本越低。注意力系数 η 的曲线最平。

图 19(b) 是低预算与中预算两档的相对灵敏度对照，横轴取对数。低预算下 Q_0 为 0.049 最敏感，γ_D 与 γ_N 约 0.023，λ 为 0.016，η 为 0.008，都在百分之几的量级，最优 loss 对这些参数不敏感。中预算 10^{22} 下质量已经饱和到 $Q^* = 1$，Q^{γ} 恒等于 1，两个质量指数的灵敏度精确为零，Q_0 与 λ 也降到 0.001 以下，只有 η 还有 0.004，因为注意力开销始终按比例抽走预算。作为对照，标度律指数 α 与 β 的相对灵敏度为 0.83 与 1.15，比配置参数高一到两个数量级。这说明模型的结论稳在两件事上：广义律的质量参数即使估计有偏，最优配置和制度切换的结论也不会变；而 α、β 必须估准，这也是本文用 1144 个真实训练点而不是半合成数据拟合它们的原因。

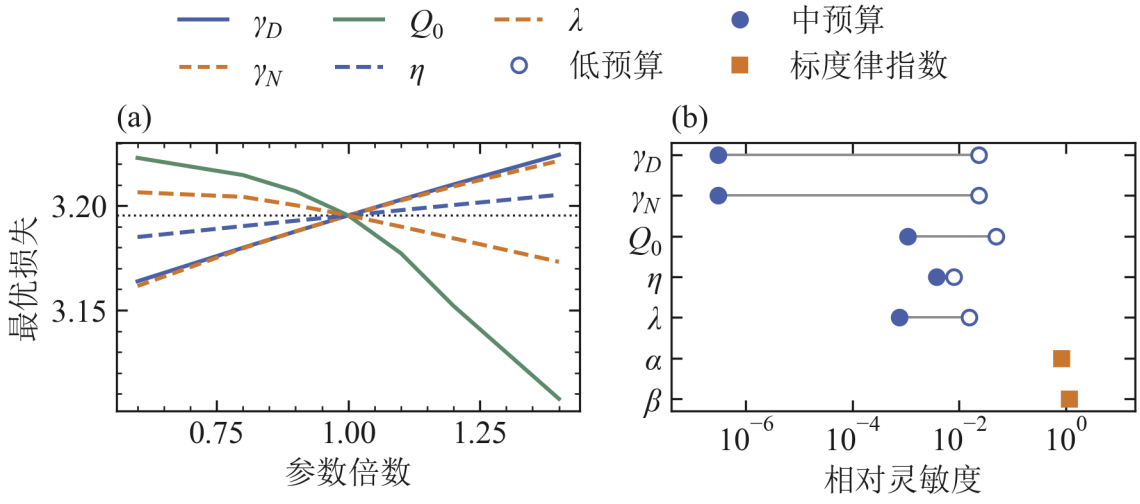


图 19　问题三最优解的参数灵敏度：(a) 曲线族；(b) 两档预算的相对灵敏度

问题一的权重方案也做了检验，组合权评分与熵权、CRITIC、PCA 评分的 Spearman 为 0.940、0.962、0.889，域级排序在四种方案下一致，质量评价对权重方案不敏感。

7.6 本章小结

本章在广义标度律上加入训练、质量与注意力三项开销约束，建立算力约束资源配置模型，用多起点序列二次规划求解并验证了 KKT 条件。三档预算的最优配置中，10^{22} FLOPs 处为 N^* = 5.58B、D^* = 234B、Q^* = 1，最优损失 2.157，比不投质量低 0.058。以活跃约束集的变化定义结构性转移，幂函数成本下在 4.0×10^{18} 与 6.3×10^{20} 处各出现一次，对数成本下在 2.5×10^{18} 处一步跳到质量饱和。解析给出临界上下文长度 30000，131072 时有效预算只剩 18.6%。灵敏度分析表明最优配置对质量参数不敏感，对标度律指数敏感，模型结论是稳的。本章求出的最优损失是问题四桥接的输入。

八. 问题四：规模与技术进步的分离及能力前沿预测

本章针对问题四展开，用附件 C 把训练损失翻译成榜单得分，分离规模扩张与非规模技术进步的贡献，再预测算力增长放缓时的能力前沿。

8.1 问题分析

问题四：规模与技术进步的分离及能力前沿预测

问题四要求说明综合能力度量、开源口径、模型类型与时间轴的取法，分离并量化规模扩张与非规模技术进步的贡献，建立损失到榜单得分的映射并讨论映射误差，在算力增长放缓情景下预测未来 12 与 24 个月的能力前沿并给出不确定性。

这一问含有三个子问题，先对它们做步骤拆分。

子问题一：先把口径定下来——立规矩

1）按许可证给榜单分层，只保留允许研究与复现的开放权重模型；2）按榜单标签区分预训练与对话微调两类；3）时间轴取提交日期，综合能力取六维平均分。

子问题二：把能力提升拆开——做分解

1）把得分对参数量对数与时间做回归，得到规模系数与时间系数；2）用首末季度前十模型的均分变化，拆出规模贡献与技术贡献；3）把同一分解做到 C8 的任务簇上，看哪些能力靠规模、哪些靠技术。

子问题三：把损失译成得分并外推——给预测

1）用上限固定为 100 的 logistic 建立损失到得分的桥接，基座与对话分开拟合；2）用问题二的经典律在损失一侧做自证，并讨论映射误差的传递；3）在 logit 尺度上对累计前沿做趋势外推，给出基准、放缓与停滞三个情景及区间。

问题四的求解路线如图 20 所示，先定口径，再做分解、桥接与逐任务聚合，最后预测前沿。

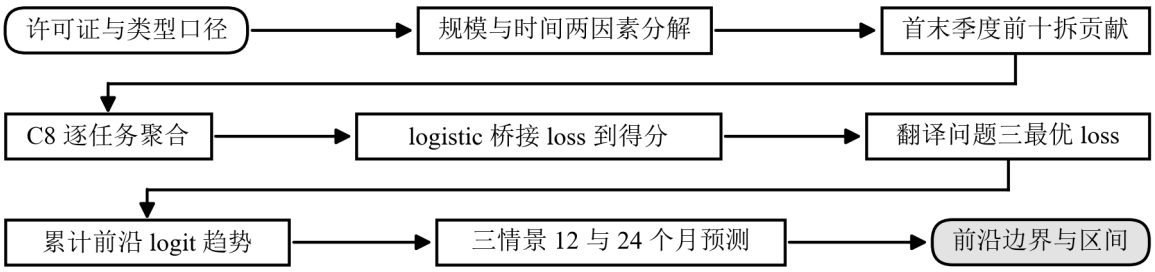


图 20 问题四思路框架图

规模与时间两因素分解模型：把榜单得分对参数量对数与提交时间做线性回归，参数量项的系数是每十倍参数带来的得分，时间项的系数是每年非规模技术进步带来的得分。前沿的抬升按首末季度前十模型的均分变化拆成规模贡献与技术贡献两部分，另做前沿回归与分位回归作对照，逐任务聚合再把同一分解做到四个任务簇上。

Loss 到 Benchmark 桥接模型：榜单得分有 0 到 100 的上下限，取上限固定为 100 的 logistic，logit 尺度的得分对 loss 线性，基座与对话模型分开拟合。桥接数据按可比性分层，高可比样本的 loss 与附件 B 同源，中可比样本的 loss 来自各自的技术报告，映射误差用两层分别报告。

累计前沿预测模型：预测对象是累计前沿而不是逐月最高分，在 logit 尺度上做线性趋势，把历史增速拆成规模与技术两部分，未来的规模项按开源模型参数量增速乘情景系数给出，基准、放缓、停滞三个情景分别对应系数 1、0.5 与 0，不确定性来自增速估计的标准误。

8.2 前沿抬升的机理分析

同一时刻的模型得分随参数量对数近似线性上升，这是规模扩张；同一参数量的模型随时间得分上升，这是架构、对齐、数据工程带来的非规模技术进步。如图 21 所示，前沿的抬升可以拆成沿参数量方向的移动和整条曲线向上的平移两部分，前者由 b_N 乘前沿模型参数量的变化给出，后者由 b_t 乘时间给出。在榜单窗口内，前沿模型的参数量从 72B 到 78B 几乎没变，抬升几乎全部来自平移。

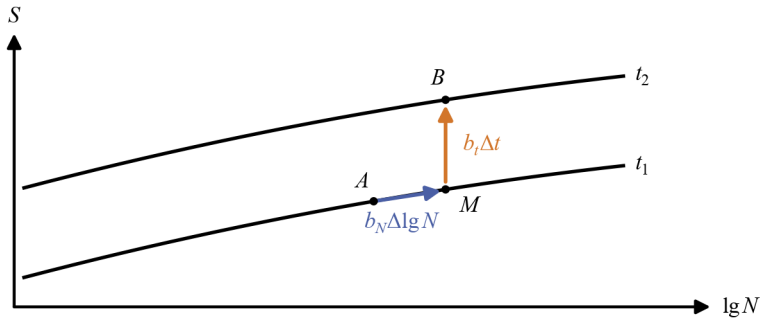


图 21 前沿抬升的两个来源

8.3 口径、分解、桥接与预测模型

8.3.1 口径设定

榜单 C1 来自 Open LLM Leaderboard v2[17]，去掉缺日期与参数量的记录后 4561 条，时间轴按提交日期，范围 2024 年 6 月 8 日到 2025 年 3 月 13 日。榜单模型均为开放权重，同名模型在榜单里有多条提交记录，元数据表按模型名去重后再匹配，匹配到 442 条，其中 424 条标注开放权重。开源口径按许可证分三层：允许研究与复现且无附加限制的 apache、mit、bsd、cc-by 等为宽松层 1787 条，允许研究但有用途限制的 llama、gemma、qwen、cc-by-nc 等为受限层 1014 条，许可证缺失的 1760 条排除，入选 2801 条。类型按榜单标签分为 pretrained 236 条与 chat/finetuned 2506 条，持续预训练与其它类型 58 条只参与全样本回归，不单独报告。榜单原始标签有七种，领域微调、基座合并与对话三类合并为 chat/finetuned，预训练单独一类，各层的条数见表 19。综合能力取六维平均分，与六维 z 分数均值的 Spearman 为 0.984，两种度量给出的排序几乎相同，取前者是因为它与榜单公布的口径一致。时间轴取提交日期而不是发布日期，因为榜单窗口只有 9 个月，发布日期缺失的模型占三分之一以上，而提交日期每条都有；两者的差别在检验一节用 C3 的长时序讨论。

8.3.2 规模与时间两因素分解模型

记得分 S，参数量 N，时间 t 以年计，类型哑变量 $\boldsymbol{z}$，

$$S = b_0 + b_N \log_{10} N + b_t\, t + \boldsymbol{b}_z^{\top}\boldsymbol{z} + \varepsilon. \tag{18}$$

表 19　问题四的数据口径与各层条数

口径	层级	条数	口径	层级	条数
开源筛选	宽松许可证	1787	模型类型	chat/finetuned	2506
开源筛选	受限许可证	1014	模型类型	pretrained	236
开源筛选	许可证缺失，排除	1760	模型类型	持续预训练与其它	58
开源筛选	入选合计	2801	开放权重	Epoch 匹配且标注开放	424 / 442

首末季度前十模型均分的变化 ΔS 拆成

$$\Delta S = \underbrace{b_N \Delta\overline{\log_{10} N}}_{\text{规模}} + \underbrace{b_t \Delta\bar{t}}_{\text{技术}} + r, \tag{19}$$

两项与 ΔS 的比值即贡献占比。

8.3.3　Loss 到 Benchmark 桥接模型

得分有上限 100，取 logistic，logit 得分对 loss 线性，基座与对话模型分别拟合。选非线性映射而不是直线，是因为榜单得分在 loss 很高时贴近零、在 loss 很低时贴近满分，两端都被压缩，看似突变的能力涌现往往只是度量的非线性 [19]，logistic 正好把这种压缩吸收掉：

$$S = \frac{100}{1 + \exp\left(-(a - bL)\right)}. \tag{20}$$

映射的形状如图 22 所示，loss 两端同样大的变化对应的得分变化很小，中段对应的变化最大，桥接误差因此也集中在中段。

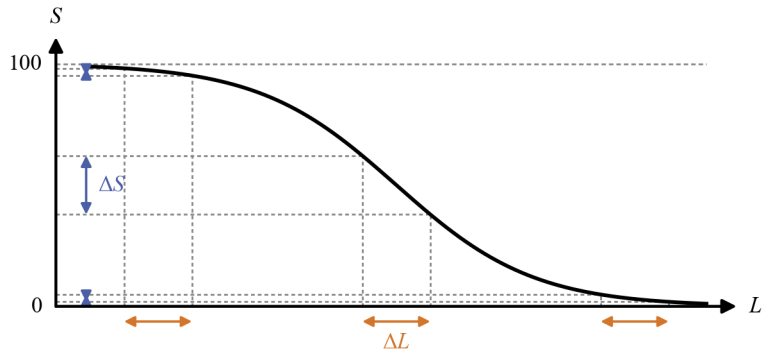


图 22　Loss 到得分的 logistic 映射

8.3.4　前沿预测模型

预测对象是累计前沿 $F(t) = \max_{\tau \le t} S(\tau)$。在 logit 尺度上，

$$\begin{cases} \operatorname{logit}\left(F(t+h)/100\right) = \operatorname{logit}\left(F(t)/100\right) + \left(r_{\text{tech}} + \kappa\, b_N^{\lg}\, \beta_{\text{open}}\right)h, \\ r_{\text{tech}} = r_F - b_N^{\lg}\, \dot{n}_{\text{rec}}, \end{cases} \tag{21}$$

r_F 是累计前沿在 logit 尺度的年增速，$b_N^{\lg}$ 是 logit 尺度面板回归的规模系数，$\dot{n}_{\text{rec}}$ 是纪录保持者参数量对数的年变化，β_{open} 是 C4 中开源模型参数量的年增速，κ 为情景系数，基准 1，算力放缓 0.5，停滞 0。不确定性取 r_F 标准误的正态抽样。

8.4 模型的求解与检验

8.4.1 分解结果

全样本 OLS 得 b_N = 13.7 分每十倍参数，b_t = 13.2 分每年，R^2 0.530，两者 p 值均小于 0.001；chat 模型 b_N = 15.8，b_t = 13.9；pretrained 模型 b_N = 7.2，b_t = 7.3。按尺寸分箱取季度最大值的前沿回归给 b_N = 9.6，b_t = 17.2，0.9 分位回归给 15.9 与 17.6。chat 模型首末季度前十均分上升 7.36 分，规模贡献 −3.95，技术贡献 8.41，残差 2.90，技术进步占 115%，规模占 −54%，前沿在参数量下降的同时靠技术进步上升；pretrained 前十下降 4.69 分，大基座模型提交减少拉低了前十。C3 长时序 2019 到 2025 年给 b_N = 14.1，b_t = 3.3 每年，年度前沿 b_t = 6.1，比榜单窗口内的 13 低得多，新榜上线初期的针对性调优抬高了短期技术系数。C4 中语言模型前沿训练算力 2020 年以来每年增长 0.47 个数量级，倍增 7.6 个月，与 Sevilla 等人 [20] 报告的深度学习时代 5 到 6 个月的倍增期同量级，开源模型每年 0.65 个数量级，倍增 5.5 个月，开源模型参数量每年增长 0.29 个数量级。三组样本的系数与前十均分的分解见表 20 与表 21。三种回归给出的规模系数在 7 到 17 之间，时间系数在 6 到 18 之间，pretrained 的两个系数都只有 chat 的一半左右，说明对话微调放大了规模与时间两方面的收益。前十均分的分解里规模贡献为负，不是规模不起作用，而是纪录模型的参数量从首季度到末季度下降了，同样的技术水平下换成更小的模型本应丢分，实际反而涨了 7.4 分，全部由技术进步补回并超出。

表 20 规模与时间两因素分解的系数（b_N 为每十倍参数的得分，b_t 为每年的得分，前沿为前沿回归，分位为 0.9 分位回归）

样本	条数	OLS b_N	OLS b_t	R^2	前沿 b_N	前沿 b_t	分位 b_N	分位 b_t
全体	2801	13.7	13.2	0.530	9.6	17.2	15.9	17.6
pretrained	236	7.2	7.3	0.477	9.3	5.6	8.8	7.7
chat/finetuned	2506	15.8	13.9	0.515	9.9	17.4	17.6	17.3

表 21 首末季度前十均分变化的分解（2024Q2 到 2025Q1，单位为分）

样本	均分变化	规模贡献	技术贡献	残差	规模占比	技术占比
全体	7.36	−3.45	8.08	2.74	−47%	110%
pretrained	−4.69	−5.82	4.89	−3.76	–	–
chat/finetuned	7.36	−3.98	8.48	2.86	−54%	115%

8.4.2 桥接结果

桥接表 C6 共 75 条，高可比 7 条全是 Pythia，得分在 5 分附近，中可比 68 条。基座 44 条 a = 0.93，b = 1.27，RMSE 8.0 分；对话模型 31 条 a = 2.67，b = 1.77，RMSE 8.6 分，同一 loss 下对话微调抬高榜单分 10 到 15 分；全体 Spearman −0.55。只用高可比 7 条拟合 RMSE 0.33，但 loss 范围只有 2.09 到 2.60，得分范围 5 到 6，不能外推。分维度看 IFEval、GPQA、MUSR 的 RMSE 在 5 到 7 分，BBH、MMLU-PRO 在 13 到 14 分。问题三的最优 loss 按基座映射：10^{19} 的 3.13 到 3.20 对应 4 分，10^{22} 的 2.15 对应 14 分，10^{24} 的 1.92 对应 18 分，若做对话微调分别约为 5、24、33 分。映射误差 8 分，10^{19} 与 10^{22} 的差距可分辨，10^{22} 与 10^{24} 的差距在误差以内，质量投入带来的 0.03 到 0.06 的 loss 收益对应 1 分以内，在 benchmark 尺度上不可辨。各层桥接与分维度的参数见表 22，问题三最优 loss 的翻译见表 23。分维度的斜率 b 差别很大：BBH 与 MMLU-PRO 在 2.0 左右，这两类知识与推理任务随 loss 下降提升最快；IFEval 只有 0.26，MUSR 0.83，指令遵循与多步推理更多来自对齐与后训练，与预训练 loss 关系弱。这也解释了为什么同一 loss 下对话模型比基座高 10 到 15 分，差距主要来自 IFEval 这一维。

表 22　Loss 到 Benchmark 桥接模型的参数与误差

样本层	条数	a	b	RMSE / 分	维度	a	b	RMSE / 分
全体	75	1.43	1.36	10.1	IFEval	−0.61	0.26	6.7
高可比	7	−2.42	0.17	0.3	BBH	2.92	2.02	12.8
中可比	68	1.12	1.17	9.9	MATH	0.25	1.29	9.2
基座	44	0.93	1.27	8.0	GPQA	1.31	1.92	5.3
对话	31	2.67	1.77	8.6	MUSR	−0.62	0.83	5.0
					MMLU-PRO	2.77	1.96	13.9

表 23　问题三最优 loss 翻译成六维平均分（幂函数成本）

预算 / FLOPs	L^*	基座得分	90% 区间	不投质量的得分	若做对话微调
10^{19}	3.195	4.1	0 到 12.2	4.1	4.9
10^{22}	2.157	14.0	6.0 到 22.0	13.1	24.2
10^{24}	1.916	18.1	10.1 到 26.1	17.5	32.8

8.4.3　逐任务聚合

C8 共 1863 个模型目录 1958 个 JSON，每个目录取最新可解析文件，4 个截断文件跳过，1860 个解析成功，1854 个与 C1 匹配，得到 38 个子任务。均值最低的是 MATH 的中级代数 3.5 分、预备微积分 4.3 分、几何 5.5 分，前沿分别为 31.8、36.3、43.2；最高的是 BBH 的布尔表达式 76.4 分、体育常识 68.0 分，前沿 96 与 95。按任务簇回归，MATH 八个子任务 $b_N = 10.4$，$b_t = 20.0$ 每年，技术进步最快；BBH 24 个子任务 $b_N = 16.1$，$b_t = 6.9$，最依赖规模；GPQA 与 MUSR 的 b_N 在 5 左右，b_t 分别为 4.6 与 1.6，几乎不随时间进步。能力增长集中在数学类任务。四个任务簇与得分最低、最高的各五个子任务见表 24。数学类子任务均值最低但前沿抬得最快，每季度 3 到 9 分，代数类的前沿已到 82 到 85 分，中级代数与预备微积分的前沿只有 32 到 36 分，是当前最难的两项；BBH 里布尔表达式、体育常识、倒装句这类任务均值已在 60 分以上，前沿接近满分，每季度只涨 0 到 1.5 分，规模效应已经把它们推到天花板附近。汇总均分把这两种走势平均掉了，逐任务聚合才看得出能力增长的结构。

表 24　C8 逐任务聚合：四个任务簇与得分最低、最高的子任务

任务簇	子任务数	均值	b_N	b_t	子任务	均值	前沿	前沿季增
BBH	24	47.7	16.1	6.9	数学中级代数	3.5	31.8	0.6
MATH	8	10.5	10.4	20.0	数学预备微积分	4.3	36.3	3.4
GPQA	3	29.7	4.9	4.6	数学几何	5.5	43.2	6.6
MUSR	3	40.0	5.3	1.6	数学计数与概率	8.7	61.0	7.0
					数学数论	10.3	74.0	6.3
					BBH 导航	58.5	83.6	2.7
					BBH 讽刺识别	60.2	92.7	−0.2
					BBH 倒装句	63.2	98.8	1.2
					BBH 体育常识	68.0	94.8	0.2
					BBH 布尔表达式	76.4	96.0	1.5

8.4.4　前沿预测

累计前沿在 logit 尺度的年增速，chat 模型为 0.468 ± 0.103，pretrained 为 0.196 ± 0.052。纪录模型参数量每年变化 0.04 个数量级，logit 尺度的规模系数 $b_N^{\lg} = 1.06$，历史规模贡献

0.04，其余 0.43 为技术进步，占 92%；未来规模项基准值 $b_N^{\lg}\beta_{\text{open}} = 1.06 \times 0.29 = 0.31$，放缓情景取一半为 0.15，停滞情景为 0。pretrained 的纪录模型参数量在窗口内没有变化，历史规模贡献为零，0.196 的增速全部是技术进步。结果如图 23 与表 25 所示。图 23(a) 是 chat 模型逐月前沿与累计前沿及三个情景的预测带，图 23(b) 是桥接散点与两条 logistic 曲线，图 23(c) 是四个任务簇的规模系数与时间系数。chat 模型当前前沿 52.1 分，12 个月后放缓情景 66 分，90% 区间 62 到 70，24 个月后 78 分，区间 72 到 83；pretrained 当前 38.4 分，12 个月后 46 分，24 个月后 53 分。面板 0.9 分位回归的乐观上界在 24 个月给 90 分，含新榜初期的调优效应，只作上限参考。放缓与基准的差在 12 个月为 3 分，24 个月为 5 分，小于趋势本身的不确定性，未来两年前沿主要由技术进步驱动。

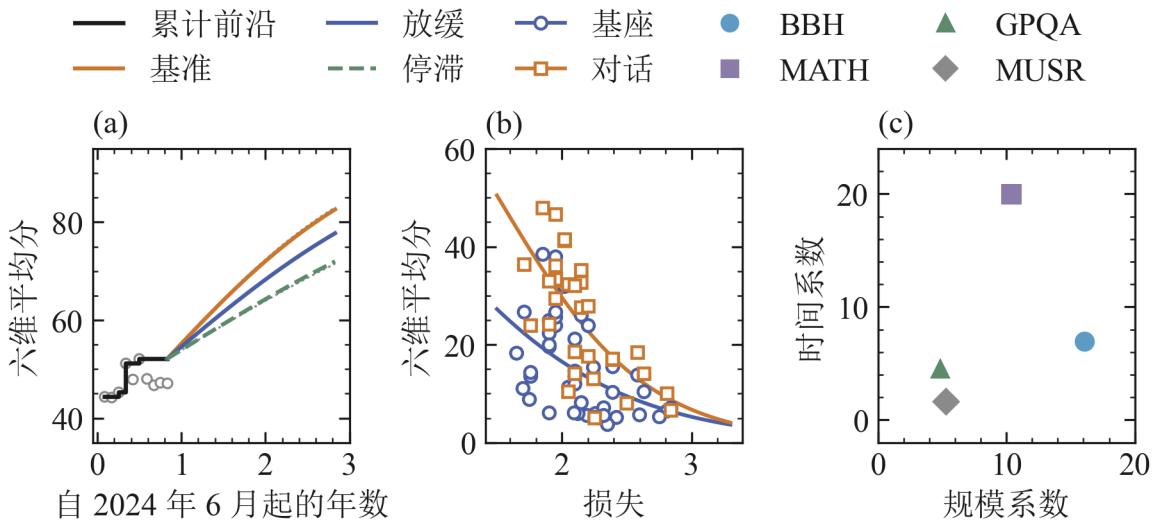


图 23　问题四结果：(a) 前沿与预测；(b) Loss 到得分的桥接；(c) 任务簇的规模与时间系数

表 25　开源模型能力前沿预测（六维平均分）

类型	情景	当前	12 个月	24 个月	24 个月 90% 区间
pretrained	基准	38.4	47.9	57.4	53.2–61.6
pretrained	算力放缓	38.4	45.5	52.8	48.6–56.9
pretrained	规模停滞	38.4	43.2	48.0	43.8–52.3
chat/finetuned	基准	52.1	69.4	82.6	77.2–86.9
chat/finetuned	算力放缓	52.1	66.1	77.7	71.5–83.0
chat/finetuned	规模停滞	52.1	62.6	72.0	64.7–78.2
chat/finetuned	面板上界	52.1	75.9	90.2	–

8.4.5　模型的检验

桥接模型用问题二的经典律做自证：桥接表里 Pythia 七个尺寸最终检查点的 loss 与式 (7) 的计算值 MAPE 0.003%，附件 B 与附件 C 在 loss 一侧完全衔接；把这些 loss 代入基座桥接得到的得分为 8.5 到 15.0 分，榜单实测为 5.1 到 6.1 分，RMSE 6.95 分，在桥接误差 8 分之内，Pythia 系统性低于现代基座曲线是因为它们是 2023 年的模型，同样 loss 下的下游能力弱于新一代基座，这正是问题四要分离的技术进步。分解模型用 C3 长时序做条件弱化检验，把窗口从 9 个月放宽到 6 年，b_N 从 13.7 变为 14.1，规模系数稳定，时间系数从 13 降到 3.3，说明短期技术系数含榜单效应，预测里因此用累计前沿的实际增速而不是面板的 b_t。

8.5　本章小结

本章先定下开源、模型类型与时间轴三项口径，入选 2801 条记录。两因素分解表明前沿抬升中技术进步贡献 115%，规模贡献 −54%，纪录模型的参数量几乎没有增长。上限固定的 logistic 桥接把交叉熵损失翻译成榜单得分，基座曲线 RMSE 为 8.0 分，据此指出问题三中 10^{22} 与 10^{24} 两档预算的得分差距落在映射误差以内。C8 的 38 个子任务聚合显示能力增长高度集中在数学类任务上，这是汇总均分看不出来的。累计前沿预测给出算力放缓情景下对话模型 12 个月后 66.1 分、24 个月后 77.7 分，放缓与基准情景的差距小于趋势本身的不确定性，说明未来两年前沿主要由技术进步驱动。

九.　模型评价

9.1　模型的优点

一是四问共用交叉熵损失这一个度量，问题一的 Q 与 $\boldsymbol{p}^{*}$ 进入问题二，问题二的广义律进入问题三，问题三的 loss 经问题四桥接成得分，前后可以互相印证，问题三的解回代问题二的弹性、桥接模型回代问题二的经典律，两处印证都通过。二是对附件数据做了可信度分层，识别出 B1 与 B10 是公式生成、B8 质量方向相反、外推表排序翻转三处特性，并据此决定各数据的用途，真实观测只用于拟合与检验，半合成只用于引入缺失的维度，估算数据只用于检查自洽。三是广义律在 $Q = 1$ 时严格退化为经典形式，弹性、等价参数倍数与替代条件都有解析式，最优性条件推出的等边际率在数值解上核对通过。四是结构性转移有明确的数学定义与两个可计算的识别指标，三者在三种成本函数下互相印证。五是每一问的关键算法都做了多算法对比，配比回归器六种、配比搜索四种、标度律拟合器四种、优化器四种，选型的理由写明，并把与结论相反的对比结果如实报告。

9.2　模型的缺点

一是质量项只能靠半合成数据 B6、B7 估计，真实训练里质量对 loss 的作用可能与之不同，半合成数据的质量分口径与问题一的质量分口径也未必一致。二是配比效应随规模衰减的指数只由 1M、60M、1B 三个尺度估计，外推到百亿参数时衰减速率可能偏离幂律。三是桥接样本的 loss 来自不同验证集，映射误差 8 分，10^{22} 与 10^{24} 预算的差距在误差以内。四是榜单窗口只有 9 个月，技术进步速率含新榜上线初期的调优效应，长时序上的时间系数只有窗口内的四分之一。

若能获得同一验证集上更多真实模型的 loss，桥接误差可以压到 3 分以内；若把质量成本函数的参数与真实数据清洗流水线的算力对齐，问题三的制度切换点会更可信；若配方实验能补上 10B 尺度的实测配比，配比衰减指数的外推会更稳；预测模型可以把 Epoch 的发布日期替代提交日期，去掉榜单效应。

9.3　模型的推广

质量评价与冲突消解的框架可用于任何多打分器的语料筛选，语义组与统计组的划分和主裁规则可以直接换成别的打分器组合；双作用广义律与算力约束配置模型可推广到多模态与代码模型的训练预算规划，只需换掉成本函数与基线质量；最优性条件给出的等边际率是通用的资源分配准则，任何可以按 FLOPs 计价的资源都能加进约束；规模与时间的分解方法可用于任何有参数量与时间戳的评测榜单，逐任务聚合能找出哪些能力靠规模、哪些靠技术，为训练资源投向提供依据。

参考文献

[1] Asai A, He J, Shao R, et al.，Synthesizing scientific literature with retrieval-augmented language models，Nature，650：857–863，2026。

[2] Hoffmann J, Borgeaud S, Mensch A, et al.，Training compute-optimal large language models，Advances in Neural Information Processing Systems，35：30016–30030，2022。

[3] Zhuang X, Zhang C, Ke Z, et al.，Meta-rater: a multi-dimensional data selection method for pre-training language models，arXiv preprint，2504.14194：1–24，2025。

[4] Penedo G, Kydlíček H, Ben allal L, et al.，The FineWeb datasets: decanting the web for the finest text data at scale，Advances in Neural Information Processing Systems，37：30811–30849，2024。

[5] Rae J W, Borgeaud S, Cai T, et al.，Scaling language models: methods, analysis and insights from training Gopher，arXiv preprint，2112.11446：1–120，2021。

[6] Liu Q, Zheng X, Muennighoff N, et al.，RegMix: data mixture as regression for language model pre-training，International Conference on Learning Representations，2025：1–28，2025。

[7] Diakoulaki D, Mavrotas G, Papayannakis L，Determining objective weights in multiple criteria problems: the CRITIC method，Computers & Operations Research，22(7)：763–770，1995。

[8] Aitchison J，The statistical analysis of compositional data，Journal of the Royal Statistical Society: Series B，44(2)：139–177，1982。

[9] Ke G, Meng Q, Finley T, et al.，LightGBM: a highly efficient gradient boosting decision tree，Advances in Neural Information Processing Systems，30：3146–3154，2017。

[10] Breiman L，Random forests，Machine Learning，45(1)：5–32，2001。

[11] Storn R, Price K，Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces，Journal of Global Optimization，11(4)：341–359，1997。

[12] Biderman S, Schoelkopf H, Anthony Q, et al.，Pythia: a suite for analyzing large language models across training and scaling，Proceedings of Machine Learning Research，202：2397–2430，2023。

[13] Bahri Y, Dyer E, Kaplan J, et al.，Explaining neural scaling laws，Proceedings of the National Academy of Sciences，121(27)：1–10，2024。

[14] Kaplan J, McCandlish S, Henighan T, et al.，Scaling laws for neural language models，arXiv preprint，2001.08361：1–30，2020。

[15] Huber P J，Robust estimation of a location parameter，The Annals of Mathematical Statistics，35(1)：73–101，1964。

[16] Kraft D，A software package for sequential quadratic programming，DFVLR-FB 88-28，Köln：DLR German Aerospace Center，1–33，1988。

[17] Fourrier C, Habib N, Lozovskaya A, et al.，Open LLM Leaderboard v2，https://huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard，访问时间 2026 年 9 月 23 日。

[18] Epoch AI，Data on AI models，https://epoch.ai/data/all_ai_models.csv，访问时间 2026 年 9 月 23 日。

[19] Schaeffer R, Miranda B, Koyejo S，Are emergent abilities of large language models a mirage?，Advances in Neural Information Processing Systems，36：55565–55581，2023。

[20] Sevilla J, Heim L, Ho A, et al.，Compute trends across three eras of machine learning，International Joint Conference on Neural Networks，2022：1–8，2022。

AI 工具使用声明

本文在数据处理代码的编写与调试、文献资料的整理以及正文文字的润色三个环节使用了 Anthropic 公司的 Claude 系列大语言模型，工具名称 Claude Code，模型版本 Claude Fable 5.1，开发机构 Anthropic，版本发布日期 2026 年。质量指标的方向判定、广义标度律的形式设计与推导、结构性转移的定义、各问结果的分析与结论由参赛队独立完成并逐项核验。附录中的代码在文件开头按规定注明了 AI 辅助信息，AI 生成的文字均经参赛队改写。

附录 A　支撑材料清单

- 结果文件：q1_quality.json（质量权重、域级 Q、冲突率）、q1_mixture.json（配比模型指标、$\boldsymbol{p}^*$）、q2_scaling.json（标度律参数、验证指标、弹性）、q3_optimize.json（三档预算最优解、预算扫描、上下文敏感性）、q4_frontier.json（分解、桥接、逐任务聚合、预测）、q_compare.json（多算法对比）、q_sens.json（灵敏度）。
- 代码文件：common.py（数据读取与预处理）、q1_quality.py、q1_mixture.py、q2_scaling.py、q3_optimize.py、q4_frontier.py、q_compare.py、q_search.py、q_argmin.py、q_sens.py，绘图为 clib.py、figs_schem.py、figs_result.py、figs_flow.py。每个文件开头按规定注明了 AI 辅助信息。
- 运行环境：Python 3.10，numpy、pandas、scipy、scikit-learn、lightgbm、statsmodels，CPU 即可。

附录 B　核心代码

以下为问题三算力约束资源配置模型的求解核心，其余代码见支撑材料。

```
# 本程序及代码是在人工智能工具辅助下完成的：Claude Code，模型 Claude Fable 5.1，
# 开发机构 Anthropic，版本发布日期 2026 年。
import numpy as np
from scipy import optimize

def L(N, D, Q):                          # 双作用广义标度律
    return E + A*(N*Q**gN)**(-al) + B*(D*Q**gD)**(-be)

def cost(N, D, Q, g, Lctx):              # 训练 + 质量 + 注意力
    return 6*N*D + D*max(g(Q)-g(Q0), 0.0) + ETA*N*D*Lctx

def solve(C, g, Lctx):
    best = None
    n0 = np.sqrt(C / (6 * 20))           # Chinchilla 比例的起点
    obj = lambda x: L(np.exp(x[0]), np.exp(x[1]), x[2])
    con = lambda x: np.log(C) - np.log(
        cost(np.exp(x[0]), np.exp(x[1]), x[2], g, Lctx))
    bnds = [(np.log(1e6), np.log(1e14)),
            (np.log(1e7), np.log(1e16)), (Q0, 1.0)]
    for fN in [0.1, 0.3, 1, 3, 10]:
        for q in [Q0, (Q0 + 1) / 2, 0.95]:
            x0 = [np.log(n0 * fN),
                  np.log(min(C / (8 * n0 * fN), 1e16)), q]
            r = optimize.minimize(obj, x0, method="SLSQP", bounds=bnds,
                                  constraints=[dict(type="ineq", fun=con)],
                                  options=dict(maxiter=500, ftol=1e-12))
            if r.success and (best is None or r.fun < best.fun):
                best = r
```

```
N, D, Q = np.exp(best.x[0]), np.exp(best.x[1]), best.x[2]
return N, D, Q, best.fun
```